# UNIVERSIDADE DE SÃO PAULO ESCOLA DE ENGENHARIA DE SÃO CARLOS

### Luciano Carli Moreira de Andrade

Transformada Wavelet e Técnicas de Inteligência Computacional Aplicadas à Identificação, Compressão e Armazenamento de Sinais no Contexto de Qualidade da Energia Elétrica

São Carlos

### Luciano Carli Moreira de Andrade

# Transformada Wavelet e Técnicas de Inteligência Computacional Aplicadas à Identificação, Compressão e Armazenamento de Sinais no Contexto de Qualidade da Energia Elétrica

Tese apresentada à Escola de Engenharia de São Carlos da Universidade de São Paulo, para obtenção do título de Doutor em Ciências - Programa de Pós-Graduação em Engenharia Elétrica.

Área de concentração: Sistemas Elétricos de Potência

Orientador: Prof. Dr. Mário Oleskovicz Coorientador: Prof. Dr. Ricardo Augusto Souza Fernandes

Trata-se da versão corrigida da tese. A versão original se encontra disponível na EESC/USP que aloja o Programa de Pós-Graduação de Engenharia Elétrica.

São Carlos 2017 AUTORIZO A REPRODUÇÃO TOTAL OU PARCIAL DESTE TRABALHO, POR QUALQUER MEIO CONVENCIONAL OU ELETRÔNICO, PARA FINS DE ESTUDO E PESQUISA, DESDE QUE CITADA A FONTE.

Carli Moreira de Andrade, Luciano

Transformada Wavelet e Técnicas de Inteligência Computacional Aplicadas à Identificação, Compressão e Armazenamento de Sinais no Contexto de Qualidade da Energia Elétrica / Luciano Carli Moreira de Andrade; orientador Mário Oleskovicz; coorientador Ricardo Augusto Souza Fernandes. São Carlos, 2017.

Tese (Doutorado) - Programa de Pós-Graduação em Engenharia Elétrica e Área de Concentração em Sistemas Elétricos de Potência -- Escola de Engenharia de São Carlos da Universidade de São Paulo, 2017.

1. Sistema Elétrico de Potência. 2. Qualidade da Energia Elétrica. 3. Detecção e Classificação de Distúrbios. 4. Sistemas Inteligentes. 5. Transformada Wavelet. 6. Compressão e Armazenamento de Dados. I. Título.

C553t

### FOLHA DE JULGAMENTO

Candidato: Bacharel LUCIANO CARLI MOREIRA DE ANDRADE.

Título da tese: "Transformada wavelet e técnicas de inteligência computacional aplicadas à identificação, compressão e armazenamento de sinais no contexto de qualidade da energia elétrica".

Data da defesa: 06/07/2017.

Comissão Julgadora:

Resultado:

Prof. Associado Mario Oleskovicz

(Orientador)

(Escola de Engenharia de São Carlos/EESC)

NOROUADO

Prof. Associado **José Carlos de Melo Vieira Junior**(Escola de Engenharia de São Carlos (EESC)

(Escola de Engenharia de São Carlos/EESC)

APROVADO

Prof. Associado **Alexandre Cláudio Botazzo Delbem** (Instituto de Ciências Matemáticas e de Computação/ICMC

Prof. Dr. Helmo Kelis Morales Paredes

(Universidade Estadual Paulista "Júlio de Mesquita Filho"/UNESP – Sorocaba)

Prof. Dr. **Francisco Assis de Oliveira Nascimento** (Universidade de Brasília/UnB)

Aprovado

Coordenador do Programa de Pós-Graduação em Engenharia Elétrica: Prof. Associado **Luis Fernando Costa Alberto** 

Presidente da Comissão de Pós-Graduação: Prof. Associado **Luis Fernando Costa Alberto** 

Este trabalho é dedicado aos meus pais, Sudário e Vandete, cuja dedicação e sacrifício permitiram que eu me tornasse Bacharel em Ciências de Computação.

### Agradecimentos

Agradeço primeiramente aos meus pais, Sudário e Vandete, cujo amor incondicional fez com que eles renunciassem aos seus sonhos para que eu pudesse realizar os meus.

À minha irmã Juliana, Doutoranda em Letras, que me motivou a cursar pósgraduação.

À minha namorada e companheira Larissa por todos os momentos de felicidade e pelo incentivo durante os momentos mais difíceis do cansativo processo de desenvolvimento do doutorado.

Ao Professor Doutor André Carlos Ponce de Leon Ferreira de Carvalho pela orientação durante a graduação onde iniciei pesquisa na área de inteligência computacional.

Ao Professor Doutor Ivan Nunes da Silva, cuja orientação durante o Mestrado em Ciências me conferiu a preparação teórica e experimental necessárias para prosseguir nos estudos e desenvolver o presente trabalho de doutorado.

Sou grato ao Ph.D. Tejaswi Nanjundaswamy, meu colega de laboratório na Universidade da Califórnia, Santa Barbara (UCSB), por compartilhar seus conhecimentos ao longo da sincera e valiosa orientação estendida a mim.

Ao professor Ph.D. Kenneth Rose (UCSB), que me deu a oportunidade de trabalhar com a sua equipe como pesquisador. Suas valiosas orientações e o acesso ao seu laboratório e às suas instalações de pesquisa em compressão de sinais tornou possível a realização do presente trabalho de doutorado.

Ao meu coorientador Professor Doutor Ricardo Augusto Souza Fernandes, pelo qual tenho muita estima e admiração, pois me propiciou um grande aprendizado, pela assistência, apoio e tempo dedicado durante o doutorado.

Meus agradecimentos, de forma muito especial, ao meu orientador Professor Doutor Mário Oleskovicz, por ter me proporcionado a oportunidade de fazer parte do programa de doutorado dessa Escola, pelas orientações e correções dos artigos escritos, pela orientação no desenvolvimento dessa tese e cuja dedicação e competência permitiram meu

amadurecimento na pesquisa e na vida acadêmica.

Ao Laboratório de Sistemas de Energia Elétrica (LSEE) por toda infra-estrutura oferecida, assim como seus integrantes, pelas sugestões durante o desenvolvimento desse trabalho e pelo companheirismo durante o decorrer do doutorado.

A todos os funcionários e docentes do programa de pós-graduação da Escola de Engenharia de São Carlos - USP, cujo compromisso com a pesquisa em engenharia possibilitou o desenvolvimento do doutorado.

À Coordenação de Aperfeiçoamento de Pessoal de Nível Superior (CAPES) pela concessão das bolsas de doutorado e de estágio no exterior. Sem todo o apoio financeiro prestado não seria possível a realização desse trabalho.

Finalmente, agradeço a todos que de alguma maneira contribuíram para minha formação como pesquisador e minha formação como cidadão.



### RESUMO

ANDRADE, L. C. M. Transformada Wavelet e Técnicas de Inteligência Computacional Aplicadas à Identificação, Compressão e Armazenamento de Sinais no Contexto de Qualidade da Energia Elétrica. 2017. 155p. Tese (Doutorado) - Escola de Engenharia de São Carlos, Universidade de São Paulo, São Carlos, 2017.

A presença de distúrbios na energia elétrica fornecida aos consumidores pode causar a diminuição no tempo de vida útil dos equipamentos, mal funcionamento ou até mesmo sua perda. Desse modo, ferramentas capazes de realizar a detecção, localização, classificação, compressão e o armazenamento de sinais de forma automática e organizada são essenciais para garantir um processo de monitoramento adequado ao sistema elétrico de potência como um todo. Dentre as ferramentas comumente aplicadas às tarefas supramencionadas, pode-se destacar a Transformada Wavelet (TW) e as Redes Neurais Artificiais (RNAs). Contudo, ainda não foi estabelecida uma metodologia para obtenção e validação da TW e seu nível de decomposição, bem como da arquitetura e da topologia de RNAs mais apropriadas às tarefas supracitadas. O principal fato que levou a esta constatação deve-se à análise da literatura correlata, onde é possível notar o uso de distintas TW e RNAs. Neste contexto, a primeira contribuição desta pesquisa foi o projeto e desenvolvimento de um método eficiente de segmentação de sinais com distúrbios associados à Qualidade da Energia Elétrica (QEE). O método desenvolvido se beneficia das propriedades da TW de identificação temporal de descontinuidades em sinais. A segunda contribuição é o desenvolvimento de um algoritmo automático que, por meio do método de segmentação desenvolvido e de classificação por RNAs, indique as melhores ferramentas (Wavelets e RNAs) para as tarefas de segmentação, extração de características e classificação de distúrbios de QEE. Esse algoritmo foi desenvolvido com base nos recursos dos Algoritmos Evolutivos (AEs) e adotou RNAs do tipo Perceptron Multicamadas, pois, esta arquitetura pode ser considerada consagrada no que se refere à classificação de padrões. Por fim, a terceira contribuição é relativa ao desenvolvimento de um procedimentos baseados em AEs, a fim de se aprimorar métodos de compressão de dados que preservem as informações relevantes nos sinais de QEE. Assim, é importante mencionar que os resultados dessa pesquisa poderão determinar mecanismos automáticos a serem utilizados no processo de registro, tratamento e armazenamento de informações que serão importantes para se manter um banco de dados (histórico) atualizado nas concessionárias de energia, a partir do qual, índices e um melhor mapeamento e entendimento de todos os distúrbios relacionados à QEE poderão ser melhor entendidos e solucionados.

Palavras-chave: Sistema Elétrico de Potência, Qualidade da Energia Elétrica, Detecção e Classificação de Distúrbios, Sistemas Inteligentes, Transformada Wavelet, Compressão e

Armazenamento de Dados.

### ABSTRACT

ANDRADE, L. C. M. Wavelet Transform and Soft Computing Techniques Applied to Identification, Compression and Storage of Signals in the Power Quality Context. 2017. 155p. Tese (Doutorado) - Escola de Engenharia de São Carlos, Universidade de São Paulo, São Carlos, 2017.

The presence of disturbances in the electrical power supplied to consumers can decrease the lifetime of the equipment, cause malfunction or even their breakdown. Thus, tools able to perform detection, localization, classification, compression and storage of signals automatically and organized manner are essential to ensure adequate monitoring process to electric power systems as a whole. Among the tools commonly applied to the tasks mentioned above, one can highlight the Wavelet Transform (WT) and Artificial Neural Networks (ANN). However, the WT has not been established yet and nor its level of decomposition, as well as the most appropriate ANN architecture and topology to the tasks already mentioned. The main fact that has led to this finding is due to the review of related literature, where it is possible to note the use of distinct WT and ANN. Therefore, the first contribution of this research was the design and development of an efficient method of segmentation of signals associate to Power Quality (PQ) disturbances. The developed method take advantage of WT properties of temporal identification of signal discontinuities. The second contribution is the development of an automatic algorithm that, through the segmentation method developed and classification by ANN, indicates the best tools (Wavelets and ANN) for the tasks of segmentation, extraction of characteristics and classification of QEE disturbances. This algorithm was developed based on the resources of the Evolutionary Algorithms and it adopts Multi-layered Perceptron type ANN, once this architecture can be considered consecrated with regard to the patterns classification. Finally, the third contribution is related to the development of EA based procedures in order to improve data compression methods that preserve the relevant information in the PQ signals. Thus, it is important to mention that the results of this research may determine automatic mechanisms to be used in the process of recording, processing and storing information that will be important in order to maintain an up-to-date (historical) database in the utilities, from which, indexes and a better mapping and understanding of all PQ related disturbances can be better understood and solved.

**Keywords**: Electric Power System, Power Quality, Detection and Classification of Disturbances, Intelligent Systems, Wavelets Transform, Data Compression and Storage.

### Lista de ilustrações

Figura 1 -	Contexto da pesquisa de doutorado.	30
Figura 2 -	Montante de trabalhos com Wavelets	41
Figura 3 -	A aplicação de Wavelets nos mais variados problemas relacionados aos	
	SEPs	42
Figura 4 -	Trabalhos observados na literatura que resultaram de aplicações por	
	RNAs	46
Figura 5 -	Trabalhos decorrentes da aplicação de RNAs em SEPs	47
Figura 6 –	Montante dos trabalhos encontrados e relacionados com AEs	49
Figura 7 -	Trabalhos que se utilizaram de aplicações de AEs	50
Figura 8 -	Sequência das principais etapas da pesquisa	75
Figura 9 -	Framework para a classificação geral dos sinais	81
Figura 10 –	Exemplo ilustrativo da decomposição realizada pela TWD	82
Figura 11 -	Limiar característico baseado na severidade dos afundamentos de tensão.	84
Figura 12 –	Limiar característico baseado no comportamento dos sinais com oscila-	
	ção transitória	84
Figura 13 -	Limiar característico baseado na DHT	85
Figura 14 -	Limiar adaptativo para sinais caracterizando o notching	86
Figura 15 -	Limiar adaptativo para a combinação de afundamentos com distorção	
	harmônica	87
Figura 16 -	As características de entrada direcionadas às 14 RNAs implementadas	
	para a classificação dos distúrbios	96
Figura 17 –	Topologia final das RNAs empregadas para a classificação dos distúrbios. 9	96
Figura 18 -	Fluxograma de determinação do conjunto $(TWD_1; TWD_2; PMC)$ mais	
	apto para a segmentação, extração de características e classificação dos	
	sinais com distúrbios de QEE	00
Figura 19 –	Cruzamento uniforme empregado no AG	01
Figura 20 -	Busca de equilíbrio na compressão	02
Figura 21 –	Fluxograma do framework de compressão dos sinais	04
Figura 22 -	Exemplo da Quantização Linear	05

Figura 23 – 1	Fluxograma dos Algoritmos 4 e 5
Figura 24 – l	Fronteira de Pareto (Melhor indivíduo)
Figura 25 – l	Limiar adaptativo para um sinal com flicker
Figura 26 – 1	Limiar adaptativo para um sinal com distorção harmônica 117
Figura 27 – 1	Limiar adaptativo para um sinal com transitório impulsivo 117
Figura 28 – 1	Limiar adaptativo para um sinal com transitório oscilatório 118
Figura 29 – 1	Limiar adaptativo para um sinal com interrupção de tensão 118
Figura 30 – 1	Limiar adaptativo para um sinal com afundamento de tensão 119
Figura 31 – 1	Limiar adaptativo para um sinal com elevação de tensão 119
Figura 32 – 1	Limiar adaptativo para um sinal com <i>notching</i>
Figura 33 – 1	Limiar adaptativo para um sinal com afundamento de tensão e flicker. 121
Figura 34 – 1	Limiar adaptativo para um sinal com elevação de tensão e flicker 122
Figura 35 – 1	Limiar adaptativo para um sinal com elevação de tensão e distorção
]	harmônica
Figura 36 – 1	Limiar adaptativo para um sinal com afundamento de tensão e transi-
t	tório oscilatório
Figura 37 – 1	Limiar adaptativo para um sinal com elevação de tensão e transitório
(	oscilatório
Figura 38 – 1	Limiar adaptativo para um sinal com afundamento e distorção harmônica. 124
Figura 39 – 1	Limiar adaptativo para uma oscilografia com distorção harmônica 125
Figura 40 – 1	Limiar adaptativo para uma oscilografia com transitório oscilatório 126
Figura 41 – l	Limiar adaptativo para uma oscilografia com afundamento de tensão e
t	transitório oscilatório
Figura 42 – 1	Limiar adaptativo para uma oscilografia com elevação de tensão 127
Figura 43 – 1	Exemplo do limiar adaptativo para uma oscilografia com interrupção
(	de tensão
Figura 44 – 1	Exemplo do limiar adaptativo para uma oscilografia com transitório
i	impulsivo
Figura 45 - 7	Taxas de segmentação ( $Daubechies~6~vs~Coiflets~2$ )
Figura 46 - 7	Taxas de classificação (Validação Cruzada vs Algoritmo Genético) 134
Figura 47 – 0	Gráficos das taxas (bits por amostra) médias dos 14 distúrbios 138
Figura 48 – 0	Curvas comparativas para harmônicos
Figura 49 – 0	Curvas comparativas para transitório oscilatório
Figura 50 – 0	Curvas comparativas para transitório oscilatório com afundamento de
t	tensão
Figura 51 – 0	Curvas comparativas para elevação de tensão
Figura 52 – 0	Curvas comparativas para interrupção de tensão
Figura 53 – 0	Curvas comparativas para transitório impulsivo

### Lista de tabelas

Tabela 1 –	Equações sintéticas dos distúrbios simples analisados	78
Tabela 2 –	Equações sintéticas dos distúrbios combinados analisados	79
Tabela 3 –	Número de segmentos para os afundamentos de tensão analisados	89
Tabela 4 –	Número de segmentos para as elevações de tensão analisadas	89
Tabela 5 –	Número de segmentos para as interrupções de tensão analisadas	89
Tabela 6 –	Número de segmentos para as distorções harmônicas analisadas	90
Tabela 7 –	Resultado geral da classificação das oscilografias reais	30
Tabela 8 –	Abreviaturas dos distúrbios	36
Tabela 9 –	Comparação da taxa de compressão	37

## Lista de Algoritmos

1	Algoritmo simplificado para a determinação do limiar adaptativo 88
2	O AG que determina os conjuntos $(TWD_1; TWD_2; PMC)$ mais aptos 98
3	Função que determina a aptidão dos conjuntos $(TWD_1;TWD_2;PMC)$ 99
4	NSGA-II para determinar o indivíduo mais apto: $(Limiar;\ Wavelet;\ FatorDeEscala;ConstanteDeDeslocamento;) \ . \ . \ . \ . \ . \ . \ . \ . \ . \ $
5	Função que determina a aptidão dos indivíduos: $(Limiar;\ Wavelet;\ Fator De Escala;\ Constante De Deslocamento;\ Dicionário;)\ \ .\ 110$
6	Chamada da função de aptidão para os sinais de teste: (LimiarMaisApto; WaveletMaisApta; FatorDeEscalaMaisApto;
	ConstanteDeDeslocamentoMaisApto; Dicionário;)

### Lista de siglas

**AEs** Algoritmos Evolutivos

AG Algoritmo Genético

AGs Algoritmos Genéticos

ANFIS Sistema Adaptativo Neuro-Fuzzy

**ANN** Artificial Neural Networks

**ART** Adaptive Resonance Theory

**DHT** Distorção Harmônica Total

**DOE** Department of Energy

**EA** Evolutionary Algorithm

**EEs** Estratégias Evolutivas

**EN** Evolução Natural

**EPRI** Electric Power Research Institute

**EPS** Electrical Power Systems

FE Fator de Escala

**FAM** Fuzzy Associative Memories

**FFML** Feedforward Multilayer

**FFT** Fast Fourier Transform

FPGA Field Programmable Gate Array

**FP** Fronteira de Pareto

**GRNN** General Regression Neural Network

**IEEE** Institute of Electrical and Electronics Engineers

LVQ Learning Vector Quantization

MP Mutação Polinomial

NSGA-II Non-dominated Sorting Genetic Algorithm II

NMSE Normalized Mean Square Error

PE Programação Evolutiva

PMC Perceptron Multicamadas

PNN Probabilistic Neural Network

**PQ** Power Quality

**PSO** Particle Swarm Optimization

**QEE** Qualidade da Energia Elétrica

RNAs Redes Neurais Artificiais

**RNA** Rede Neural Artificial

**RBF** Radial Basis Function

RMS Root Mean Square

**RBFNN** Radial Basis Function Neural Networks

SEPs Sistemas Elétricos de Potência

**SEP** Sistema Elétrico de Potência

**SG** Smart Grids

**STFT** Short Time Fourier Transform

**SVM** Support Vector Machine

**SBX** Simulated Binary Crossover

 ${f TW}$  Transformada Wavelet

TWC Transformada Wavelet Cosseno

TWCD Transformada Wavelet Cosseno Discreta

TWD Transformada Wavelet Discreta

TWDO Transformada Wavelet Discreta Ortogonal

TWP Transformada Wavelet Package

TWS Transformada Wavelet Spline

**TF** Transformada de Fourier

TS Transformada Stanlet

WEKA Waikato Environment for Knowledge Analysis

WT Wavelet Transform

VHDL Very High Speed Integrated Circuits Hardware Description Language

VTCDs Variações de Tensão de Curta Duração

VTLDs Variações de Tensão de Longa Duração

# Sumário

1	INTRODUÇÃO	27
1.1	Contexto Geral da Pesquisa	28
1.2	Objetivos e Justificativas	29
1.3	Contribuições da Tese	31
1.4	Organização da Tese	32
2	REFERENCIAL TÉCNICO-CIENTÍFICO	33
2.1	Qualidade da Energia Elétrica (QEE)	33
2.1.1	Variações de Tensão de Curta Duração (VTCDs)	35
2.1.2	Transitórios	36
2.1.3	Flutuações de Tensão	37
2.1.4	Distorções da Forma de Onda	38
2.1.5	Variações de Tensão de Longa Duração (VTLDs)	38
2.1.6	Desequilíbrios de Tensão	39
2.2	Ferramentas Aplicadas nesta Pesquisa e no Contexto da QEE	39
2.2.1	Transformada <i>Wavelet</i> (TW)	39
2.2.2	Redes Neurais Artificiais (RNAs)	43
2.2.3	Algoritmos Evolutivos (AEs)	47
2.2.4	Outras Ferramentas	50
2.2.5	Considerações Finais	52
3	APLICAÇÕES DE INTERESSE DA PESQUISA	53
3.1	A Segmentação dos Sinais em Análise	<b>5</b> 3
3.2	A Classificação dos Distúrbios Manifestados	58
3.3	A Compressão e a Descompressão dos Sinais	65
3.4	O Armazenamento dos Sinais	72
3.5	Considerações Finais	73
4	METODOLOGIA	75
4.1	Fluxograma Geral da Pesquisa	<b>7</b> 5
4.2	Dados de Entrada	77
4.2.1	Dados Gerados Sinteticamente	77
4.2.2	Dados do IEEE P1159.3	77

4.2.3	Oscilografias Reais Registradas	80
4.3	Procedimento para a Classificação Geral dos Sinais	80
4.3.1	Segmentação dos Sinais	81
4.3.1.1	Cálculo do Limiar Adaptativo	82
4.3.2	Determinação do melhor número de amostras por ciclo	88
4.3.3	Extração de Características por meio de Wavelets	90
4.3.4	Seleção de Atributos por meio do <i>software</i> WEKA	92
4.3.5	O Uso das RNAs para a Classificação dos Sinais	94
4.3.6	Otimização da Segmentação e Classificação dos Sinais	95
4.3.6.1	Cruzamento Uniforme	00
4.4	Procedimento de Compressão dos Sinais	01
4.4.1	Método de Quantização Linear	03
4.4.2	Huffman Coding	04
4.4.3	Arithmetic Coding	05
4.4.4	Otimização da Compressão dos Sinais	.07
4.4.4.1	Treinamento para Determinação dos Indivíduos mais Aptos	.07
4.4.4.2	Testes dos Indivíduos mais Aptos	11
4.4.4.3	Determinação do Melhor Indivíduo	13
4.5	Considerações Finais	14
5	RESULTADOS	15
5 5.1	RESULTADOS	
		15
5.1	Módulo de Segmentação dos Sinais	<b>15</b> 15
<b>5.1</b> 5.1.1	Módulo de Segmentação dos Sinais	<b>15</b> 15 20
<b>5.1</b> 5.1.1 5.1.2	Módulo de Segmentação dos Sinais	15 15 20 23
<b>5.1</b> 5.1.1 5.1.2 5.1.3	Módulo de Segmentação dos Sinais1Distúrbios Simples - Sinais Sintéticos1Distúrbios Múltiplos - Sinais Sintéticos1Oscilografias Reais1	15 15 20 23 29
<b>5.1</b> 5.1.1 5.1.2 5.1.3 <b>5.2</b>	Módulo de Segmentação dos Sinais1Distúrbios Simples - Sinais Sintéticos1Distúrbios Múltiplos - Sinais Sintéticos1Oscilografias Reais1Módulo de Classificação dos Sinais1	15 20 23 29
<b>5.1</b> 5.1.1 5.1.2 5.1.3 <b>5.2</b> 5.2.1	Módulo de Segmentação dos Sinais1Distúrbios Simples - Sinais Sintéticos1Distúrbios Múltiplos - Sinais Sintéticos1Oscilografias Reais1Módulo de Classificação dos Sinais1Sinais Sintéticos1	15 15 20 23 <b>29</b> 29
<b>5.1</b> 5.1.1 5.1.2 5.1.3 <b>5.2</b> 5.2.1 5.2.2	Módulo de Segmentação dos Sinais1Distúrbios Simples - Sinais Sintéticos1Distúrbios Múltiplos - Sinais Sintéticos1Oscilografias Reais1Módulo de Classificação dos Sinais1Sinais Sintéticos1Oscilografias Reais1	15 15 20 23 29 29 29
<b>5.1</b> 5.1.1 5.1.2 5.1.3 <b>5.2</b> 5.2.1 5.2.2 <b>5.3</b>	Módulo de Segmentação dos Sinais1Distúrbios Simples - Sinais Sintéticos1Distúrbios Múltiplos - Sinais Sintéticos1Oscilografias Reais1Módulo de Classificação dos Sinais1Sinais Sintéticos1Oscilografias Reais1Oscilografias Reais1Otimização da Segmentação e Classificação dos Sinais1	15 15 20 23 29 29 29 30
<b>5.1</b> 5.1.1 5.1.2 5.1.3 <b>5.2</b> 5.2.1 5.2.2 <b>5.3</b> 5.3.1	Módulo de Segmentação dos Sinais1Distúrbios Simples - Sinais Sintéticos1Distúrbios Múltiplos - Sinais Sintéticos1Oscilografias Reais1Módulo de Classificação dos Sinais1Sinais Sintéticos1Oscilografias Reais1Otimização da Segmentação e Classificação dos Sinais1Análise do Desempenho do Método Otimizado para a Segmentação dos Sinais1	15 15 20 23 29 29 29 30 30
<b>5.1</b> 5.1.1 5.1.2 5.1.3 <b>5.2</b> 5.2.1 5.2.2 <b>5.3</b> 5.3.1 5.3.2	Módulo de Segmentação dos Sinais1Distúrbios Simples - Sinais Sintéticos1Distúrbios Múltiplos - Sinais Sintéticos1Oscilografias Reais1Módulo de Classificação dos Sinais1Sinais Sintéticos1Oscilografias Reais1Otimização da Segmentação e Classificação dos Sinais1Análise do Desempenho do Método Otimizado para a Segmentação dos Sinais 1Análise do Desempenho do Método Otimizado para a Classificação dos Sinais 1	15 15 20 23 29 29 30 30 32 33
<b>5.1</b> 5.1.1 5.1.2 5.1.3 <b>5.2</b> 5.2.1 5.2.2 <b>5.3</b> 5.3.1 5.3.2 <b>5.4</b>	Módulo de Segmentação dos Sinais1Distúrbios Simples - Sinais Sintéticos1Distúrbios Múltiplos - Sinais Sintéticos1Oscilografias Reais1Módulo de Classificação dos Sinais1Sinais Sintéticos1Oscilografias Reais1Otimização da Segmentação e Classificação dos Sinais1Análise do Desempenho do Método Otimizado para a Segmentação dos Sinais1Análise do Desempenho do Método Otimizado para a Classificação dos Sinais1Módulo de Compressão dos Sinais1	15 15 20 23 29 29 30 30 32 33 34
5.1 5.1.1 5.1.2 5.1.3 5.2 5.2.1 5.2.2 5.3 5.3.1 5.3.2 5.4 5.4.1	Módulo de Segmentação dos Sinais1Distúrbios Simples - Sinais Sintéticos1Distúrbios Múltiplos - Sinais Sintéticos1Oscilografias Reais1Módulo de Classificação dos Sinais1Sinais Sintéticos1Oscilografias Reais1Otimização da Segmentação e Classificação dos Sinais1Análise do Desempenho do Método Otimizado para a Segmentação dos Sinais1Análise do Desempenho do Método Otimizado para a Classificação dos Sinais1Módulo de Compressão dos Sinais1Análise do Desempenho do Método para a Compressão dos Sinais1Análise do Desempenho do Método para a Compressão dos Sinais1	15 15 20 23 29 29 30 30 32 33 34 34
5.1 5.1.1 5.1.2 5.1.3 5.2 5.2.1 5.2.2 5.3.1 5.3.2 5.4 5.4.1 5.4.1.1 5.4.1.2	Módulo de Segmentação dos Sinais1Distúrbios Simples - Sinais Sintéticos1Distúrbios Múltiplos - Sinais Sintéticos1Oscilografias Reais1Módulo de Classificação dos Sinais1Sinais Sintéticos1Oscilografias Reais1Otimização da Segmentação e Classificação dos Sinais1Análise do Desempenho do Método Otimizado para a Segmentação dos Sinais1Análise do Desempenho do Método Otimizado para a Classificação dos Sinais1Módulo de Compressão dos Sinais1Análise do Desempenho do Método para a Compressão dos Sinais1Sinais Sintéticos1Oscilografias Reais1CONCLUSÕES GERAIS1	15 15 20 23 29 29 30 30 32 33 34 34 38
5.1 5.1.1 5.1.2 5.1.3 5.2 5.2.1 5.2.2 5.3 5.3.1 5.3.2 5.4.1 5.4.1.1 5.4.1.2	Módulo de Segmentação dos Sinais1Distúrbios Simples - Sinais Sintéticos1Distúrbios Múltiplos - Sinais Sintéticos1Oscilografias Reais1Módulo de Classificação dos Sinais1Sinais Sintéticos1Oscilografias Reais1Otimização da Segmentação e Classificação dos Sinais1Análise do Desempenho do Método Otimizado para a Segmentação dos Sinais1Análise do Desempenho do Método Otimizado para a Classificação dos Sinais1Módulo de Compressão dos Sinais1Análise do Desempenho do Método para a Compressão dos Sinais1Sinais Sintéticos1Oscilografias Reais1	15 15 20 23 29 29 30 30 32 33 34 34 38

### Introdução

Nas últimas décadas, o setor de energia elétrica passou por profundas mudanças devido a inúmeros fatores, dentre os quais pode-se citar: a alteração na forma com que a energia elétrica é utilizada e na natureza das cargas instaladas, a desregulamentação (em curso) do setor em nível mundial, a proliferação de auto-produtores, a importância das questões ambientais relacionadas às fontes de geração de energia elétrica convencionais ou renováveis e ao surgimento de tecnologias que visam a melhor atender ao Sistema Elétrico de Potência (SEP) como um todo.

Logo, deve ser também significativa a evolução no que diz respeito às tecnologias dos equipamentos de medição que têm sido empregados no monitoramento do SEP. No entanto, ainda são grandes as dificuldades no que se refere à determinação dos locais adequados para sua instalação, agravadas pelos longos períodos destinados às medições e à baixa capacidade de transmissão dos dados. Devido à grande quantidade de dados, também são limitados os recursos destinados a uma análise automática, bem como ao armazenamento de informações a partir destes registros.

No cenário apresentado, um dos fatores cruciais para a competitividade dos setores industriais e de serviços, atualmente nos Sistemas Elétricos de Potência (SEPs), é a Qualidade da Energia Elétrica (QEE) fornecida.

O conceito de QEE está relacionado a um conjunto de alterações que podem ocorrer no sistema elétrico de modo a refletir em problemas manifestados na tensão, corrente ou desvio de frequência que poderá resultar em falha ou má operação de equipamentos dos consumidores (DUGAN et al., 2012).

É importante notar que, em períodos passados, os problemas causados pela baixa qualidade no fornecimento da energia elétrica não eram tão expressivos, pois, os equipamentos existentes eram pouco sensíveis aos efeitos dos distúrbios ocorridos e não era frequente a instalação de dispositivos que causavam problemas de QEE. Entretanto, com o aprimoramento dos dispositivos conectados aos SEPs, as análises da QEE tornaram-se essenciais para as concessionárias e consumidores. Dentre os principais motivos para sua

maior relevância estão:

- Os equipamentos hoje utilizados são mais sensíveis às variações na QEE. Em muitos casos, estes equipamentos são microprocessados e, portanto, tornam-se sensíveis a muitos tipos de distúrbios;
- A maior racionalização e conservação da energia elétrica têm aumentado o uso de equipamentos que maximizam os níveis das distorções harmônicas, podendo levar o sistema a condições de ressonância e amplificação harmônica;
- A maior conscientização por parte dos consumidores quanto aos fenômenos relacionados à má QEE, tornando-os mais exigentes;
- A integração dos processos, significando que a falha de um componente tem consequências muito mais importantes para o sistema elétrico; e
- Os danos causados a componentes elétricos que venham a afetar sua vida útil.

Uma vez apontada a crescente importância de estudos na área de QEE, essa pesquisa trata de todas as etapas necessárias para um monitoramento automático dos distúrbios, bem como a disponibilização dos dados resultantes para que especialistas possam tomar decisões que venham a inibir os danos causados pelos distúrbios ou, até mesmo, para que possam agir de forma preventiva contra os mesmos.

Cabe adiantar que esta pesquisa empregou ferramentas inteligentes de otimização para a determinação da melhor Transformada Wavelet (TW) a ser empregada na tarefa de segmentação dos sinais de tensão, assim como para determinar a melhor topologia de Rede Neural Artificial (RNA) para a tarefa de classificação dos sinais frente aos distúrbios elétricos conhecidos. Também serão analisados os procedimentos para a compressão e descompressão de dados a serem empregados em equipamentos de medição com o intuito de garantir um melhor aproveitamento dos seus recursos de transmissão e armazenamento sem que haja perdas significativas de informações.

#### 1.1 Contexto Geral da Pesquisa

Um dos fatores dominantes para o futuro dos SEPs está no desenvolvimento de novas tecnologias de hardware e software (GHARAVI; GHAFURIAN, 2011). Dado que 90% de todas interrupções de tensão e distúrbios têm sua origem na rede de distribuição (FARHANGI, 2010), é fundamental o seu monitoramento e o controle de seus componentes, pois desse modo, as concessionárias terão informações em tempo real sobre o sistema. Essas informações, aliadas à modelagem de sistemas integrados e ferramentas de diagnóstico,

permitirão a detecção de precursores de falhas, com o intuito de guiar manutenções preventivas e sistemas de gerenciamento (MOSLEHI; KUMAR, 2010).

A motivação dessa pesquisa vem da necessidade de se aprimorarem as técnicas empregadas no monitoramento de SEPs. Medidores registram informações sobre o consumo de energia, incluindo os valores de tensão, fase e frequência, assim como informações sobre a rede de distribuição. Aliado à uma infraestrutura de comunicação, os medidores podem enviar essas informações para um servidor localizado em uma estação central. Entretanto, essa operação envolve uma quantidade enorme de transmissão de dados. A manutenção, administração e armazenamento desses dados podem ser tarefas árduas e onerosas. A baixa largura de banda das redes de comunicação dos medidores pode gerar tráfego intenso, limitando a quantidade de dados que pode ser transmitida. Além disso, o armazenamento dos registros dos medidores pode gerar custos adicionais para sua implantação (DEPURU; WANG; DEVABHAKTUNI, 2011).

A Figura 1 apresenta um esquema simplificado que ilustra como o sistema de distribuição pode ser monitorado. Os medidores instalados nos consumidores, que podem ser residenciais, comerciais e industriais, registram suas informações, dentre as quais a tensão. O sinal de tensão pode apresentar distúrbios de QEE que, uma vez detectados, podem fornecer informações para que ações preventivas e manutenções possam ser efetuadas. Essas informações têm que ser transmitidas e armazenadas na concessionária de energia elétrica, o que torna imprescindível o uso de métodos de minimização dos recursos de tráfego de dados e de memória.

#### 1.2 Objetivos e Justificativas

É evidente o interesse crescente por uma melhor QEE devido aos fatores mencionados anteriormente, com enfoque para a atenuação dos prejuízos econômicos causados pelos distúrbios de energia elétrica. O principal objetivo desta pesquisa é a elaboração e validação de procedimentos que permitam o tratamento automático dos sinais de tensão e corrente de forma que seus resultados propiciem tomadas de decisões que visem a correção e prevenção de problemas associados à QEE. Para isso, serão analisadas e empregadas ferramentas de segmentação de sinais, classificação de padrões, otimização de processos e compressão/descompressão de dados.

As etapas de desenvolvimento da pesquisa permitirão que as ferramentas sejam empregadas em tarefas específicas que, quando reunidas, terão como foco um completo monitoramento automático dos distúrbios no contexto da QEE. Neste sentido, a TW será empregada na segmentação dos sinais e as Redes Neurais Artificiais (RNAs) serão utilizadas como classificadores. Os algoritmos evolutivos determinarão as melhores Wavelets  $(TW_1; TW_2)$ , sua melhor decomposição e a melhor topologia das RNAs, que

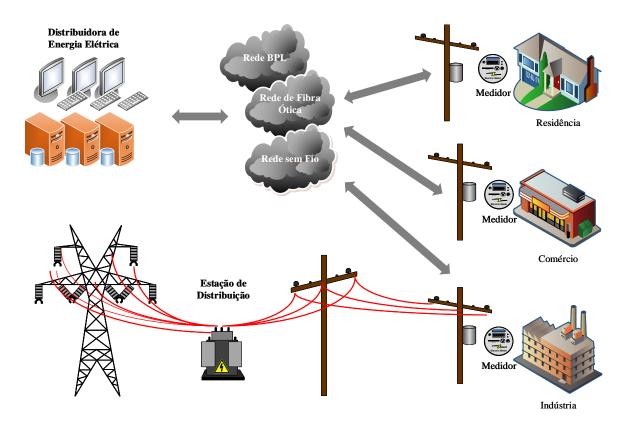


Figura 1 – Contexto da pesquisa de doutorado.

Fonte: Autoria própria.

juntas  $(TW_1; TW_2; RNA)$  permitirão a classificação dos distúrbios presentes nos sinais em análise. O desenvolvimento de um algoritmo de compressão/descompressão de dados permitirá aperfeiçoar a capacidade de armazenamento e tratamento dos dados provenientes dos medidores de energia elétrica instalados, bem como o uso da *internet* permitirá a disponibilização dos resultados obtidos e a formulação de um histórico dos registros que poderá ser disponibilizado para que ações corretivas e preventivas sejam tomadas.

Para que o objetivo principal da pesquisa fosse cumprido, objetivos menores, mas não menos importantes, também foram cumpridos. São estes:

- Desenvolvimento de um algoritmo computacional para a segmentação dos sinais por meio da TW;
- Desenvolvimento de um algoritmo computacional para a classificação dos sinais por meio de RNAs;
- Desenvolvimento de um algoritmo computacional evolutivo. Esse procedimento irá determinar as Wavelets e a topologia de RNA que juntas  $(TW_1; TW_2; RNA)$  apresentarão o melhor desempenho quanto à detecção e à classificação dos distúrbios

em QEE;

- Análise do melhor indivíduo determinado pelo algoritmo evolutivo e a análise dos resultados obtidos por ele; e
- Desenvolvimento de um algoritmo computacional para a compressão dos dados classificados.

É importante mencionar que os algoritmos computacionais desenvolvidos fizeram uso das Wavelet Toolbox, Neural Network Toolbox e Communications System Toolbox, presentes no Mathworks Matlab ©.

### 1.3 Contribuições da Tese

Dentre as contribuições que serão apresentadas no decorrer da tese, pode-se destacar:

- Criação de uma base de dados com 14 distúrbios únicos ou combinados (simultâneos) associados à QEE, a saber, afundamentos de tensão, elevações de tensão, interrupções de tensão, transitórios impulsivos e oscilatórios, distorções harmônicas, flutuações de tensão e notching, afundamento de tensão com flicker, elevação de tensão com flicker, afundamento de tensão com distorção harmônica, elevação de tensão com distorção harmônica, transitório com elevação de tensão e transitório com afundamento de tensão;
- Uso de ferramentas já consagradas de forma inovadora visando um melhor monitoramento e registro das condições de operação enfrentadas pelos SEPs frente aos distúrbios relacionados à QEE;
- Análise e o desenvolvimento de um procedimento que permita a segmentação de sinais de tensão que caracterizem distúrbios associados à QEE;
- Desenvolvimento de um método de otimização por Algoritmos Genéticos (AGs) que determine a estrutura  $(TW_1; TW_2; RNA)$  mais apta para a classificação de distúrbios (únicos ou simultâneos) de QEE, como a formada por Wavelets Coiflets 2, Wavelets Daubechies 6 e uma RNA com 10 neurônios em uma única camada intermediária; e
- Implementação de um algoritmo genético multi-objetivo para a determinação dos parâmetros (Limiar; *Wavelet*; Fator de Escala; Constante de Deslocamento; Dicionário; etc.) necessários para a compressão dos sinais de tensão.

### 1.4 Organização da Tese

A tese está organizada em seis capítulos, que apresentam todas as informações que compõem a pesquisa realizada, desde o estado da arte até os materiais, métodos e os resultados obtidos na solução de cada uma de suas etapas.

Assim, o Capítulo 1 introduz o tema da tese, apresentando as motivações e justificativas para o desenvolvimento da pesquisa.

O Capítulo 2 apresenta aspectos referentes aos distúrbios relacionados à QEE que foram analisados nessa pesquisa. Esse capítulo também apresenta aspectos a respeito das ferramentas empregadas no desenvolvimento da pesquisa que se encontram presentes na literatura.

Uma revisão bibliográfica com os aspectos fundamentais dos principais trabalhos relacionados ao tema dessa pesquisa são apresentados no Capítulo 3.

Todas as informações sobre os materiais e os métodos empregados no desenvolvimento da pesquisa são apresentadas no Capítulo 4.

O Capítulo 5 apresenta os resultados obtidos em todas as etapas da pesquisa desenvolvida.

As conclusões gerais obtidas, assim como a discussão e as principais contribuições da pesquisa de doutorado, serão apresentadas no Capítulo 6.

#### Referencial Técnico-Científico

Neste capítulo são apresentadas informações gerais sobre os distúrbios no contexto da QEE. Também são apresentadas informações gerais sobre as ferramentas inteligentes que podem ser empregadas na identificação e classificação de sinais contendo distúrbios.

### 2.1 Qualidade da Energia Elétrica (QEE)

O termo "Qualidade da Energia Elétrica" surgiu no início da década de 1970 quando sistemas sofisticados de controle tornaram-se partes integrantes das cargas dos usuários finais no setor de energia. Desde esta época, sabe-se que muitos equipamentos param de funcionar de forma intermitente sem razão aparente, enquanto outros equipamentos, como motores e aquecedores da mesma classe de operação (nível de tensão) na fábrica (indústria), não são afetados. Sabe-se também que a preocupação é verdadeira não somente pelos equipamentos dos usuários finais, mas também pelos equipamentos das concessionárias de energia como um todo (SANTOSO, 2012).

Como anteriormente já afirmado, a razão fundamental pelo interesse em QEE é o valor econômico agregado às operações sobre o SEP. Neste contexto, existem de forma clara e direta impactos econômicos tanto para as concessionárias como para os consumidores e fornecedores de equipamentos elétricos. Por exemplo, nos Estados Unidos, a interrupção no fornecimento de energia a partir de uma linha de montagem de uma fábrica automotiva resultou em um prejuízo de 250 mil dólares, e interrupções no processamento em lote de semicondutores pode chegar a um milhão de dólares por incidente (HUNTER, 2001). Conforme ilustrado por Dugan et al. (2012), perdas financeiras de aproximadamente 10 mil dólares são comuns devido à uma simples e momentânea interrupção na operação de uma linha de produção. De acordo com estudos conduzidos pelo *Electric Power Research Institute* (EPRI) e pelo *Department of Energy* (DOE) no início dos anos 2000, a má QEE custava à economia americana em torno de 120 bilhões de dólares anuais (SANTOSO, 2012).

Além dos impactos financeiros óbvios para as concessionárias e consumidores indus-

triais, existem inúmeros custos indiretos e intangíveis associados com problemas de energia elétrica. Consumidores residenciais não costumam sofrer perdas financeiras diretas como resultado da maioria dos problemas de QEE, mas estes representam uma grande parcela dentre os consumidores quando percebem que a concessionária está fornecendo serviço de baixa qualidade. Estes consumidores finais se tornaram mais sensíveis à interrupções e à baixa QEE fornecida em função da popularização dos computadores e da *internet* (DUGAN et al., 2012).

Nos primeiros anos de aplicação do conceito de QEE, concessionárias, fabricantes de equipamentos e usuários finais tinham conceitos diferentes sobre esse tema. A maioria das cargas não eram controladas eletronicamente e, desse modo, não eram afetadas pela baixa qualidade da energia elétrica fornecida. Naquele cenário, por exemplo, os refrigeradores continuavam a refrigerar e os aquecedores continuavam aquecendo. Entretanto, a baixa QEE poderia interromper a operação de sistemas eletronicamente controlados (SANTOSO, 2012).

Neste contexto, existem algumas definições envolvendo a QEE que podem ser destacadas. Dentre estas, tem-se como definição para a QEE:

O conceito de fornecer e sustentar energia aos equipamentos eletrônicos de maneira que seja adequada para a operação do equipamento e compatível com o sistema de cabeamento e outros equipamentos conectados (IEEE Std 1100-2005, 2006);

A habilidade de um equipamento ou sistema de operar satisfatoriamente em seu ambiente eletromagnético sem introduzir distúrbios eletromagnéticos intoleráveis a outro equipamento/sistema qualquer naquele ambiente (IEC 61000-1-1, 2013); e

Qualquer problema manifestado na tensão, corrente ou desvio de frequência, que resulte em falha ou má operação dos equipamentos dos consumidores (DUGAN et al., 2012; SANTOSO, 2012).

Uma vez citadas algumas das definições que podem ser encontradas, a QEE envolve certamente uma correta e desejável caracterização dos sinais de corrente e tensão de um SEP. Talvez, uma definição aceitável para a QEE seja a de fornecer tensão e corrente de forma que o usuário final possa utilizar a energia elétrica de um SEP com sucesso, sem interferência e interrupções. Uma definição mais específica de QEE converge para a atenuação das distorções nos sinais de tensão e corrente (HEYDT, 1998). Dentre os distúrbios de tensão e corrente que podem resultar em problemas de QEE, incluem-se as Variações de Tensão de Longa Duração (VTLDs), as Variações de Tensão de Curta Duração

(VTCDs), distorções da forma de onda (por exemplo, harmônicas e inter-harmônicas) e os distúrbios eletromagnéticos da corrente (BOLLEN et al., 2009). Mais detalhes sobre cada um dos distúrbio apontados são apresentados nos subitens desse capítulo.

Na prática, sabe-se que o problema de baixa QEE deve ser preocupação das concessionárias, dos fornecedores de equipamentos e dos consumidores finais.

As concessionárias devem reduzir o número e a duração dos distúrbios elétricos no sistema e informar de forma clara aos consumidores as causas, consequências e ações que podem ser tomadas para minimizá-los. Aos fornecedores de equipamentos, cabe projetar, desenvolver e fornecer equipamentos e soluções aplicáveis que sejam, ao máximo possível, tolerantes às intrínsecas variações no fornecimento da energia elétrica. Já os consumidores devem investigar as vulnerabilidades de suas instalações, operar os equipamentos em condições adequadas e estar cientes das técnicas de atenuação dos problemas associados à falta da QEE (HUNTER, 2001).

Sendo assim, é evidente a necessidade de pesquisas na área de QEE que devem ser constantemente motivadas pela necessidade de se fornecer sinais de tensões e correntes livres de distúrbios.

No que segue, algumas definições conceituais básicas, mas indispensáveis para a compreensão desta pesquisa como um todo, serão apresentadas.

#### 2.1.1 Variações de Tensão de Curta Duração (VTCDs)

As VTCDs são caracterizadas por sua duração e magnitude. Essas variações têm tipicamente uma duração entre meio ciclo e um minuto, com magnitudes de tensão de zero a 1,2 p.u.. Baseado na sua duração e magnitude, esses distúrbios podem ser agrupados segundo sua duração, em instantâneos, momentâneos e temporários, e, segundo sua magnitude, em interrupção, afundamento e elevação. As VTCDs podem ser causadas por condições de falta (curtos-circuitos sobre os SEPs), pela energização de grandes cargas que requerem altas correntes de partida ou ainda pelas perdas intermitentes de conexões na rede elétrica (DUGAN et al., 2012; SANTOSO, 2012). Dentre as VTCDs pode-se mencionar:

- Interrupções de tensão: ocorrem quando o fornecimento de tensão diminui para menos de 0,1 p.u. por um período de no máximo um minuto. A ocorrência deste distúrbio pode ser resultado de curtos-circuitos nos SEP, falhas de equipamentos, etc. Algumas interrupções podem ser precedidas por afundamentos (DUGAN et al., 2012; SANTOSO, 2012).
- Afundamentos de tensão: é uma diminuição entre 0,1 e 0,9 p.u. na tensão com

duração de meio ciclo a um minuto. Esse tipo de distúrbio é normalmente associado com faltas no sistema e pode também ser causado pela energização de grandes cargas e pela partida de grandes motores. Sabe-se na prática, que o afundamento é o distúrbio de QEE mais comum (DUGAN et al., 2012; SANTOSO, 2012).

• Elevações de tensão: esse tipo de distúrbio é definido como um aumento entre 1,1 e 1,8 p.u. na tensão com duração de meio ciclo a um minuto. O distúrbio está associado a condições de falta, mas não são tão comuns quanto os afundamentos de tensão. Pode ser causado pelo desligamento de grandes blocos de cargas e grandes bancos de capacitores (DUGAN et al., 2012; SANTOSO, 2012).

#### 2.1.2 Transitórios

Os transitórios podem ser denotados por duas categorias, impulsivos ou oscilatórios, com frequências que vão de poucas centenas de Hertz até centenas de mega-Hertz. O termo transitório tem sido usado na análise das variações em SEPs para denotar um evento que é indesejável e momentâneo por natureza. Os mesmos são decorrentes de uma mudança repentina e rápida na operação do sistema elétrico. Essa mudança repentina pode ser de origem natural, como por uma descarga atmosférica, ou pode ser planejada, como pela energização de equipamentos, ou ainda, não planejada, como as decorrentes de condições de curtos-circuitos. Independentemente da causa da mudança repentina, os transitórios são geralmente indesejáveis e de curta duração (DUGAN et al., 2012; SANTOSO, 2012).

Uma definição usual de transitório, mas ampla em seu escopo, é:

A parte da mudança em uma variável que desaparece durante a transição de uma condição de operação estacionária para outra (IEEE Std 100-1992, 1993; DUGAN et al., 2012; SANTOSO, 2012).

Infelizmente, esta definição pode ser usada para descrever muitos dos distúrbios passíveis de ocorrência nos SEPs.

Além disso, é importante comentar que a palavra surge é considerada um sinônimo para transitório (IEEE Std 100-1992, 1993). Surges são pulsos de alta energia que surgem das mudanças ocasionadas por distúrbios em SEPs, tanto diretamente, quanto como resultado de circuitos ressonantes associados com dispositivos de comutação (ARRILLAGA; WATSON; CHEN, 2000). Apesar deste conhecimento, muitos usuários empregam esse termo indiscriminadamente para descrever qualquer situação não usual que possa ser observada no fornecimento da energia elétrica. Desse modo, Dugan et al. (2012) e Santoso (2012)

caracterizam e classificam os transitórios em duas categorias, impulsivos e oscilatórios. Esses termos refletem o comportamento das ondas (sinais) de corrente e tensão, como descrito a seguir:

- Transitórios Impulsivos são repentinas mudanças na frequência da tensão, corrente ou ambos, unidirecionais em sua polaridade que pode ser tanto positiva quanto negativa. Estes são normalmente caracterizados por seu acentuado tempo de elevação e queda. A causa mais comum dos transitórios impulsivos são os relâmpagos decorrentes das descargas atmosféricas (DUGAN et al., 2012; SANTOSO, 2012);
- Transitórios Oscilatórios são também repentinas mudanças na frequência da tensão, corrente ou ambos. Entretanto, estas se alteram rapidamente entre a polaridade positiva e negativa. Dentre as causas desse fenômeno estão o chaveamento de bancos de capacitores, a energização de transformadores, a energização de linhas de transmissão, e a ferrorressonância (DUGAN et al., 2012; SANTOSO, 2012).

#### 2.1.3 Flutuações de Tensão

As flutuações de tensão são variações sistemáticas ou séries de mudanças aleatórias no sinal de tensão. Sua magnitude normalmente não excede os limites de 0,9 a 1,1 p.u.. A norma IEC 61000-2-1 (1990) define vários tipos de flutuação de tensão. Contudo, a forma mais discutida na literatura é caracterizada por séries aleatórias ou contínuas de flutuações na tensão (DUGAN et al., 2012). Essas variações de tensão causam resultados indesejados, como cintilações luminosas perceptíveis nas lâmpadas, que são chamadas de *flicker*. As normas costumeiramente mantêm ligados os termos flutuação de tensão e *flicker* (DUGAN et al., 2012; SANTOSO, 2012).

A norma IEC 61000-4-15 (2010) define a metodologia e especificações da instrumentação para se mensurar o flicker. O grupo de trabalho sobre flicker do Institute of Electrical and Electronics Engineers (IEEE) adota essa norma para uso na América do Norte. Essa norma cria uma métrica fundamental chamada de sensação do flicker de curta duração (P<sub>st</sub>). Esse valor é normalizado em 1,0 para representar o nível de flutuação de tensão suficiente para que 50% dos membros de um grupo em observação possa ser sensibilizado pelo flicker. Outra medida chamada de sensação de flicker de longa duração (P<sub>lt</sub>) é usada com frequência com o propósito de se verificar a conformidade entre os níveis compatíveis estabelecidos por grupos normatizadores e usado pelas concessionárias (DUGAN et al., 2012; SANTOSO, 2012).

# 2.1.4 Distorções da Forma de Onda

A distorção da forma de onda pode ser definida como um desvio no regime permanente de uma forma senoidal ideal caracterizada, principalmente, pelo conteúdo espectral do desvio (DUGAN et al., 2012; SANTOSO, 2012).

Dentre os distúrbios que caracterizam uma distorção da forma de onda, têm-se:

- Harmônicos são tensões ou correntes senoidais com componentes de frequência múltiplos inteiros da frequência fundamental (frequência na qual o sistema de fornecimento foi projetado para operar). São originados de características não lineares de dispositivos e cargas conectadas no SEP. Os níveis das distorções harmônicas são descritos pelo espectro harmônico completo com magnitudes e ângulos das fases de cada componente harmônico individual. Também é comum o uso do termo Distorção Harmônica Total (DHT), como uma medida do valor efetivo da distorção harmônica (DUGAN et al., 2012);
- Inter-harmônicos são tensões ou correntes senoidais com componentes de frequência não múltiplas inteiras da componente de frequência fundamental. As principais fontes geradoras desses distúrbios são os conversores de frequência estáticos, conversores de ciclos, fornos de indução e dispositivos à arco. Sinais de onda portadora também podem ser considerados inter-harmônicos. Estes são geralmente o resultado de conversões de frequência e são, frequentemente, inconstantes, variando de acordo com a carga (DUGAN et al., 2012; SANTOSO, 2012);
- Notching é um distúrbio de tensão periódico provocado pela operação normal de dispositivos eletrônicos quando a corrente é comutada de uma fase para outra. Uma vez que o notching ocorre de forma continuada, este pode ser caracterizado por meio do espectro harmônico da tensão afetada. Entretanto, este é tratado como um caso especial. As componentes de frequência associadas com o notching podem ser bem altas e podem não ser facilmente caracterizadas por medidores normalmente empregados na análise usual de harmônicos (DUGAN et al., 2012; SANTOSO, 2012).

#### 2.1.5 Variações de Tensão de Longa Duração (VTLDs)

Estas variações envolvem desvios na tensão (na frequência fundamental) com duração superior a um minuto. Tais desvios também são caracterizados por sua magnitude, sendo divididos em interrupções sustentadas, sobretensões (valores típicos entre 1,1 e 1,2 p.u.) e subtensões (tensão remanescente menor do que 0,9 p.u.). Sobretensões e subtensões são causados por variações na carga e operações de chaveamento no sistema. Interrupções

sustentadas são causadas por situações de faltas manifestadas no sistema (SANTOSO, 2012).

#### 2.1.6 Desequilíbrios de Tensão

Esta condição ocorre em um sistema polifásico quando o valor *Root Mean Square* (RMS) da componente fundamental das tensões de fase (módulo e ângulo de fase) diferem entre si. As normas IEEE Std 1159-1995 (1995) e IEC 61000-3-4 (1998) quantificam o grau de desbalanceamento (desequilíbrio) em termos da razão entre as componentes de sequências negativa e nula (zero) com a componente de sequência positiva da tensão. Geralmente, o desbalanceamento esperado e aceitável é menor do que 2% (DUGAN et al., 2012; SANTOSO, 2012). As origens destes desequilíbrios estão geralmente nos sistemas de distribuição, os quais possuem cargas monofásicas distribuídas inadequadamente, fazendo surgir no circuito tensões de sequência negativa.

# 2.2 Ferramentas Aplicadas nesta Pesquisa e no Contexto da QEE

# 2.2.1 Transformada Wavelet (TW)

O conceito de Wavelets começou a ser empregado na literatura a partir de 1980. O conceito provém de uma síntese de várias ideias originadas em diferentes disciplinas, como a matemática, física e engenharia. Jean Morlet, um engenheiro geofísico francês, introduziu a ideia da TW como a de uma nova ferramenta matemática para análise de sinais sísmicos. Já Alex Grossman, um físico francês, reconheceu rapidamente a importância da TW Morlet e desenvolveu sua fórmula inversa. Isso significa que um sinal submetido à TW pode ser perfeitamente restaurado a partir de seus coeficientes de transformação. Desde que a TW é inversível, a informação contida em um sinal não é perdida por ela. Morlet e Grossman também demonstraram que uma pequena modificação nos coeficientes Wavelets produziam uma correspondente modificação no sinal reconstruído. Esse resultado é importante, pois forma a base para os métodos de filtragem de ruídos por meio das Wavelets. A ideia de multi-resolução foi proposta em 1986 por Stephane Mallat e Yves Meyer, ambos matemáticos franceses, e é considerada um grande passo na teoria das Wavelets. Mallat também é responsável pela concepção dos algoritmos de decomposição e reconstrução Wavelets usando análise multi-resolução (DEBNATH, 1998; GARGOUR et al., 2009).

A partir desse ponto, matemáticos e outros pesquisadores estavam aptos a construir suas próprias famílias de *Wavelets*. Nos dez anos seguintes, a construção de novas *Wavelets* foi intensa. Contudo, recentemente, essa tendência se tornou menos regular e se resume

a objetivos específicos, frequentemente associados ao contexto de aplicações limitadas (MISITI et al., 2007).

Existe um número grande de Wavelets que podem ser usadas tanto para análise contínua quanto para análise discreta dos sinais. As famílias de Wavelets mais conhecidas são as Wavelets Haar, Daubechies, Symlets, Coiflets, Biorthogonais, Biorthogonais reversas, Meyer, Gaussianas, Chapéu Mexicano, Morlet, Gaussianas complexas, Shannon, dentre outras. A escolha da Wavelet é determinada pelas características do sinal, bem como pela natureza da aplicação. Se forem conhecidas as propriedades de análise e de síntese das Wavelets, pode-se escolher a mais otimizada para uma aplicação específica (MISITI et al., 2007).

A filtragem e compressão, po exemplo, são dois dos vários problemas que podem ser bem resolvidos por *Wavelets* e estão, no entanto, ainda sujeitos a desenvolvimento. O objetivo geral da filtragem é separar o sinal desejado do ruído, e o da compressão é compactar as informações para preservá-las ou transmiti-las (MISITI et al., 2007).

Dentre as possíveis e mais diversas aplicações das Wavelets, têm-se como exemplos:

- Caracterização das rajadas de ventos oceânicos durante a sua formação, seu crescimento e seu período de desenvolvimento completo;
- Identificação automática de abalos baseados em componentes de um sinal sísmico, utilizando *Wavelets* como uma ferramenta de reconhecimento de padrões;
- Estudo batimétrico do solo marinho a fim de se mapear áreas que possam apresentar fortes declives;
- Compressão adequada por Wavelets na análises de sinais de eletrocardiogramas longos.
   Este problema surge na análise de sinais biomédicos para fins de armazenamento e transmissão dos dados. Nesta situação, a taxa de compressão dos dados deve ser aumentada, mantendo a distorção a um nível aceitável, a fim de permitir um exame clínico;
- Estudo da influência do tipo de gordura ingerida por um indivíduo e na gordura armazenada pelo corpo. A análise por *Wavelets* é baseada no espectro de ressonância magnética que fornece as informações sobre a composição química da gordura;
- Determinação da família Wavelet correta a fim de garantir uma boa análise dos dados de ressonância magnética funcional;
- Aplicação em ciências biomédicas, onde as *Wavelets* entram no processo com o objetivo de descobrir uma disfunção, comparando o normal com o anormal, e

melhorar a informação recolhida para garantir um trabalho mais claro;

- Codificação de imagens de vídeo de animação por meio de Wavelets; e
- Utilização de Wavelets para construir um previsor de sinais gravados no tempo.

Essas são apenas algumas das aplicações em que foram empregadas Wavelets. Existem inúmeras outras aplicações que podem ser encontradas nos repositórios de trabalhos publicados em revistas, livros, congressos, etc. A Figura 2 ilustra a quantidade de trabalhos encontrada no repositório de artigos científicos do site Scopus © da Elsevier relacionados a aplicações de Wavelets em distintas áreas do conhecimento humano.

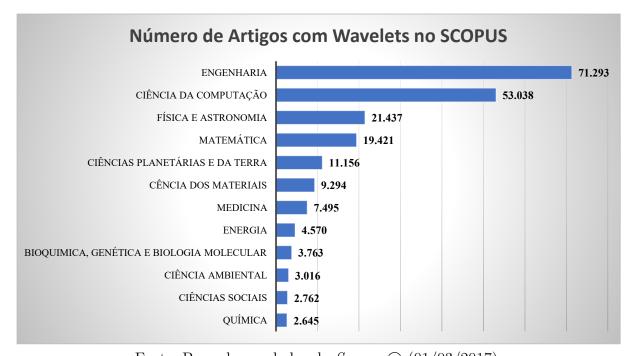


Figura 2 – Montante de trabalhos com Wavelets.

Fonte: Baseado em dados do Scopus © (01/03/2017).

Pode-se encontrar também diversas aplicações de Wavelets em SEPs. Na literatura consultada, uma das primeiras aplicações nessa área data de 1994 e foram publicadas nos trabalhos de Ribeiro (1994) e Robertson, Camps e Mayer (1994). A partir desse ano o número de publicações aumentou e as aplicações de Wavelets mais frequentes em SEPs são em QEE, descargas parciais, previsão, medição, proteção e análise dos transitórios em SEPs (SHARIATINASAB; AKBARI; RAHMANI, 2012).

O gráfico da Figura 3 ilustra o quão representativa é a aplicação de *Wavelets* nos mais variados problemas relacionados aos SEPs.

Pode-se verificar que o maior percentual de trabalhos trata de problemas relacionados à QEE. Neste sentido, vários estudos foram realizados para detecção e localização

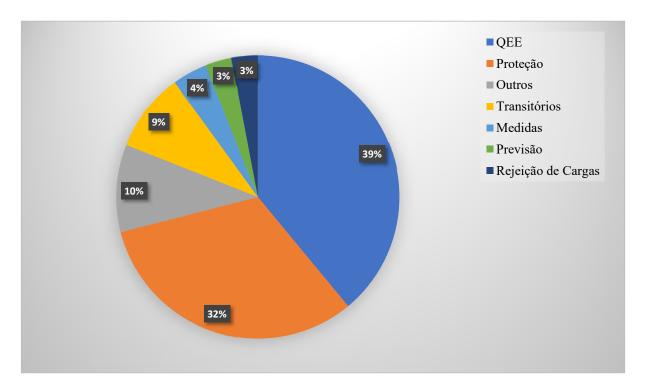


Figura 3 – A aplicação de Wavelets nos mais variados problemas relacionados aos SEPs.

Fonte: Shariatinasab, Akbari e Rahmani (2012, p. 225).

de distúrbios, usando-se *Wavelets* como uma ferramenta útil para analisar afundamentos, elevações e interrupções, dentre outros sinais não estacionários. Examinando-se os coeficientes da TW em um nível alto de decomposição, permite-se determinar a ocorrência de um distúrbio, assim como a sua localização no tempo. Devido a isso, técnicas empregando-se a TW têm sido amplamente usadas para analisar distúrbios de QEE (SHARIATINASAB; AKBARI; RAHMANI, 2012).

Ainda segundo os mesmos autores, todas as características do sinal original estão presentes quando todos os níveis de decomposição por Wavelets são considerados. Entretanto, se todos os níveis de decomposição por Wavelets forem considerados, será difícil classificar os diversos distúrbios associados à QEE em um tempo aceitável, uma vez que a decomposição completa exige um grande esforço computacional.

Além disso, vale relembrar que com o uso crescente de equipamentos para o monitoramento do SEP, e, neste caso em específico, direcionados para a análise da QEE, o volume de dados acumulado durante a última década tornou-se imenso. Esse grande volume de dados impõe problemas práticos para o armazenamento e para a comunicação dos monitores locais com computadores centrais de processamento de dados. Portanto, a compressão de dados também se tornou assunto importante no contexto da QEE, sendo a TW também apontada para este tipo de aplicação (SANTOSO; POWERS; GRADY, 1997), pois permite a eliminação de redundâncias nas características dos sinais analisados,

reduzindo assim o seu volume para o posterior armazenamento.

Desse modo, habilitar os equipamentos de monitoramento de SEPs para o reconhecimento de distúrbios e a compressão de seus dados, tornou-se assunto importante e essencial também para a área de QEE. E, neste cenário, tem-se que as *Wavelets* podem ser uma ferramenta eficiente para a localização, transferência e armazenamento de dados em SEPs (SHARIATINASAB; AKBARI; RAHMANI, 2012).

#### 2.2.2 Redes Neurais Artificiais (RNAs)

RNAs são modelos computacionais inspirados na forma de funcionamento do cérebro dos seres vivos. Seu poder computacional é baseado na sua estrutura paralelamente distribuída e na sua habilidade de generalizar. Possuem capacidade de aquisição e manutenção do conhecimento baseadas nas informações. Podem ser definidas como um conjunto de unidades de processamento conhecidos como neurônios artificiais (BASHEER; HAJMEER, 2000; HAYKIN, 2001; SILVA; SPATTI; FLAUZINO, 2010). Essas unidades são interligadas por elos de conexões, cada um caracterizado por pesos próprios. Dentre as diversas características das RNAs pode-se citar algumas, como (BASHEER; HAJMEER, 2000; HAYKIN, 2001; SILVA; SPATTI; FLAUZINO, 2010):

- Capacidade de aprendizado por meio de métodos de treinamento, que podem ser supervisionados ou não supervisionados, a rede consegue extrair o relacionamento entre as variáveis que formam a aplicação;
- Habilidade de generalização uma vez terminado o processo de treinamento, ou ajuste das conexões sinápticas, as redes neurais podem estimar uma solução baseada em exemplos desconhecidos ou que não pertenciam ao conjunto de treinamento;
- Organização de dados com base em características inerentes a um conjunto de informações, a rede é capaz de realizar seu agrupamento em conjuntos que apresentem particularidades em comum;
- Tolerância a falhas o desempenho das redes se degrada suavemente sob condições de operação adversas. Se um neurônio ou suas conexões são danificadas, a natureza distribuída das informações armazenadas torna o sistema tolerante a falhas;
- Adaptabilidade as redes têm a capacidade de modificar seus pesos sinápticos em tempo real conforme modificações em um meio ambiente não-estacionário; e
- Armazenamento distribuído o conhecimento extraído de um conjunto de dados de treinamento é preservado por uma arquitetura neural na forma distribuída das

diversas sinapses de seus neurônios artificiais.

Existe um vasto número de RNAs e novas modificações têm sido constantemente desenvolvidas. Algumas das aplicações podem ser resolvidas usando-se diferentes redes neurais, entretanto, outras podem ser resolvidas por uma rede neural específica. Algumas redes neurais são mais eficientes na solução de problemas perceptuais, enquanto outras são mais apropriadas para a modelagem de dados e aproximação de funções (BASHEER; HAJMEER, 2000; HAYKIN, 2001; SILVA; SPATTI; FLAUZINO, 2010). Em seguida são apresentadas as RNAs usadas mais frequentemente:

- Redes recorrentes de Hopfield é uma rede recorrente com duas camadas simétricas totalmente conectadas que funcionam como uma memória associativa não-linear. Este tipo de rede é especialmente eficiente na solução de problemas de otimização;
- Redes Adaptive Resonance Theory (ART) consiste em duas camadas totalmente interconectadas. Os pesos feedforward são usados para selecionar o neurônio de saída vencedor (grupo). Redes ART podem ser usadas no reconhecimento e classificação de padrões;
- Redes auto-organizáveis de Kohonen essas redes, também conhecidas por mapas auto-organizáveis, são redes de duas camadas que transformam padrões de entrada n-dimensionais em padrões de ordem inferior. Elas são treinadas de forma não-supervisionada para formar grupos de dados. Além de serem usadas no reconhecimento e classificação de padrões, também são empregadas em compressão;
- Redes perceptron multi-camadas são os tipos de redes mais amplamente empregadas. Mediante treinamento supervisionado, essas redes mapeiam os dados de um espaço para outro por meio de exemplos. Essas redes são versáteis e podem ser usadas para a classificação, previsão, controle, compressão de dados e imagens, e reconhecimento de padrões;
- Redes recorrentes são redes cujas saídas de alguns neurônios são realimentados para esses mesmos neurônios ou em neurônios de camadas anteriores. O seu fluxo de informação flui nas duas direções, para frente e para trás;
- Redes counter-propagation são treinadas por meio de uma aprendizagem híbrida para criar uma tabela de consulta auto-organizável. Estas são usualmente empregadas na aproximação de funções e classificação; e
- Redes Radial Basis Function (RBF) são casos especiais de redes de três multicamadas feedforward. Podem ser treinadas por uma variedade de algoritmos de

aprendizagem, incluindo aprendizado híbrido. Podem ser empregadas em quase todos os tipos de problemas tratados pelas redes *perceptron* multi-camadas, inclusive aqueles que envolvem aproximação de funções e classificação de padrões.

São inúmeras as áreas de aplicações das RNAs. A decisão de qual rede funciona melhor para um dado problema depende estritamente da logística do problema. Dentre os fatores que determinam a escolha da melhor rede neural estão os tipos de entrada (booleanos, contínuos ou ambos) e o tempo de execução uma vez treinadas (BASHEER; HAJMEER, 2000; HAYKIN, 2001; SILVA; SPATTI; FLAUZINO, 2010). Os principais tipos de problemas que podem ser solucionados pela aplicação de RNAs podem ser organizadas da seguinte forma:

- Aproximador de funções a tarefa das redes neurais é a de mapear o relacionamento entre as variáveis de um sistema a partir de um conjunto conhecido de seus valores.
   O trabalho de Zainuddin e Ong (2008) empregou RNAs na estimação de funções contínuas periódicas, exponenciais e definidas por partes;
- Controle de processos cabe as redes neurais determinar ações de controle que permitam atingir metas de qualidade, eficiência e segurança do processo. O trabalho de Willis et al. (1992) discute algumas das aplicações de redes neurais na solução de processos em engenharia;
- Classificação de padrões o objetivo desse tipo de aplicação é de se relacionar uma determinada amostra ou valor de entrada à uma classe previamente definida. O tutorial de Yegnanarayana (1994) discute modelos computacionais baseados em RNAs com o propósito de tratar situações de reconhecimento de padrões na vida real;
- Agrupamento de dados a tarefa das redes neurais relativa a essa aplicação consiste da identificação e detecção de similaridades dentre os diversos valores de entrada com o objetivo de permitir seu agrupamento. O trabalho de Du (2010) apresenta uma visão geral de métodos de agrupamento baseado em RNAs;
- Previsão as redes neurais podem ser empregadas na estimação de valores futuros de um determinado processo considerando-se medidas prévias já mensuradas. Hill et al. (1994) fazem uma revisão da literatura comparando métodos estatísticos e RNAs na tarefa de previsão de séries temporais;
- Otimização o objetivo consiste em minimizar ou maximizar uma função objetivo, respeitando-se as restrições que possam ser impostas para um mapeamento adequado do problema (SILVA; SPATTI; FLAUZINO, 2010). Problemas de otimização podem

ser encontrados em diversos campos, incluindo engenharia mecânica, elétrica e de produção, pesquisa operacional, administração, ciência da computação, análise de sistemas, economia, medicina, manufatura, processamento de imagens, entre outros. (MALEK, 2008); e

• Memórias associativas - a sua aplicação consiste na recuperação de padrões corretos, mesmo que seus elementos constituintes foram apresentados de forma incerta ou imprecisa. Michel e Farrell (1990) apresentam em seu trabalho várias técnicas que empregam redes neurais para implementar memórias associativas. São apresentados também exemplos específicos que servem para ilustrar os pontos fortes e fracos das aplicações.

Essas áreas de aplicações permitem que as RNAs sejam empregadas numa infinidade de situações práticas nas mais diversas áreas do conhecimento. Na Figura 4 são apresentadas as quantidades de trabalhos encontradas no repositório de artigos científicos do site *Scopus* © da *Elsevier* relacionados às aplicações de RNAs.

Número de Artigos com RNAs no SCOPUS ENGENHARIA 52.047 CIÊNCIA DA COMPUTAÇÃO 49.332 MATEMÁTICA 13.802 MEDICINA 10.824 NEUROSCIENCE 8.814 BIOQUIMICA, GENÉTICA E BIOLOGIA MOLECULAR 8.255 FÍSICA E ASTRONOMIA 8.034 CIÊNCIA AMBIENTAL 7.725 CIÊNCIAS PLANETÁRIAS E DA TERRA 7.167 CÊNCIA DOS MATERIAIS 6.689 ENERGIA 6.043 QUÍMICA 5.698

Figura 4 – Trabalhos observados na literatura que resultaram de aplicações por RNAs.

Fonte: Baseado em dados do Scopus © (01/03/2017).

A Figura 5 ilustra a quantidade de artigos publicados em algumas das áreas de pesquisas relacionadas aos SEPs os quais decorrem da aplicação de RNAs.

Nota-se pelo gráfico da Figura 5 que a maior parte dos trabalhos em SEP estão relacionados à QEE. No que se refere aos trabalhos de classificação de distúrbios, a sua grande maioria emprega *Wavelets* para segmentar e extrair as características dos distúrbios

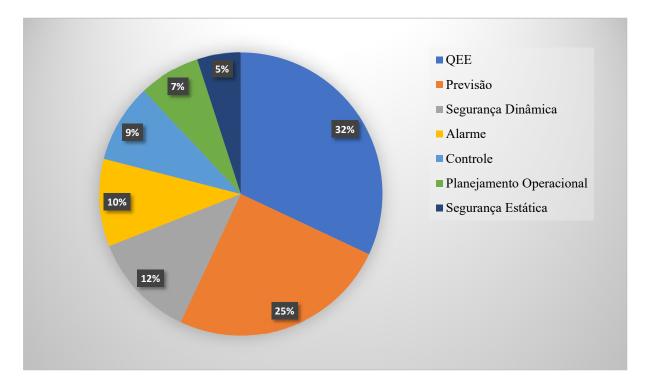


Figura 5 – Trabalhos decorrentes da aplicação de RNAs em SEPs.

Fonte: Baseado em Haque e Kashtiban (2005, p. 54).

presentes nos sinais. Em seguida, estes trabalhos usam as características extraídas para, via RNAs, proceder a classificação dos mesmos. Na Seção 3.2 são apresentados inúmeros trabalhos relacionados à classificação de distúrbios, onde, em quase na sua totalidade, empregam RNAs para essa tarefa.

### 2.2.3 Algoritmos Evolutivos (AEs)

Nas décadas de 1950 e 1960, vários cientistas computacionais estudaram sistemas evolutivos com a ideia de que o conceito de evolução pudesse ser usado como ferramenta de otimização em problemas de engenharia. A ideia de todos esses sistemas era evoluir uma população de soluções candidatas de um dado problema, usando operadores inspirados na variação genética e seleção natural. Rechenberg, em 1965, introduziu o termo Estratégias Evolutivas (EEs). Seu método foi usado na otimização dos parâmetros para dispositivos como aerofólios. O campo das EEs se manteve como um área ativa de pequisa, na maioria das vezes desenvolvido independentemente do campo dos AGs. Em 1966, Fogel, Owens e Walsh desenvolveram o que chamaram de Programação Evolutiva (PE). A técnica desenvolvida adota soluções candidatas que representam máquinas de estados finitos para executar determinadas tarefas. Na década de 1960, John Holland inventou e desenvolveu os AGs, que tinham por objetivo estudar formalmente o fenômeno de

adaptação que ocorre na natureza e desenvolver mecanismos para que esse conceito pudesse ser importado para sistemas computacionais. Juntas, EEs, PE e AGs, apresentadas no que segue, formaram a espinha dorsal dos Algoritmos Evolutivos (AEs) (MITCHELL; TAYLOR, 1999; MITCHELL, 2002):

- Estratégias Evolutivas (EEs) foi proposta para otimizar soluções candidatas compostas por parâmetros reais. Seus métodos de evolução podem ser elitistas ou não elitistas. No seu método de mutação, cada componente do cromossomo é modificado por um valor aleatório obtido de uma distribuição normal com média zero e um desvio padrão que pode se adaptar durante o processo de evolução. Sua recombinação pode ser discreta ou intermediária, onde a média aritmética é o tipo mais frequente (TINÓS; CARVALHO, 2008);
- Programação Evolutiva (PE) sua forma inicial, onde soluções candidatas são inicialmente representadas por máquinas de estados finitos, foi uma tentativa de criar inteligência artificial inspirada no princípio da Evolução Natural (EN). Inicialmente em PE, os diagramas de transição de estado das máquinas, que representavam a evolução dos indivíduos, eram aleatoriamente modificados, e os indivíduos com o melhor fitness eram selecionados. Nos últimos anos, novas representações de PE tem aparecido, o que tem resultado em algoritmos similares aos das EEs (TINÓS; CARVALHO, 2008); e
- Algoritmos Genéticos (AGs) apresentam as soluções candidatas de um problema usualmente codificadas na forma de um vetor composto por número binário, embora outras representações possam ser encontradas. Nestes, um vetor representa um indivíduo e é conhecido como cromossomo. AGs usam a seleção e a reprodução durante a evolução de sua população. Após a seleção, os operadores genéticos de reprodução são aplicados. Os mais populares são o crossover e a mutação, embora muitos outros tenham sido propostos (TINÓS; CARVALHO, 2008).

Os AGs são a mais explorada das três técnicas, mesmo sendo as EEs as mais populares na Europa, onde foram inicialmente desenvolvidas. É importante mencionar que as diferenças entre as três áreas têm diminuído nos últimos anos, devido ao crescente número de pesquisas de uma área adotar conceitos das outras (TINÓS; CARVALHO, 2008).

Desse modo, pode-se definir AEs como uma classe de algoritmos meta-heurísticos empregados em otimização e aprendizado de máquina, inspirados nos princípios da Evolução Natural e Genética. A ideia básica dos AEs é a criação de um conjunto de soluções candidatas para uma dada tarefa, sendo a sua evolução dada por meio de mecanismos de seleção e reprodução inspirados naqueles encontrados na evolução natural (FOSTER,

## 2001; TINÓS; CARVALHO, 2008).

Desde a sua concepção, AEs têm sido empregados na solução de uma infinidade de problemas práticos nas mais diversas áreas de conhecimento. Na Figura 6 são apresentadas as quantidades de trabalhos que podem ser encontradas no repositório de artigos científicos do site *Scopus* © da *Elsevier* relacionados às aplicações de AEs.

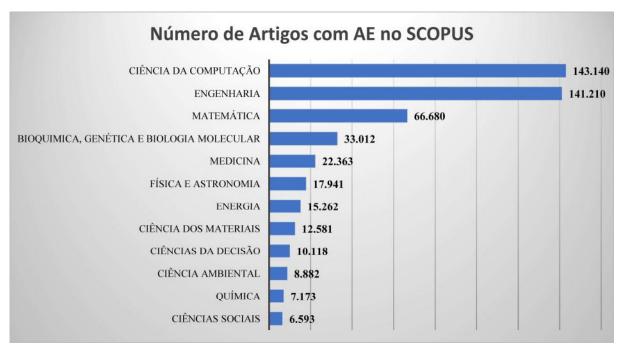


Figura 6 – Montante dos trabalhos encontrados e relacionados com AEs.

Fonte: Baseado em dados do Scopus © (01/03/2017).

A Figura 7, diferentemente dos gráficos anteriores, ilustra a quantidade de artigos de autores brasileiros publicados em algumas das áreas do conhecimento nas quais foram empregadas AEs.

Tinós e Carvalho (2008) mencionam em seu trabalho que a Figura 7 foi compilada considerando as bases de dados das publicações encontradas na Web of Science e na Compendex, que juntas envolvem 27 mil periódicos e congressos. Contudo, os autores ressaltam que as duas bases representam apenas uma fração dos trabalhos publicados de pesquisadores brasileiros. Muitas outras publicações em AEs com outras importantes origens não foram consideradas nessas bases de dados como a de eventos em engenharia e ciências da computação. Tinós e Carvalho (2008) também verificaram em seu trabalho que o número de publicações relacionados a AEs de pesquisadores brasileiros tem crescido muito nos últimos anos.

Baseado na Figura 7, pode-se verificar que a maioria das publicações dos pesquisadores brasileiros está relacionada à áreas onde tradicionalmente são utilizados métodos de otimização, como SEPs e sistemas de controle (TINÓS; CARVALHO, 2008).

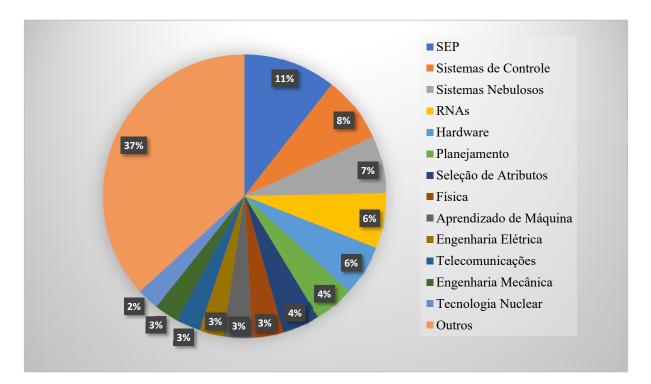


Figura 7 – Trabalhos que se utilizaram de aplicações de AEs.

Fonte: Baseado em Tinós e Carvalho (2008, p. 10)

#### 2.2.4 Outras Ferramentas

Existem outras ferramentas inteligentes que são empregadas no reconhecimento e classificação de distúrbios relacionados à QEE. Essas ferramentas não são empregadas com a mesma frequência do que as RNAs, mas também podem apresentar resultados promissores. Dentre essas ferramentas, pode-se citar:

• Sistemas fuzzy - refere-se a um sistema que generaliza o sistema lógico clássico de dois valores para o raciocínio com incerteza. Sua motivação é baseada na observação de que o raciocínio humano pode utilizar conceitos e conhecimentos que não têm fronteiras precisas ou bem definidas. Ao contrário dos conjuntos booleanos, que permitem apenas valores 0 e 1, os conjuntos fuzzy são conjuntos com as fronteiras suaves que permitem pertinências parciais. O grau de pertinência de um objeto referente a um conjunto é expresso por um número entre 0 e 1, onde 0 indica a exclusão total do conjunto, e 1 indica a inclusão total no conjunto. Já os números entre 0 e 1 indicam inclusão ou exclusão parciais do conjunto. Dessa forma, a transição gradual de uma região fora de um conjunto, para a região dentro do conjunto, pode ser caracterizada. Portanto, um sistema fuzzy é um sistema inteligente que usa uma coleção de conjuntos fuzzy e uma base de regras para raciocinar a partir dos dados. Um exemplo do uso de lógica fuzzy na classificação de distúrbios no contexto da QEE

pode ser encontrado em Liao e Lee (2004). Os autores empregaram as transformadas de Fourier e *Wavelet* para obter as características dos sinais em análise e empregaram sistemas *fuzzy* para tomar a decisão referente ao tipo de distúrbio manifestado;

Máquinas de vetores suporte - é uma técnica que tem sido usada em muitos problemas de classificação de padrões e problemas de regressão, assim como em problemas de estimação de dependência, previsão, entre outros. Os resultados da aplicação desta técnica são comparáveis aos obtidos por outros algoritmos de aprendizado, como as RNAs. Em algumas tarefas (em específico), as máquinas de vetores suporte têm se mostrado superiores às usuais, tal como na detecção de faces em imagens, na categorização de textos e em aplicações em Bioinformática (LORENA; CARVAHO, 2003). O trabalho de Ekici (2009) apresentou um método efetivo baseado em máquinas de vetores suporte para a identificação de distúrbios em SEPs. Os autores empregaram a TW para extrair características dos sinais de tensão. Após a extração das características, as máquinas de vetores suporte foram usadas para classificar os sinais dentre os distúrbios desejados. Os resultados de Ekici (2009) demonstraram desempenho comparável as das RNAs; e

Árvores de decisão - a classificação de distúrbios baseado em árvores de decisão faz uso do princípio de dividir para conquistar, pois particiona recursivamente um conjunto de distúrbios até que cada subconjunto obtido deste particionamento contenha casos com as mesmas características que estão sendo utilizadas na tomada de decisão. A árvore de decisão toma como entrada dois tipos de características, o valor RMS e os cumulantes de segunda ordem, e retorna a decisão - o valor de saída previsto, de acordo com a entrada (BARBOSA; FERREIRA, 2013). Os atributos de entrada para a árvore de decisão podem ser contínuos ou discretos, mas no caso da pesquisa de Barbosa e Ferreira (2013), tem-se atributos discretos. A árvore de decisão apresenta o seu resultado de acordo com uma sequência ordenada de perguntas relacionadas aos valores RMS e aos cumulantes de segunda ordem. As perguntas feitas a cada passo na sequência dependem das respostas às perguntas anteriores. A sequência termina com a classificação dos distúrbios. O ponto de partida de uma árvore de classificação é chamado de nó raiz, e consiste do conjunto de aprendizado formado por todas as classes de distúrbios que estão sendo analisados. Cada nó da árvore é um subconjunto do conjunto de distúrbios, e pode ser terminal ou não-terminal. Um nó não-terminal é um nó que divide as classes de distúrbios em nós filhos. Tal divisão de um nó em outros é determinada por uma condição relacionada aos valores RMS e aos cumulantes de segunda ordem. Um nó que não se divide é chamado de nó terminal e a ele é atribuída uma classe de distúrbios. Cada classe de distúrbio cai em um dos nós terminais (BARBOSA; FERREIRA, 2013).

# 2.2.5 Considerações Finais

Portanto, umas das tarefas fundamentais para o desenvolvimento dessa pesquisa foi a realização de uma revisão que pudesse fornecer informações sobre ferramentas consagradas para execução de cada uma de suas etapas (segmentação, classificação e compressão) e que, quando aplicadas em conjunto, e de forma inovadora, pudessem fornecer contribuições para o tratamento dos sinais e problemas relacionados aos SEPs, no contexto da QEE.

# Aplicações de Interesse da Pesquisa

Este capítulo apresenta uma revisão dos trabalhos publicados referentes aos temas que formam essa pesquisa (segmentação, classificação, compressão e armazenamento de distúrbios de QEE). Os aspectos fundamentais das publicações mais relevantes foram destacados, bem como as justificativas apresentadas pelos autores, suas ferramentas, os métodos propostos e seus principais resultados.

## 3.1 A Segmentação dos Sinais em Análise

De acordo com Santoso, Powers e Grady (1994), a QEE em geral se refere à manutenção da forma de onda senoidal da tensão em sua magnitude e frequência. Portanto, distúrbios de QEE podem ser definidos como qualquer desvio, distorção ou afastamento da forma de onda senoidal na sua magnitude ou frequência. Santoso, Powers e Grady (1994) lembram que o sistema de distribuição é interconectado entre as concessionárias e os consumidores. Portanto, qualquer distúrbio gerado no lado da concessionária pode ser propagado para o lado dos consumidores. Além disso, uma vez que consumidores estão interconectados, é possível que um consumidor gere distúrbios que afetarão a QEE de outros consumidores. Santoso, Powers e Grady (1994) afirmam que são inúmeros os Institutos que conduzem pesquisas independentes na área de QEE nos Estados Unidos e Canadá. Segundo os autores, tais Institutos têm como objetivo formar um grande conjunto de dados para a subsequente análise dos distúrbios, a fim de fornecer o conhecimento das causas e dos impactos dos mais variados distúrbios, identificando assim, as origens dos mesmos. Santoso, Powers e Grady (1994) ainda reiteram a grande quantidade (volume) dos dados coletados, não sendo assim, nada prática a manipulação dos dados para qualquer fim, deixando ainda mais evidente a necessidade de uma forma automática para detectar a ocorrência dos distúrbios. Desse modo, a abordagem do trabalho de Santoso, Powers e Grady (1994) emprega TW para a detecção e a localização dos distúrbios, uma vez que estas são sensíveis às irregularidades dos sinais (distúrbios) e indiferentes ao comportamento constante do sinal (forma de onda senoidal). Baseado nessas propriedades, é evidente que

as transformadas *Wavelet* se caracterizam como uma ferramente apropriada para detectar e localizar distúrbios no contexto da QEE.

Segundo Santoso et al. (1996), o interesse em QEE tem crescido rapidamente desde que inúmeros problemas têm afetado as cargas, gerando mau funcionamento, instabilidades e redução de vida útil, dentre outras situações não desejáveis. Conforme frisam os autores, as causas e as consequências dos distúrbios devem ser conhecidas antes que medidas apropriadas sejam tomadas e, para que isso seja possível, deve-se ter a capacidade de se detectar, localizar e classificar os distúrbios. Procedimentos manuais foram desenvolvidos com esse propósito. Entretanto, devido ao grande esforço necessário, tais procedimentos são dispendiosos e muitas vezes, ineficientes. Santoso et al. (1996) afirma que a ideia principal da localização de distúrbios elétricos por meio de Wavelets é a de se decompor o sinal a ser analisado em outros sinais, representando as versões suavizada e detalhada do sinal original. A versão detalhada contêm as descontinuidades do sinal como bordas acentuadas, transições e sobressaltos. Dessa forma, as Wavelets discriminam os distúrbios do sinal original e os analisam separadamente. Santoso et al. (1996) indicam a família de Wavelets Daubechies como mais apropriadas para identificar distúrbios, afirmando que a Daubechies 4 e 6 são as mais indicadas para detectar os distúrbios transitórios curtos e rápidos, e as Daubechies 8 e 10 para detectar os transitórios lentos. Entretanto, Santoso et al. (1996) lembram que a determinação da Wavelet mais apropriada ocorre sem que se saiba quais são as características dos distúrbios que podem aparecer nos sinais. Portanto, ao invés de se desenvolver algoritmos para selecionar as Wavelets mais apropriadas, utiliza-se uma Wavelet em todo o curso de detecção e localização de todos os tipos de distúrbios. O trabalho de Santoso et al. (1996) ainda apresenta as características dos distúrbios que podem ser extraídas com o uso das Wavelets. Tais características podem ser empregadas na classificação dos distúrbios, por exemplo, por meio de RNAs.

Segundo Poisson, Rioual e Meunier (1998), métodos de detecção de afundamentos de tensão e de transitórios devem ser precisos o suficiente para determinar as causas desses distúrbios. A identificação confiável dos distúrbios permite às concessionárias aprimorar os SEPs. Os autores descrevem a TW como uma nova ferramenta de processamento de sinais que pode ser empregada na análise da QEE. A TW, assim como a Short Time Fourier Transform (STFT), fornece uma compreensível representação do sinal transitório correspondente ao plano tempo-frequência. Este plano fornece informações relativas ao tempo e à frequência do sinal analisado. Ao contrário da STFT, o tamanho da janela de alisamento da TW depende da frequência a ser analisada, visto que janelas longas são empregadas em baixas frequências e janelas curtas em altas frequências. Em baixas frequências, a TW apresenta uma resolução de frequência precisa, mas pobre localização no tempo. Reciprocamente, em altas frequências, a TW apresenta localização no tempo precisa e pobre resolução de frequência. De acordo com Poisson, Rioual e Meunier (1998), esta característica demonstra ser apropriada para a análise de sinais provenientes de

afundamentos ou transitórios. Os planos tempo-frequência são também significativos para cada tipo de distúrbio, pois fornecem suas caraterísticas de tempo e de frequência. Portanto, o trabalho de Poisson, Rioual e Meunier (1998) emprega a TW para extrair características dos sinais investigados e efetua a sua comparação com valores de referência. Os resultados dessa comparação permitem a detecção da presença dos distúrbios nos sinais analisados e fornecem as características desses distúrbios. O trabalho também faz comparações de desempenho entre o método baseado no valor RMS e a TW para detecção dos afundamentos de tensão, assim como faz comparações de desempenho entre o método derivativo de detecção e a TW para detecção dos transitórios. Segundo os autores, essas comparações fornecem a validação experimental do algoritmo de detecção baseado na TW.

O trabalho de Zhang, Liu e Malik (2003) define os problemas de QEE como qualquer variação no fornecimento de energia, como quedas e flutuações de tensão, interrupções, elevações e afundamentos de tensão e distorções harmônicas. Os autores afirmam que são muitas as técnicas a respeito da detecção de distúrbios em QEE, incluindo comparações ponto a ponto de ciclos adjacentes, RNAs e análise por TW. Segundo Zhang, Liu e Malik (2003), a desvantagem da primeira abordagem é sua ineficácia na detecção de distúrbios que aparecem periodicamente. Já as abordagens baseadas em RNAs são úteis na classificação dos distúrbios, mas sua velocidade de convergência e precisão são afetadas por ruídos. De acordo com os autores, Wavelets são amplamente empregadas na avaliação da QEE, mas em muitos casos, o efeito do ruído elétrico não é adequadamente considerado nessas investigações. A fim de se melhorar a precisão na detecção de distúrbios e seu desempenho computacional, o trabalho de Zhang, Liu e Malik (2003) apresenta uma abordagem simples baseada na transformada de correlação short-time para filtragem dos ruídos elétricos e na aplicação da TW.

Vega et al. (2008) apresenta em seu trabalho um método para se determinar a melhor família Wavelet para a detecção de distúrbios de QEE. Segundo os autores, esses distúrbios afetam o suprimento dos clientes e sua detecção por sistemas de monitoramento é fundamental para se determinar soluções confiáveis. As técnicas de processamento por meio da TW têm sido empregadas na detecção dos distúrbios de QEE, devido as suas propriedades de análise multi-resolução tempo-frequência. No trabalho de Vega et al. (2008), trinta de duas funções Wavelets de quatro famílias foram analisadas (Biortogonal, Coiflet, Daubechies, e Symlet) e os resultados apresentados indicaram que a família Wavelet que apresentou melhor desempenho foi a Biortogonal.

O trabalho de Xue et al. (2008) defende o uso de matemática morfológica para a filtragem dos ruídos presentes em sinais e emprega Wavelets complexas para a localização de distúrbios de QEE. Xue et al. (2008) confirma que as Wavelets possuem características apropriadas para a detecção e a identificação de distúrbios de QEE, mas defende que as Wavelets possuem muitas deficiências relativas à filtragem de ruídos. Segundo Xue

et al. (2008), matemática morfológica é eficiente na filtragem de ruído branco e ruído impulsivo. A matemática morfológica trata de um tipo de transformação não linear que modifica localmente as características geométricas dos sinais. Xue et al. (2008) afirmam que, nos últimos anos, os filtros morfológicos têm sido aplicados com sucesso em muitas áreas, incluindo processamento de imagens, detecção de bordas, supressão de ruídos, reconhecimento de formas, dentre outras. No que se refere à detecção dos distúrbios Xue et al. (2008) empregou a família Daubechies no seu trabalho, depois de comparar muitos tipos de Wavelets diferentes. Xue et al. (2008) reiteram que as Wavelets fornecem um método apropriado para a detecção de singularidades, devido à sua característica de localização no domínio do tempo e da frequência.

Tan e Ramachandaramurthy (2009) apresentaram resultados experimentais que demonstraram excelente desempenho na tarefa de detecção, localização, segmentação e estimação da energia, frequência, magnitude, duração e sobretensão de distúrbios transitórios (oscilatório e impulsivo). Tan e Ramachandaramurthy (2009) descrevem transitórios como distúrbios não estacionários que contaminam os sinais dos SEPs com altas frequências por um tempo de duração muito curto. Segundo Tan e Ramachandaramurthy (2009), dentre as causas dos transitórios estão relâmpagos próximos ou sobre as linhas de transmissão, transformadores, bancos de capacitores e cargas. Os autores afirmam que as Wavelets são consideradas uma excelente ferramenta para analisar as características de tempo e de frequência dos transitórios, uma vez que estes podem causar danos ou mau funcionamento de equipamentos eletrônicos sensíveis. A seleção do suporte de transformadas Wavelets contínuas com sua análise no tempo é proposta no trabalho de Tan e Ramachandaramurthy (2009) para analisar transitórios oscilatórios e impulsivos e para determinar sua frequência de oscilação. Segundo Tan e Ramachandaramurthy (2009), a família Wavelets Morlet foi escolhida como transformada Wavelet, contínua uma vez que esta se assemelha à natureza das curvas de onda dos SEPs, e devido ao fato de ser amplamente usada na análise de distúrbios de QEE.

O trabalho de Le, Gu e Bollen (2010) emprega sistemas de segmentação chamados causal e anti-causal. Segundo os autores, um sistema de segmentação causal determina sua saída de acordo com as entradas passadas ou atuais. Um sistema anti-causal determina sua saída somente de acordo com entradas futuras. O trabalho dos autores faz uma combinação dos dois sistemas de segmentação, pois o uso de apenas um desses sistemas apresenta um atraso na determinação de um ponto a sofrer segmentação. Baseado nos resultados obtidos com duas janelas de análise (janela de análise causal e janela de análise anti-causal), o método de Le, Gu e Bollen (2010) determina um ponto de transição em um segmento de forma precisa. Os autores apresentam, dentre os resultados, o atraso para a detecção das transições em segmentos de acordo com o valor da tensão remanescente, velocidade de transição e taxa de ruído. Segundo Le, Gu e Bollen (2010), sua técnica obteve resultados que, mesmo na presença de ruídos, não apresentam alarmes falsos e não apresentam

diferenças significativas de atraso na detecção.

Conforme o trabalho de Mahmoudi, Hosseinian e Doroudi (2010), uma revisão da literatura demonstra que pesquisas anteriores foram baseadas na seleção de dados brutos empregados no estudo e na análise de distúrbios. Entretanto, o montante de dados mensurados é frequentemente massivo. Essa abundância de dados exige uma inspeção demorada para um diagnóstico. Além do que, esta não é adequada para uma supervisão online, em tempo real, o que exige uma abordagem mais eficiente. Mahmoudi, Hosseinian e Doroudi (2010) afirmam, então, que pela TW pode-se determinar um framework para o processamento de sinais, uma vez que esta emprega janelas de diferentes tamanhos de acordo com o montante de frequências dos sinais e também pode monitorar mais precisamente características de não estacionariedade. Os comportamentos transitórios, as cavidades e as descontinuidades dos sinais podem ser investigados pela TW, uma vez que ela apresenta um equilíbrio entre tempo e frequência. Segundo o trabalho de Mahmoudi, Hosseinian e Doroudi (2010), as Wavelets mais adequadas para a detecção dos distúrbios são a Daubechies 4, a Daubechies 20, a Symlets 8 e a De Meyer. Os resultados do trabalho demonstram que a Wavelet de Meyer possui desempenho superior quando comparada às demais, e que a Wavelet Daubechies 20 possui desempenho superior à Daubechies 4. É importante mencionar que o trabalho afirma que, na medida em que os distúrbios se manifestam nos sinais, a energia calculada na decomposição muda, permitindo o uso de um limiar para identificar a ocorrência dos mesmos.

A fim de se melhorar a QEE, Sushama, Ram e Laxmi (2010) reiteram que as origens e as causas dos distúrbios devem ser conhecidas para que ações corretivas possam ser tomadas. Desse modo, são necessários registros contínuos das curvas dos distúrbios, o que leva a um volume de dados a ser inspecionado pelos engenheiros. Segundo Sushama, Ram e Laxmi (2010), problemas de QEE podem ser descritos como qualquer variação nos sinais de fornecimento da energia elétrica resultando em má operação ou falha dos equipamentos do usuário final. Portanto, técnicas de processamento de sinais baseadas em Wavelets podem ser ferramentas de análise de transitórios em SEPs, classificação de distúrbios e proteção das linhas de transmissão. O trabalho de Sushama, Ram e Laxmi (2010) emprega a família de Wavelets Daubechies na decomposição dos sinais de distúrbios e fornece gráficos que permitem fácil identificação visual do resultados dessas decomposições.

Runhong, Sen e Yili (2012) reiteram que problemas de QEE têm se tornado cada vez mais importantes para os envolvidos nesse mercado. Segundo os autores, muitos equipamentos elétricos não lineares vêm sendo conectados ao sistema elétrico, o que aumenta as dificuldades no gerenciamento da QEE. Adicionalmente, equipamentos eletrônicos têm se tornado mais sensíveis à qualidade da energia elétrica e suas falhas podem causar grandes perdas econômicas à comunidade em geral. Runhong, Sen e Yili (2012) afirmam que equipamentos elétricos inteligentes são baseados na localização precisa de distúrbios.

Portanto, um método de localização preciso de distúrbios é a base do aprimoramento da QEE e da proteção de equipamentos elétricos. O trabalho de Runhong, Sen e Yili (2012) propõe então o uso de um algoritmo de detecção baseado em morfologia, combinado com a Transformada *Top-hat*, originalmente empregada na extração de detalhes de imagens, e métodos de limiarização suaves, que têm sido aplicados numa variedade de distúrbios de QEE, apresentando resultados precisos de localização. Os resultados de Runhong, Sen e Yili (2012) demonstraram que o método proposto é preciso na localização dos distúrbios de QEE sob várias condições.

Dwivedi e Tiwari (2015) reiteram que a QEE é, frequentemente, afetada por distorções harmônicas e transitórios. Segundo eles, com o aumento do uso de dispositivos eletrônicos nos SEPs modernos, a QEE se tornou um assunto desafiador para os engenheiros eletricistas. Os autores afirmam que, a fim de se monitorar e controlar esse distúrbios, sua identificação é essencial para se efetuar medidas preventivas e corretivas adequadas. Dwivedi e Tiwari (2015) lembram que a Transformada de Fourier (TF) apresenta o conteúdo espectral do sinal, entretanto, não apresenta a localização temporal de seus componentes. Portanto, a TF não é adequada para sinais não estacionários, especialmente sinais aperiódicos. Segundo Dwivedi e Tiwari (2015), uma ferramenta capaz de fornecer as informações de tempo de frequência simultaneamente é a TW. Apesar de Dwivedi e Tiwari (2015) relatarem as atribuições da TW, seu trabalho propõe uma abordagem simples baseada em aproximação polinomial ortogonal para detectar e localizar distúrbios de QEE. A ideia principal de sua abordagem é de ajustar um dado sinal com distúrbio, de tal modo que a parte não correlacionada (distúrbio) não esteja presente na versão aproximada do sinal. Desse modo, Dwivedi e Tiwari (2015) podem detectar e localizar distúrbios de QEE analisando a diferença entre os sinais originais e suas aproximações. Isso é realizado escolhendo-se um grau do polinômio utilizando o critério de mínima variância do erro. Dwivedi e Tiwari (2015) testaram a efetividade de sua abordagem em sinais gerados sinteticamente e sinais obtidos da força tarefa (IEEE 1159.3 Task Force, 1993). Segundo os autores, os resultados comparativos entre as técnicas que empregam a TW e sua abordagem revelam seu potencial e demonstram sua simplicidade e suas vantagens.

#### 3.2 A Classificação dos Distúrbios Manifestados

A QEE, conforme Santoso et al. (2000), tornou-se um assunto importante para as concessionárias e seus consumidores. Consumidores, em particular, têm se tornado menos tolerantes aos distúrbios da energia elétrica porque estes degradam o desempenho e a eficiência de suas cargas, especialmente as eletrônicas. Santoso et al. (2000) mencionam que 80% dos problemas relacionados à QEE são originados nas instalações dos consumidores. Entretanto, eles geralmente se voltam para as concessionárias para identificar o problema. Desse modo, muitas concessionárias mantêm engenheiros dedicados a tratar de problemas

de QEE dos consumidores e de fornecer procedimentos apropriados para sua amenização. A fim de se melhorar a QEE as concessionárias monitoram continuamente a energia fornecida para os consumidores. Santoso et al. (2000) adverte que o procedimento de se registrar continuamente as formas de onda das cargas por meio de instrumentos medidores de energia, produz anualmente arquivos de dados da ordem de gigabytes. Segundo Santoso et al. (2000), os métodos existentes para se identificar e se analisar os distúrbios de energia elétrica são árduos, pois são baseados na inspeção visual das formas de onda. Como resultado, os engenheiros de QEE são inundados com um enorme montante de dados para ser inspecionado. Contudo, os recentes avanços na análise de sinais levaram ao desenvolvimento de novas técnicas de identificação dos distúrbios. Desse modo, o propósito do trabalho de Santoso et al. (2000) é tratar desses avanços, especialmente da TW, RNAs e da teoria matemática da evidência, aplicadas no reconhecimento dos distúrbios de QEE. O uso da TW se justifica quanto a detecção e extração de características dos distúrbios devido à sua sensibilidade às irregularidades e insensibilidade ao comportamento regular do sinal. Quanto às RNAs, o trabalho de Santoso et al. (2000) emprega uma versão supervisionada dos mapas auto-organizáveis chamada de Learning Vector Quantization (LVQ). A teoria da matemática da evidência é aplicada no pós-processamento dos resultados das redes neurais para efetuar a decisão sobre quais tipos de distúrbios foram encontrados.

De acordo com Elmitwally et al. (2001), usualmente é grande o volume de dados registrados e que têm que ser processados nos sistemas elétricos. Os medidores empregados ainda não apresentam a habilidade de distinguir os eventos presentes nos sinais. Desse modo, é muito demorado e cansativo, mesmo para um técnico competente, interpretar os dados e fornecer recomendações úteis. Portanto, para Elmitwally et al. (2001), é altamente desejável que o processo de aquisição dos dados seja mais automatizado, com dispositivos de monitoramento que não apenas registrem os distúrbios mas também os classifique. Para os autores, o medidor inteligente seria capaz de reconhecer diferentes tipos de distúrbios e oferecer meios para selecionar informações significativas necessárias para avaliar o desempenho do sistema elétrico. Em seu trabalho, Elmitwally et al. (2001) empregam Wavelets para a detecção e extração de características dos sinais e o sistema neuro-fuzzy para a classificação dos distúrbios. Segundo os autores, a escolha da Wavelet mais apropriada não é uma tarefa simples. Entretanto, a família de Wavelets Daubechies tem demonstrado ser eficiente na análise de QEE. Seu trabalho então a emprega na extração de características dos sinais que são apresentados como entrada para que o sistema neuro-fuzzy possa fornecer sua classificação. Elmitwally et al. (2001) concluem que as ferramentas e os mecanismos empregados podem auxiliar na elaboração de um medidor inteligente capaz de detectar e identificar automaticamente eventos que violem a QEE.

Huang, Negnevitsky e Nguyen (2002) afirmam que os os dispositivos eletrônicos e os sistemas baseados em microprocessadores, amplamente empregados nas indústrias modernas, são mais sensíveis às variações de QEE do que os equipamentos empregados no

passado. Portanto, esse tema se tornou prioridade nas concessionárias e de seus usuários finais. Segundo os autores, esforços consideráveis têm sido empregados nessa área por meio da avaliação dos impactos causados devido a deterioração da QEE, por meio do monitoramento dos distúrbios que ocorrem nas redes de transmissão e distribuição, e por meio da adoção de medidas de melhoramento do serviço. Huang, Negnevitsky e Nguyen (2002) reiteram que investigações iniciais são necessárias para se identificar as circunstâncias exatas em que ocorrem os problemas de QEE, assim como as medidas a serem adotadas contra eles. Na prática, o fornecimento da energia elétrica é monitorado constantemente, produzindo arquivos de dados anuais de qiqabytes. Huang, Negnevitsky e Nguyen (2002) afirmam então que é um grande desafio identificar diferentes distúrbios nas medidas feitas em campo, tanto on-line como off-line, e que inspeções visuais são penosas e demoradas. Portanto, é primordial o desenvolvimento de técnicas de reconhecimento automático sofisticadas. De acordo com Huang, Negnevitsky e Nguyen (2002), seu trabalho apresenta um novo classificador de distúrbios de QEE baseado nas Wavelets e em tecnologias neurais e de lógica nebulosa. Devido ao tamanho desmedido do arquivo de dados brutos adotados no desenvolvimento de seu trabalho, Wavelets da família Daubechies foram adotadas para extrair características das curvas originais. Essas características são então apresentadas como entradas para o classificador formado por redes neurais LVQ e por Fuzzy Associative Memories (FAM). Como resultado, o trabalho de Huang, Negnevitsky e Nguyen (2002) apresentou uma média de reconhecimento de 93%. Depois da fase de treinamento, o custo computacional envolvido na classificação foi reduzido significativamente devido aos esforços na remoção das redundâncias e simplificação do esquema. O que, segundo os autores, permite à abordagem proposta ser empregada em aplicações on-line.

A QEE se tornou um assunto importante nos últimos anos, é o que também assegura o trabalho de Zhu, Tso e Lo (2004). Os autores afirmam que os métodos empregados para análise e identificação dos distúrbios associados à falta da QEE são baseados na inspeção visual dos sinais. Logo, o conhecimento dos engenheiros da área tem um papel importante, e os mesmos são inundados com um enorme montante de dados a serem inspecionados. Portanto, é desejável o desenvolvimento de métodos automáticos para detecção, investigação e análise dos distúrbios. Zhu, Tso e Lo (2004) afirmam que poderosas ferramentas de análise e classificação de distúrbios de QEE estão disponíveis atualmente, e sua classificação automática tem tido grande progresso. Entretanto, segundo Zhu, Tso e Lo (2004), a correta classificação dos distúrbios apresenta índices inferiores àqueles encontrados em outras áreas de reconhecimento de padrões, assim como, baixo desempenho no seu processo de reconhecimento. Consequentemente, ainda existe espaço para melhorias. Desse modo, o trabalho de Zhu, Tso e Lo (2004) apresenta uma abordagem baseada em Wavelet Daubechies para a extração de características, e em lógica nebulosa para a classificação dos distúrbios. A partir dos padrões de distribuição da energia de cada nível de decomposição Wavelet são determinadas as regras linguísticas da lógica nebulosa para cada distúrbio. O algoritmo de Zhu, Tso e Lo (2004) é então testado com um amplo montante de dados de distúrbios gerados por simulação numérica e nenhuma taxa de erro foi apresentada para a abordagem. Adicionalmente, o algoritmo proposto demonstrou robustez mesmo na presença de ruído.

Medidores geram um elevado montante de dados brutos, de acordo com o trabalho de Abdel-Galil et al. (2004), tornando sua análise proibitiva quanto ao tempo e ao conhecimento. Portanto, a classificação automática de distúrbios de QEE se tornou um assunto importante, especialmente em mercados desregulamentados. Desse modo, muitos sistemas automáticos de classificação em QEE tem sido projetados. Segundo os autores, abordagens empregando RNAs têm atraído atenção devido a sua capacidade de reconhecimento de padrões e sua habilidade em tratar os sinais na presença de ruídos. Assim como os métodos de classificação por similaridade com modelos, essas técnicas, segundo Abdel-Galil et al. (2004), embora forneçam resultados satisfatórios, carecem ainda de maiores justificativas para os resultados obtidos. Em contrapartida, sistemas baseados em regras para classificação de distúrbios em QEE dependem do desenvolvimento de um conjunto de regras que descrevam o conhecimento de um especialista, ou seja, o especialista fornece o conhecimento por trás da decisão de classificação. Abdel-Galil et al. (2004) empregaram esse conceito para desenvolver um sistema baseado em um conjunto de regras para identificar dez diferentes distúrbios de QEE. A TW Haar é empregada na decomposição dos sinais e as energias dos diferentes níveis representam os vetores de características. Esses vetores são, então, apresentados para uma árvore de decisão cuja estrutura consiste de um nó raiz, nós decisão e nós folha. Os vetores de características percorrem a árvore da raiz para as folhas, as quais fornecem a identificação dos distúrbios de QEE. A abordagem de Abdel-Galil et al. (2004) apresentou uma precisão de 91% para exemplos distintos daqueles empregados no ajuste da árvore de decisão.

Choong, Reaz e Mohd-Yasin (2005) defendem a importância da QEE para as concessionárias e seus consumidores. Segundo os autores, os efeitos da falta de QEE pode ser sentida nos negócios, nas indústrias, nas corporações e nas empresas, as quais sofrem a perda de bilhões de dólares todo ano devido à interrupção de suas operações diárias. Adicionalmente, as indústrias requerem alta disponibilidade do serviço e os sistemas de manufatura precisos são muito sensíveis aos problemas de QEE. Segundo Choong, Reaz e Mohd-Yasin (2005), as vantagens de um sistema automático de análise de faltas foram constatadas já na década de 1960 e nos últimos 10 anos foram sugeridas inúmeras abordagens para análise automática de faltas empregando métodos inteligentes. A abordagem adotada pelos autores emprega a TW que, segundo eles, têm provado ser muito eficiente na análise de sinais e demonstrado ser adequada para os estudos na área de QEE. Os autores também fazem a integração de RNAs e lógica nebulosa, por combinarem computação paralela e habilidades de aprendizado com habilidades de representação do conhecimento humano. Choong, Reaz e Mohd-Yasin (2005) propõem, então, um classificador empre-

gando a combinação dessas três tecnologias implementadas em *Field Programmable Gate Array* (FPGA), resultando em um classificador simples com um significativo aumento de desempenho e precisão.

São muitas as razões para o crescente interesse em QEE, segundo Janik e Lobos (2006). Dentre elas, a desregulamentação do mercado (por ter causado a necessidade de padronização e de melhores critérios de desempenho), a maior sensibilidade dos equipamentos eletrônicos atuais e a geração de distúrbios causadas pelos equipamentos dos próprios consumidores. Janik e Lobos (2006) afirmam que métodos automáticos de monitoramento são necessários para o tratamento de um grande número de incidentes, e que a sua abordagem permitirá a análise de grandes conjuntos de dados. O trabalho de Janik e Lobos (2006) emprega Wavelets Daubechies para detecção dos distúrbios, e a ideia de fasor espacial para a construção de padrões suficientemente distinguíveis que são então apresentados para Support Vector Machine (SVM). Para efeito de comparação, os autores também empregaram as Radial Basis Function Neural Networks (RBFNN) na classificação dos distúrbios por serem consideradas a melhor ferramenta na tarefa de classificação de padrões. Os resultados apresentados no trabalho de Janik e Lobos (2006) demonstraram capacidade de classificação superior das SVM.

Segundo Reaz et al. (2007), a escassez de especialistas em QEE restringe a manipulação do enorme montante de dados mensurados por sistemas de monitoramento. Os autores afirmam que os sinais dos distúrbios elétricos contêm sérias imprecisões nos seus dados e fornecem pouca informação, tornando sistemas convencionais incapazes de identificar qualquer problema de QEE. Os métodos de reconhecimento existentes necessitam de melhorias em termos de versatilidade, confiabilidade e precisão a fim de se tratar os sinais com distúrbios. Os dados obtidos não são auto-explicativos e requerem a intervenção de especialistas para fazer sua classificação. De acordo com Reaz et al. (2007), dados complexos de distúrbios de QEE são não estacionários e transitórios por natureza. Pontos de variação abruptas, como sinais transitórios, carregam informações importantes sobre os distúrbios e são fundamentais para a extração e a interpretação de forma eficiente desses eventos. Reaz et al. (2007) também afirmam que a TW tem provado ser muito eficiente na análise de sinais. Além da filtragem de ruídos, ela detecta precisamente mudanças abruptas e descontinuidades nos sinais elétricos, assim como, extrai suas características permitindo a identificação dos distúrbios. Os autores também reiteram que RNAs podem ser empregadas na solução de problemas em SEPs, particularmente naqueles em que as abordagens tradicionais têm dificuldade em fornecer a eficiência e a precisão desejadas. A lógica fuzzy, segundo os autores, permite descrever regras, as quais modelam processos do mundo real, fornecendo informações úteis e compreensíveis sobre os distúrbios na energia elétrica. Portanto, a abordagem de Reaz et al. (2007) faz uso dessas três tecnologias para obter uma maior precisão na classificação desses distúrbios. Os autores modelaram seu sistema por meio da Very High Speed Integrated Circuits Hardware Description Language (VHDL) e, segundo eles, obtiveram um desempenho encorajador. Seus resultados revelaram que a abordagem proposta é computacionalmente simples, precisa e fornece um bom equilíbrio de flexibilidade, desempenho, tamanho e tempo de projeto. A taxa de acerto pela abordagem proposta foi de 98,19%.

Masoum, Jamali e Ghaffarzadeh (2010) afirmam que a QEE tem recebido uma significativa atenção nos últimos anos e que, para seu aperfeiçoamento, as origens e causas dos distúrbios devem ser determinadas antes de se iniciar ações de melhoria. Contudo, isto requer monitoramento, detecção e classificação de distúrbios que costumam ser tarefas incômodas envolvendo um grande número de categorias de distúrbios. Masoum, Jamali e Ghaffarzadeh (2010) propõem uma abordagem para a detecção e a classificação de distúrbios em QEE empregando Wavelets para filtragem do ruído e decomposição dos sinais e redes neurais Wavelets para sua classificação. Por meio da decomposição dos sinais e da análise de componentes principais, vetores de características são determinados para que sejam apresentados para as redes neurais Wavelets. Segundo Masoum, Jamali e Ghaffarzadeh (2010) o uso de Redes Neurais Wavelets não apresenta as limitações associadas às RNAs tradicionais ou o neuro-Fuzzy como convergência para pontos de mínimo local ou problemas de overfitting ou underfitting. A eficácia do método proposto por Masoum, Jamali e Ghaffarzadeh (2010) é testada usando-se um grande número de distúrbios e suas combinações. Os resultados, quando comparados com outros métodos existentes, demostraram desempenho superior.

Saikia, Borah e Pait (2010) também afirmam que a QEE se tornou um tema importante para as concessionárias e seus consumidores. Os consumidores particularmente se tornaram menos tolerantes aos distúrbios de QEE. Tais distúrbios degradam o desempenho e a eficiência das cargas dos consumidores, em especial as cargas eletrônicas. Segundo Saikia, Borah e Pait (2010), as concessionárias mantêm engenheiros dedicados a tratar de problemas de QEE e de fornecer procedimentos apropriados de melhoria, uma vez que os consumidores se voltam para as concessionárias quando da ocorrência de problemas. Os autores afirmam também que, a fim de se melhorar a qualidade da energia, as concessionárias monitoram continuamente seu fornecimento. Desse modo, meios de se fazer a classificação automática dos distúrbios nas linhas de transmissão são altamente desejáveis. De acordo com Saikia, Borah e Pait (2010), muitos estudos quanto ao uso da TW em análise de sinais levaram à sua aplicação na identificação de distúrbios de QEE. A razão principal para seu sucesso se apoia no fato de que a transformada Wavelet fornece informação temporal dos distúrbios. Ainda segundo os autores, as Wavelets Daubechies 4, 6, 8 e 10 funcionam apropriadamente para detecção da maioria dos casos de distúrbios, com ênfase no uso das Daubechies 4 e 6 para transitórios rápidos, e as Daubechies 8 e 10 para transitórios lentos. Uma vez identificados os distúrbios, o trabalho faz uma comparação entre a lógica nebulosa e RNAs para sua classificação. Saikia, Borah e Pait (2010) identificaram dificuldades no uso de lógica nebulosa para a classificação dos distúrbios, uma vez que esta não é precisa

nas fronteiras entre a sua distorção harmônica total e sua energia, empregadas como dados de entrada. Desse modo, o trabalho de Saikia, Borah e Pait (2010) empregou também RNAs para a classificação dos distúrbios, apresentando também como entradas a distorção harmônica total e a energia obtida por meio das Wavelets. Em termos de precisão, a lógica nebulosa apresentou um erro de 12% e as RNAs apresentaram um erro por volta de 5%.

Christy, Vedamani e Karthikeyan (2011) lembram que o interesse em QEE tem aumentado rapidamente, uma vez que uma baixa QEE causa muitos problemas nas cargas afetadas, como avarias, instabilidades, tempo de vida reduzido, e assim por diante. De acordo com os autores, tradicionalmente, a QEE vinha sendo avaliada por meio de inspeções visuais dos distúrbios presentes nos sinais, o que cria uma enorme quantidade de dados e conduz à muitas complicações. Portanto, eles reiteram que é desejável o desenvolvimento de métodos automáticos de detecção, identificação e análise dos vários distúrbios. Segundo Christy, Vedamani e Karthikeyan (2011), dentre as inúmeras técnicas investigadas para o tratamento dos distúrbios de QEE, as mais empregadas são a Fast Fourier Transform (FFT) e a STFT. Entretanto, para sinais não estacionários, a FFT e a STFT não são capazes de acompanhar as dinâmicas dos sinais apropriadamente, pois a FFT pode mostrar apenas a existência de certos componentes de frequência, enquanto a STFT é limitada a uma janela fixa. Christy, Vedamani e Karthikeyan (2011) afirmam que Wavelets têm sido empregadas, por vários anos, em áreas como compressão de imagens, acústica e vibrações mecânicas, e que, recentemente, vários trabalhos têm proposto o uso de Wavelets na análise de sinais de energia elétrica. Entretanto, eles mencionam que, embora a precisão das Wavelets seja significativa, o esforço computacional aumenta na medida em que aumentam os níveis de decomposição das mesmas. Para superar essas limitações, o trabalho de Christy, Vedamani e Karthikeyan (2011) propõe um novo método para detecção e classificação baseado nas assinaturas de energia das Wavelets e no método da mínima distância.

Kanirajan e Kumar (2015) afirmam que o desligamento de grandes cargas e a energização de grandes capacitores podem causar as elevações de tensão, enquanto que as faltas geram os afundamentos de tensão e interrupções. As distorções harmônicas e os notchings são causados devido ao uso de dispositivos comutadores de estado sólido e ou de cargas não lineares, como retificadores e inversores. A energização de transformadores ou capacitores pode causar transitórios. Flutuações de tensão podem ser causadas por fornos à arco e descargas atmosféricas podem levar aos picos de tensão. Segundo Kanirajan e Kumar (2015), esses distúrbios devem ser identificados a fim de se melhorar a qualidade dos SEPs, embora esta tarefa seja difícil, pois envolve uma grande variedade de categorias de distúrbios. Kanirajan e Kumar (2015) reiteram que a TW oferece uma excelente resolução tempofrequência, o que permite o uso da TW na análise de sinais com distúrbios, assim como na classificação de problemas de QEE com baixas e altas frequências. Os autores afirmam que, por meio da decomposição pela TW, é possível extrair informações importantes a fim de

se determinar o tipo de distúrbio presente nos sinais. Baseado em todas essas informações, Kanirajan e Kumar (2015) propuseram um classificador de distúrbios de QEE empregando a TW, a Particle Swarm Optimization (PSO) e as RBFNN. De acordo com os resultados de Kanirajan e Kumar (2015), seu classificador apresentou desempenho superior a outros classificadores como Feedforward Multilayer (FFML), LVQ, General Regression Neural Network (GRNN) and Probabilistic Neural Network (PNN).

### 3.3 A Compressão e a Descompressão dos Sinais

Santoso, Powers e Grady (1997) empregam a TW como técnica de compressão de dados relacionados a QEE. A técnica de compressão de Santoso, Powers e Grady (1997) é executada por meio da decomposição do sinal, separação dos coeficientes da TW por meio de limiares e reconstrução do sinal. Os autores descartam os coeficientes com valores inferiores ao limiar estabelecido e mantém àqueles com valores superiores, assim como suas localizações no tempo. O tamanho do arquivo de dados comprimido é de um sexto a um terço daquele dos dados originais. Portanto, segundo Santoso, Powers e Grady (1997), o custo relacionado ao armazenamento e transmissão dos dados são significativamente reduzidos. Santoso, Powers e Grady (1997) afirmam que monitores de QEE são utilizados a fim de se capturar uma vasta gama de fenômenos de distúrbios. Entretanto, o registro de apenas um distúrbio pode gerar um mega byte de dados. O volume de dados registrados cresce significativamente, o que leva a um alto custo no armazenamento desses dados. Portanto, a realização de uma correta compressão de dados é altamente desejada. Santoso, Powers e Grady (1997) ressaltam que técnicas de redução de dados são empregadas no monitoramento de distúrbios relacionados à QEE sobrescrevendo os dados mais recentes sobre os dados mais antigos. Desse modo, Santoso, Powers e Grady (1997) enfatizam a importância do uso de métodos de compressão de sinais no contexto da QEE. No trabalho, os autores efetuam a compressão por meio da TW, mantendo-se os coeficientes da TW relacionados com os distúrbios e descartando-se os coeficientes livres de distúrbios. Desse modo, apesar de alguma informação ser perdida, seus coeficientes estão relacionados aos distúrbios. Portanto, segundo Santoso, Powers e Grady (1997), a qualidade do sinal reconstruído é muito boa.

Hsieh, Huang e Huang (1998) empregam em seu trabalho Wavelets para a compressão de sinais contaminados por distúrbios relacionados à QEE. O framework proposto pelos autores se inicia com a extração das diferenças entre o sinal a ser comprimido e um sinal de referência. Em seguida, o sinal subtraído é então submetido à TW para sua compressão. Hsieh, Huang e Huang (1998) afirmam que, desse modo, o montante de dados sofre significativa redução e sua transmissão e armazenamento são aprimorados. Segundo os autores, a compressão de sinais elétricos tem fundamental importância, uma vez que o monitoramento e diagnóstico de distúrbios nos SEPs requerem que grandes montantes de

dados sejam analisados. Portanto, para reduzir o grande volume de dados sem sacrificar características importantes, técnicas de compressão de dados se tornaram uma alternativa viável. Segundo Hsieh, Huang e Huang (1998), a compressão dos dados por meio de seu framework permite a reconstrução do sinal original com uma pequena perda de informação. Para os autores validarem esse aspecto, o trabalho compara o sinal original com o sinal reconstruído para quantificar sua diferença. Hsieh, Huang e Huang (1998) afirmam que seu método é viável para o tratamento de problemas de QEE.

O trabalho de Littler e Morrow (1999) apresenta resultados comparativos empregandose Wavelets e a Transformada Wavelet Cosseno Discreta (TWCD) e examina a aplicação da compressão Wavelet no monitoramento da QEE para mitigar os custos de comunicação na transferência dos dados. Segundo Littler e Morrow (1999), apesar de o registrador digital efetuar análises diretas nos registros de faltas, frequentemente, os dados têm que ser transferidos através de um link de comunicação para uma localização central. Os autores afirmam, então, que diferentes técnicas de compressão podem ser empregadas durante o registro das faltas para redução do volume de dados necessários para transferência. Littler e Morrow (1999) afirmam que um pré-requisito útil para uma técnica de compressão é a habilidade de analisar os dados para se extrair informações relevantes e remover as redundâncias. De acordo com o trabalho de Littler e Morrow (1999), as Wavelets fornecem um método de pré-processamento para compressão de dados por meio da preservação da integridade das suas características e remoção de redundâncias para obter alta taxa de compressão com degradação controlada da fidelidade dos dados. Portanto, uma vez aplicada a TW, seus coeficientes são então comprimidos de forma mais efetiva por um métodos sem perdas, como Lempel-Ziv-Welch, Huffman ou código aritmético. Ainda segundo o trabalho de Littler e Morrow (1999), não se deve esperar que os métodos sem perdas produzam alta compressão com números binários randômicos. No entanto, efetuando-se um pré-processamento por meio de uma transformada (como Wavelets), altera-se o viés estatístico dos dados para melhorar sua compressibilidade. Os resultados da técnica de Littler e Morrow (1999) resultaram numa compressão para menos de 10% do tamanho original dos dados.

Panda et al. (2002) empregaram uma Transformada Wavelet Discreta Ortogonal (TWDO) com localização temporal aperfeiçoada para a compressão de sinais elétricos em seu trabalho. Panda et al. (2002) afirmam que oscilografias são mensuradas a uma elevada taxa de amostragem e seus dados são armazenados na memória de dispositivos. O volume de dados de corrente e tensão relacionados aos distúrbios elétricos é bastante elevada. Portanto, operações de compressão de tais dados são essenciais para seu armazenamento, sua transmissão e sua interpretação. A técnica de compressão de Panda et al. (2002) envolve uma transformada para extrair informações contidas nos dados e uma lógica para remover toda redundância presente nos mesmos. Os autores definiram a taxa de compressão como o número de dados originais pelo número de dados mantidos após a passagem de um

limiar. Quanto menor a taxa de compressão, mais fiel são os dados reconstruídos. Panda et al. (2002) concluem seu trabalho fazendo uma comparação da TWDO com as TWCD e Transformada Wavelet Discreta (TWD) na tarefa de compressão de dados de distúrbios em SEPs. Seus resultados demonstraram que a TWDO possui melhor desempenho do que as outras duas transformadas.

Segundo Hamid e Kawasaki (2002), o registro de um único distúrbio durante segundos por meio de instrumentos de monitoramento pode gerar megabytes de dados. Pode-se então inferir que o volume de dados gerados e mantidos durante o monitoramento de SEPs cresce significativamente, o que leva a altos custos de armazenamento e transmissão de dados. Portanto, conforme Hamid e Kawasaki (2002), é necessário o desenvolvimento de técnicas de compressão efetivas, as quais devem ter a capacidade de reduzir o volume de dados a serem armazenados e aumentar a velocidade de sua transmissão para um eficiente monitoramento remoto. Para isso, o trabalho de Hamid e Kawasaki (2002) introduz uma técnica de compressão por meio da TWD e da Transformada Wavelet Package (TWP), as quais são empregadas na decomposição dos sinais até um determinado nível, limiarização e reconstrução do sinal. Segundo os autores, a escolha de qual Wavelet será empregada na compressão é de suma importância, pois a Wavelet afeta a qualidade da reconstrução do sinal. Uma escolha inapropriada da Wavelet pode gerar distorções durante a reconstrução dos sinais e pode causar uma taxa de compressão não ótima. Embora hajam muitos tipos de Wavelets e uma Wavelet que seja ótima para uma sinal não ser necessariamente ótima para outro sinal, o trabalho de Hamid e Kawasaki (2002), se restringiu à análise das famílias de Wavelets Daubechies, Coiflets e Symlets com um determinado nível de decomposição. Adicionalmente, seu método de compressão baseado em Wavelets foi então combinado com codificação sem perdas, como Huffman, Lempel-Ziv-Welch ou Lempel-Ziv-Haruyasu para se obter uma compressão mais efetiva. Para a análise de desempenho das Wavelets, duas métricas foram empregadas. A primeira foi a taxa de compressão, e a segunda foi o erro quadrático médio percentual. Os resultados demonstraram que as duas transformadas possuem propriedades atrativas para compressão de sinais elétricos, embora seja necessário o uso da Wavelet apropriada para cada sinal. As taxas de compressão obtidas por meio da técnica empregada no trabalho de Hamid e Kawasaki (2002) apresentou uma taxa de compressão da ordem de 11%.

O trabalho de Meher, Pradhan e Panda (2004) apresenta uma abordagem para compressão de dados de QEE usando Transformada Wavelet Spline (TWS) e RNAs. O desempenho de sua abordagem é avaliado em termos da taxa de compressão, erro quadrático médio e percentual de energia retido nos sinais reconstruídos. Os eventos de afundamento, elevação e de interrupção de tensão, harmônicos e transitórios foram usados para avaliar o desempenho da abordagem proposta por Meher, Pradhan e Panda (2004). Segundo os autores, técnicas de compressão de dados são importantes, uma vez que, com o avanço dos equipamentos de monitoramento de SEPs o montante de dados acumulados

em tais sistemas se tornaram imensos. O grande montante de dados impõe problemas práticos de armazenamento e comunicação dos monitores com centrais de processamento. Os autores reiteram que técnicas de compressão envolvem a extração de características dos dados e uma lógica para remover a redundância presente nessas características. De acordo com Meher, Pradhan e Panda (2004), dentre a variedade de funções Wavelets a TWS é a melhor no que se refere a localização no tempo e quanto à propriedade de suavização. Os testes de Meher, Pradhan e Panda (2004) comparam seu método com técnicas chamadas por eles de convencionais que fazem uso de Transformada Wavelet Cosseno (TWC) e TWD. As RBFNN foram empregadas pelos autores na sua abordagem pois possuem vantagens sobre as redes neurais de múltiplas camadas tais como: maior precisão, menor tempo de treinamento, topologia simples e ausência de problema de mínimo local.

Ribeiro, Romano e Duque (2004) apresentam uma abordagem baseada no processamento de sinais adaptativos completos, o qual estima a componente sinusoidal fundamental do sinal separando-a dos transitórios. Segundo os autores, quando essas componentes não estacionárias são submetidas à técnicas de compressão por Wavelets, ocorre uma melhora na taxa de compressão. Adicionalmente, a perda de informações nos dados submetidos à compressão com perdas é minimizada. Segundo o trabalho de Ribeiro, Romano e Duque (2004), a modernização das indústrias e dos centros comerciais causou a instalação de novas cargas não lineares sensíveis à imperfeições, aumentando a importância da QEE. Desse modo, equipamentos de monitoramento devem ser usados para permitir a aplicação, no futuro, de técnicas apropriadas para mitigar problemas de QEE. Ribeiro, Romano e Duque (2004) reiteram que os equipamentos devem mensurar, analisar, armazenar e transmitir informações relativas à QEE dos SEPs por eles monitorados. Desse modo, uma das mais importantes características para avaliar a eficiência de tais equipamentos é sua capacidade de compressão, uma vez que o monitoramento demanda longos períodos de tempo armazenando dados e, consequentemente, grandes montantes de dados a serem transmitidos. Ribeiro, Romano e Duque (2004) afirmam que a escolha correta do método de compressão proporciona uso mais eficiente de canais de comunicação, enquanto aprimora a capacidade de armazenamento dos equipamentos de monitoramento. Nesse contexto, o método proposto por Ribeiro, Romano e Duque (2004), emprega técnicas de processamento de sinais adaptativos para realizar a estimação da componente senoidal fundamental permitindo seu cancelamento para, em seguida, efetuar a aplicação da TWD no sinal transitório restante. Três casos de transitórios são analisados para verificação do desempenho no método proposto no trabalho de Ribeiro, Romano e Duque (2004). O primeiro caso é o de notching, seguido pelo transitório oscilatório e por fim a distorção harmônica. Os resultados de Ribeiro, Romano e Duque (2004) demonstram que se o sinal transitório tem característica de banda estreita, representados no artigo pelo transitório oscilatório, a melhor solução obtida foi com um número maior de níveis de decomposição da TWD. Já os sinais com característica de banda larga, representada no artigo pelo

notching, apresentam melhor resultado com menor número de níveis de decomposição.

Segundo Ibrahim e Morcos (2005), armazenagem e comunicação de dados são o principal problema para as partes envolvidas com o monitoramento de SEP e com a QEE. Ibrahim e Morcos (2005) afirmam que o problema surgiu devido ao tremendo montante de dados envolvidos e que um desejo comum da indústria de QEE é de se encontrar novas técnicas para compressão e armazenamento de dados. O trabalho de Ibrahim e Morcos (2005) apresenta em detalhes uma técnica baseada em sistemas fuzzy para a compressão de dados baseada no fato de que os requisitos para se manter um sistema fuzzy são muito menores do que aqueles necessários para se manter os dados originais. O método proposto por Ibrahim e Morcos (2005) emprega o Sistema Adaptativo Neuro-Fuzzy (ANFIS) para a aprendizagem das curvas de onda das cargas e geração dos parâmetros fuzzy que podem, então, ser armazenados ou transmitidos. A compressão dos dados possui alta precisão e pouca ou nenhuma perda de informação.

Ribeiro et al. (2007) assumiram em seu trabalho que, no caso de curta duração, sinais elétricos podem ser modelados como a soma de três diferentes grupos de componentes: (1) a componente fundamental e as componentes harmônicas; (2) as inter-harmônicas e as componentes transitórias; e (3) os ruídos. Com base nesta consideração, o trabalho de Ribeiro et al. (2007) apresentou uma nova técnica de compressão de distúrbios elétricos intitulada método de codificação de transitórios, harmônicos e da fundamental. A técnica de Ribeiro et al. (2007) divide um sinal em sua fundamental determinística, em suas componentes harmônicas e em suas componentes não determinísticas, e aplica diferentes técnicas de codificação para cada grupo de sinais. Segundo Ribeiro et al. (2007), a compressão de dados de QEE tem carecido do desenvolvimento de algoritmos eficientes e de baixa complexidade para a detecção, classificação, compressão e a transmissão de eventos. Baseado em resultados simulados, pode-se ver que o método proposto supera todos os outros métodos quando aplicados na compressão de eventos de QEE. A melhora surge da combinação da subtração dos harmônicos da fundamental com os métodos de comprimento mínimo publicado por Ribeiro et al. (2007).

O trabalho de Gerek e Ece (2008) emprega algoritmos de compressão comerciais disponíveis em uma e duas dimensões (1D e 2D, respectivamente) com codificadores baseados em Wavelets utilizando exemplos de dados de distúrbios reais. Seus resultados preliminares indicam que a representação em 2D fornece uma significativa eficiência na compactação da energia. Gerek e Ece (2008) reiteram que o processamento e armazenamento de dados de QEE constitui um importante aspecto no projeto e desenvolvimento de dispositivos para a eliminação de problemas indesejáveis em SEPs. Segundo Gerek e Ece (2008), o processamento normalmente consiste na extração de características para detecção, localização e classificação de eventos relacionados à QEE. Uma vez detectado o evento em um trecho dos dados mensurados, o armazenamento desse trecho para análises futuras

originou uma aplicação importante de compressão. Os autores contribuem de forma original com o uso *codecs* disponíveis em 1D e 2D, originalmente empregados na compactação e descompactação de imagens e de áudio, para a compressão e armazenamento de dados de QEE. Os resultados de Gerek e Ece (2008) demonstraram que os métodos de compressão dos dados em 2D são melhores do que aqueles apresentados pelos métodos de compressão 1D. O trabalho de Gerek e Ece (2008) fornece, então, uma visão clara para a seleção de uma codificação que possa ser empregada na compressão de dados de QEE 2D.

Ning et al. (2011) propuseram em seu trabalho uma abordagem para a compressão de dados em Smart Grids (SG) baseada nas Wavelets. Segundo os autores, no futuro das SG, dados representando o estado de todos os níveis da rede serão gerados por sistemas de medição inteligentes, controles supervisionados e sistemas de aquisição de dados, além de outros dispositivos de monitoramento. Como fato, tem-se que o enorme montante de dados precisa circular e ser armazenado em centros de controle, concessionárias e consumidores em tempo real. Portanto, o uso de técnicas de compressão de dados será imprescindível para atenuar seu esforço de comunicação e armazenamento. Segundo Ning et al. (2011), os requisitos básicos para a compressão de dados são: os dados devem der comprimidos nos terminais de monitoramento antes de serem enviados; o processo de compressão dos dados deve manter as informações relevantes contidas nos dados originais; e os dados comprimidos devem ser reconstruídos para análise nos terminais de recebimento dos dados. Os autores afirmam que com a evolução das técnicas computacionais, os algoritmos de compressão de dados podem ser empregados em aplicações online. Desse modo, é possível embarcar algoritmos de compressão baseados em Wavelets nos dispositivos de monitoramento, cujos dados podem ser comprimidos antes de serem enviados, a fim de se atenuar o congestionamento de dados. Segundo Ning et al. (2011), seu método é capaz de comprimir, efetivamente, o tamanho dos dados de distúrbios ao mesmo tempo que diminui o ruído contido nos sinais. Portanto, seu método pode ser implementado em SG, para melhorar a qualidade da transmissão de dados.

Em sua tese, o autor, Angarita (2013), reitera a necessidade de minimizar os custos de armazenamento e transmissão de informações provenientes do monitoramento dos SEPs. Portanto, segundo o autor, a compressão de sinais de QEE é de suma importância para o contexto dos SG. Na tese, Angarita (2013) verificou a necessidade de abordagens de compressão de sinais específicas para os dados provenientes dos SEPs. O autor apresenta o estado da arte em compressão de sinais e propõe novas técnicas que possibilitam a compressão eficiente dos distúrbios de QEE. O autor apresenta as contribuições de sua tese na forma de três técnicas híbridas de compressão de sinais por meio da combinação eficiente de metodos de compressão de sinais com perdas e sem perdas, com enfoque na estratégia de alocação dinâmica de bits no domínio da transformada. Em sua primeira técnica, Angarita (2013) executa a alocação de bits segundo um conjunto de padrões vetoriais característicos de distribuição de energia. Na segunda técnica, foram utilizadas curvas de

padrões de estimação da distribuição de energia. Na terceira técnica proposta por Angarita (2013), foram identificadas e desagregadas as características comportamentais do regime permanente e do estado transitório para alocação de bits. Angarita (2013) afirma que suas técnicas priorizam a qualidade na reconstrução da forma de onda em detrimento da taxa (bits por amostra), embora outras abordagens efetuem o contrário. Em sua conclusão, Angarita (2013), descreve suas abordagens propostas como técnicas mais eficientes do que as encontradas na literatura correlata. Seus resultados são taxas de compressão entre 8:1 e 32:1 para o banco de sinais testado, com relação sinal ruído na faixa de 40 dB a 60 dB para sinais de tensão e na faixa de 40 dB a 50 dB para sinais de corrente. O autor compara o desempenho de suas três técnicas, relatando que, mesmo a técnica menos eficiente dentre elas, é superior aos métodos encontrados na literatura correlata. Segundo Angarita (2013), seus resultados indicaram que seus métodos propostos são capazes de obter taxas de compressão superiores a 8:1 com confiabilidade e robustez, sem o comprometimento da análise das formas de onda comprimidas, evitando erros de quantificação de parâmetros de QEE. Portanto, os resultados de Angarita (2013) demonstraram um bom desempenho quanto à taxa de compressão e quanto à fidelidade da forma de onda reconstruída. Sua comparação com métodos relevantes da literatura correlata demonstraram a superioridade das técnicas desenvolvidas.

Dapper et al. (2015) afirmam que os medidores empregados no monitoramento dos SEPs empregam métodos de agregação através de um processo de cálculo de médias dos parâmetros registrados por eles. Os autores reiteram que o uso desse método de agregação pode minimizar a gravidade de distúrbios de QEE ou até mesmo distúrbios podem não serem registrados. Segundo Dapper et al. (2015), uma solução para isso seria registrar as curvas de onda para uma posterior análise. Para isso, é necessária uma grande disponibilidade de memória, que causa um impacto significativo nos custos dos equipamentos. Desse modo, a memória de armazenamento deve ser utilizada da maneira mais eficiente possível. Dapper et al. (2015) constatam, então, que para reduzir a quantidade de memória requerida para os longos períodos de observação, é necessária a compressão das curvas registradas antes de seu armazenamento. Desse modo, Dapper et al. (2015) apresentam em seu trabalho uma abordagem para compressão de sinais de QEE composta por três passos. Primeiramente, os autores aplicam uma FFT no sinal. Em seguida, o sinal é aproximado por um algoritmo de aproximação polinomial de primeira ordem que causa uma compressão inicial com perdas no sinal e, por fim, é aplicado o método de compressão sem perdas Huffman Coding. A fim de analisar seu método de compressão, Dapper et al. (2015) o empregaram em 50 sinais obtidos das bases de dados do IEEE 1159.3 Task Force (1993). Segundo os autores, seu método oferece baixo custo computacional e alta taxa de compressão, e se comporta bem tanto para sinais estacionários como para sinais transitórios. Dapper et al. (2015) destacam que seu método tem uma vantagem significativa: ele evita o processo de separação dos sinais em suas componentes estacionárias

e transitórias antes de ser aplicada a compressão.

## 3.4 O Armazenamento dos Sinais

O trabalho de Lima, Lotufo e Minussi (2014) apresenta um sistema chamado de filtro passa normal para geração de uma base de dados em SEPs. Este filtro foi desenvolvido por Lima, Lotufo e Minussi (2014) com base em sistemas imunes artificiais de seleção negativa com o intuito de se determinar a presença de anormalidades. Quando uma anormalidade é detectada, o sistema registra o sinal anormal em uma base de dados. Segundo Lima, Lotufo e Minussi (2014), muitos investimentos estão sendo dedicados em um novo conceito de sistemas elétricos conhecido como SG. Esse novo conceito é baseado no uso intenso de tecnologias de automação, computação e comunicação para o monitoramento e controle de sistemas elétricos, a fim de se empregar novas estratégias de controle, proteção e otimização para melhorar a eficiência dos sistemas elétricos atuais. Lima, Lotufo e Minussi (2014) reiteram que a transformação dos SEPs para as SG deverá ser gradual. Segundo os autores, para se produzir bons resultados é necessário entender o comportamento dos SEPs. Esse conhecimento pode ser adquirido com os dados históricos dos SEPs armazenados em uma base de dados. Portanto, é primordial o uso de dispositivos empregados no monitoramento de SEPs. Entretanto, tais dispositivos não devem registrar continuamente, pois a base de dados resultante não seria utilizada de forma eficiente devido à grande quantidade de dados armazenados e devido ao fato de que esses dados não refletem as situações em que efetivamente ocorreram perturbações na operação normal dos SEPs. Dessa forma, Lima, Lotufo e Minussi (2014) afirmam que o uso de um procedimento mais racional para criar essa base de dados se faz necessário. Esse procedimento deve apresentar uma menor quantidade de informações armazenadas e fornecer uma discriminação precisa dos distúrbios que tenham ocorrido. Essas características satisfazem um dos requisitos de operação dos sistemas elétricos no contexto das smart grids: a capacidade de analisar, processar e discriminar dados com o objetivo de armazenar apenas os dados efetivamente anormais. Lima, Lotufo e Minussi (2014) destacam que uma vez implementado esse procedimento, exemplos de faltas armazenadas na base de dados podem ser acessados possibilitando um estudo mais detalhado com o propósito de aumentar a qualidade da informação. Portanto, procedimentos eficientes de armazenamento de sinais com distúrbios elétricos em bases de dados são cada vez mais imprescindíveis, e o método proposto por Lima, Lotufo e Minussi (2014) apresenta resultados satisfatórios com alta capacidade de generalização, confiabilidade, precisão e esforço computacional.

## 3.5 Considerações Finais

É importante mencionar que a revisão bibliográfica para a pesquisa foi dinâmica, ou seja, na medida em que trabalhos de relevância foram publicados sobre os temas tratados, eles foram inseridos nessa seção.

O método de segmentação desenvolvido nesta pesquisa será baseado em um limiar adaptativo empregando a TWD, uma vez que foi observado, por meio da literatura correlata, a sua capacidade de analisar um sinal, simultaneamente, no tempo e frequência, permitindo a detecção temporal de descontinuidades presentes.

O método de classificação adotado será baseado em um framework proposto na literatura correlata. A contribuição desta pesquisa pode então ser apontada pelo uso de AGs para a determinação das wavelets e RNAs mais adequadas a serem utilizadas na classificação dos sinais associados à QEE.

No que se refere à compressão de sinais, métodos propostos na literatura correlata serão adaptados e otimizados pelo *Non-dominated Sorting Genetic Algorithm II* (NSGA-II) para o contexto desta pesquisa.

Desse modo, a revisão bibliográfica foi de suma importância para identificação da relevância do tema QEE e dos materiais e métodos que poderiam ser empregados na pesquisa.

Também pode-se notar, tanto por meio dos primeiros trabalhos, quanto pelos trabalhos mais recentes consultados, que o tema tem se tornado cada vez mais importante devido ao crescente uso de cargas não lineares e devido ao advento das redes inteligentes, que exigirão um melhor e maior monitoramento do sistema elétrico como um todo, acarretando em um volume de dados considerável a ser analisado de forma eficiente e automática.

# Metodologia

## 4.1 Fluxograma Geral da Pesquisa

A Figura 8 apresenta, de forma resumida, a sequência de todas as principais etapas que fizeram parte desta pesquisa. Cabe frisar que a figura tem somente por objetivo, ilustrar e melhor detalhar as distintas etapas de desenvolvimento da pesquisa realizada.

Figura 8 – Sequência das principais etapas da pesquisa.

Fonte: Autoria própria.

Cabe colocar que uma etapa preliminar ao fluxograma apresentado na Figura 8, foi um estudo investigativo dos trabalhos técnico-científicos referentes à segmentação dos sinais, com enfoque naqueles que fazem uso da TW. Uma vez identificadas as informações relevantes sobre a segmentação dos sinais, a revisão bibliográfica procurou identificar as RNAs mais relevantes para a classificação de padrões e que poderiam ser empregadas de forma eficiente na classificação dos sinais já segmentados. O passo seguinte da revisão bibliográfica foi a identificação dos possíveis algoritmos evolutivos que poderiam ser empregados na busca da melhor configuração  $(TWD_1; TWD_2; PMC)$  a ser empregada na

classificação dos distúrbios em QEE. A sequência do trabalho de revisão bibliográfica foi voltada para a identificação dos possíveis algoritmos de compressão/descompressão que poderiam ser empregados nesta pesquisa, após a etapa de classificação dos distúrbios. O passo final da etapa de revisão bibliográfica passou a ser, então, a identificação de todos os recursos disponíveis para o armazenamento dos sinais e demais dados relevantes.

Como pode ser observado na Figura 8, a primeira etapa da pesquisa foi a aquisição dos dados, passando pela manipulação de dados sintéticos, por dados disponibilizados no website da IEEE 1159.3 Task Force (1993), e por algumas oscilografias mensuradas em subestações de distribuição de energia elétrica localizadas no interior do estado de São Paulo. Vale afirmar que a principal fonte de dados empregada foi a criação de uma base de dados composta por 1.400 padrões gerados sinteticamente por meio da implementação de um procedimento via o software Matlab Mathworks ©. Esta base de dados é composta tanto por distúrbios individuais (únicos), como combinados e simultâneos no contexto da QEE.

Uma vez obtidas as oscilografias dos sinais em análise (sintéticos ou reais), a segunda etapa da pesquisa foi o desenvolvimento do Algoritmo 1 adaptativo de segmentação dos sinais por meio de uma das Wavelets disponíveis na Wavelet toolbox do software Matlab Mathworks ©. Vale frisar que a escolha da Wavelet empregada no desenvolvimento desse algoritmo foi baseada nas informações obtidas durante a revisão bibliográfica, assim como nos resultados obtidos no processo de segmentação dos sinais sintéticos. Este algoritmo foi posteriormente refinado na etapa de classificação, quando da implementação do Algoritmo 2.

A terceira etapa da pesquisa foi a determinação e utilização das características mais apropriadas e extraídas da decomposição por *Wavelets* e que permitiriam uma classificação eficiente dos distúrbios contidos nos sinais já segmentados.

Na quarta etapa foi desenvolvido um algoritmo capaz de fazer a classificação dos sinais segmentados por meio de RNAs, cuja arquitetura foi definida de acordo com as informações obtidas sobre a classificação de padrões durante a etapa de revisão bibliográfica.

Ainda na quarta etapa, foram desenvolvidos os Algoritmos 2 e 3 que, baseados nas etapas anteriores, determinaram o conjunto  $(TWD_1; TWD_2; PMC)$  mais apto para as tarefas de segmentação, extração de características e classificação dos distúrbios de QEE. Para isso, foram empregados os recursos dos AEs indicados pela revisão bibliográfica e, dentre os quais, os AGs são os mais conhecidos.

A quinta etapa da pesquisa foi de desenvolvimento dos Algoritmos 4 e 5 para a determinação dos parâmetros (Limiar; *Wavelets*; Fator de Escala; Constante de Deslocamento; e Dicionário) mais eficientes para a compressão e descompressão dos sinais.

A sexta e última etapa da pesquisa foi a determinação do uso de arquivos do Matlab

4.2 Dados de Entrada 77

Mathworks © como possível forma de armazenamento dos sinais.

As seis etapas da pesquisa foram desenvolvidas de forma a caracterizar as contribuições citadas na Seção 1.3. Para isso, ferramentas matemáticas (*Wavelets*), de inteligência computacional (RNAs, AGs) e de compressão de sinais (*Huffman Coding*, *Arithmetic Coding* (SAYOOD, 2000; SALOMON; MOTTA, 2009)) foram empregadas de forma inovadora.

De uma maneira em geral, foram então implementados os Algoritmos (1, 2, 3, 4, 5) que combinaram essas ferramentas para a determinação de métodos eficientes para a segmentação, classificação e compressão de sinais com distúrbios associados à falta da QEE.

#### 4.2 Dados de Entrada

#### 4.2.1 Dados Gerados Sinteticamente

Para tornar possível o desenvolvimento deste trabalho, foi gerada uma base de dados sintéticos por meio de modelos matemáticos como apresentado nas Tabelas 1, 2 e ?? (ABDEL-GALIL et al., 2004; ABDEL-GALIL et al., 2005; HE; STARZYK, 2006; JANIK; LOBOS, 2006; UYAR; YILDIRIM; GENCOGLU, 2008; PANIGRAHI; PANDI, 2009; ERISTI; UCAR; DEMIR, 2010; HOOSHMAND; ENSHAEE, 2010; TAN; RAMA-CHANDARAMURTHY, 2010).

Essa base de dados é composta por 1.400 padrões de distúrbios, representando 14 classes, as quais foram divididas entre 800 padrões de distúrbios individuais (afundamentos, elevações e interrupções de tensão; transitórios; distorções harmônicas; flutuações de tensão e notching) (Tabela 1), e 600 padrões de distúrbios combinados (afundamento de tensão com flicker, elevação de tensão com flicker, afundamento de tensão com distorção harmônica, elevação de tensão com distorção harmônica, transitório com elevação de tensão e transitório com afundamento de tensão) (Tabela 2).

#### 4.2.2 Dados do IEEE P1159.3

Pela força tarefa 1159.3 de 2003 do IEEE é recomendado o uso de um formato de arquivo adequado para a troca de medições relacionadas à QEE e dados de simulação de forma independente do fornecedor (IEEE Std 100-1992, 1993). Embora esse documento esteja incompleto, exemplos detalhados (arquivos de cabeçalho, exemplos de código fonte, sinais, etc.) relacionados à força tarefa 1159.3 podem ser encontrados em (IEEE 1159.3 Task Force, 1993).

Tabela 1 - Equações sintéticas dos distúrbios simples analisados.

Dist.	Equações	Parâmetros
Afundamento de tensão	$v(t) = \sqrt{2}v_n \sin(2\pi \times 50t + \varphi)[u(t - T_s) - u(t - T_e)]$	$0.1 \le V_n \le 0.9 \\ -\pi/4 \le \varphi \le \pi/4 \\ T_s = T, 2T,, 8T \\ T_e - T_s = T, 2T,, 9T$
Distorções Harmônicas	$v(t) = \sqrt{2}[\sin(2\pi \times 50t + \varphi) + \dots + \alpha_{2k}\sin(2\pi(2k)) \times (2k)]$	$-\pi \le \varphi \le \pi$ $DHT \ge 5\%$ $0.015 \le \alpha_{2k} \le 0.03$ $0.03 \le \alpha_{2k+1} \le 0.06$ $-\pi \le \varphi_{2k} \le \pi$ $-\pi \le \varphi_{2k+1} \le \pi$ $k = 1, 2,, 10$
Elevação de tensão	$v(t) = \sqrt{2}v_n \sin(2\pi \times 50t + \varphi)[u(t - T_s) - u(t - T_e)]$	$1.1 \le V_n \le 1.8 \\ -\pi/4 \le \varphi \le \pi/4 \\ T_s = T, 2T,, 8T \\ T_e - T_s = T, 2T,, 9T$
Flutuação de tensão	$v(t) = \sqrt{2}sin(2\pi \times 50t + \varphi)[1 + v_n sin(2\pi f_n t)]$	$0 \le \varphi \le 2\pi$ $0.05 \le v_n \le 0.1$ $8 \le f_n \le 25$
Interrupção de Flutuação de tensão tensão	$v(t) = \sqrt{2}v_n \sin(2\pi \times 50t + \varphi)[u(t - T_s) - u(t - T_e)]$	$0 \le V_n \le 0.1 \\ -\pi/4 \le \varphi \le \pi/4 \\ T_s = T, 2T,, 8T \\ T_e - T_s = T, 2T,, 9T$
Notching	$v(t) = \begin{cases} \sqrt{2}[sin(\omega t + \pi/6) + 0.5\rho sin(\omega t + 5\pi/6)] & k = 1, 7\\ \sqrt{2}[sin(\omega t + \pi/6) - 0.5\rho cos(\omega t)] & k = 3, 9\\ \sqrt{2}[sin(\omega t + \pi/6) - \rho sin(\omega t + \pi/6)] & 5, 11\\ \sqrt{2}sin(\omega t + \pi/6) & outros \end{cases}$	$\omega = 2\pi \times 50, \rho = 0.5$ $0 \le \alpha \le \pi/2, \mu < \alpha$ $\mu = \frac{36500 \times 2\pi/20000}{\sqrt{2} \times 460\rho sin(\alpha)}$ $\omega t \in \left[\alpha + \frac{k\pi}{6}, \alpha + \frac{k\pi}{6} + \mu\right]$
Transitório impulsivo	$v(t) = 1.11v_p(e^{-7.5 \times 10^2(t - T_s)} - e^{-3.44 \times 10^2(t - T_s)}) \times (u(t - T_s) - u(t - T_e))$	$0.2 \le v_p \le 1$ $T \le T_s \le 7T$ $T_e = T_s + 1ms$
Oscilatório transitório	$v(t) = \sqrt{2}sin(2\pi \times 50t) \times [1 + \sqrt{2}v_n e^{-\alpha(t-T_s)}sin(2\pi f_{n(t-T_s)} + \varphi)]$	$0.3 \le v_n \le 1$ $150 \le \alpha \le 1000$ $T_s = T, 2T,, 7T$ $300 \le f_n \le 900$ $0 \le \varphi \le 2\pi$

4.2 Dados de Entrada 79

Tabela 2 – Equações sintéticas dos distúrbios combinados analisados.

Dist.	Equações	Parâmetros
Afundamento de tensão com flutuação de tensão	$v(t) = \sqrt{2}sin(2\pi \times 50t)[v_{nf}sin(2\pi f_n t)] + \sqrt{2}v_{ns}sin(2\pi \times 50t + \varphi) \times [u(t - T_s) - u(t - T_e)]$	$300 \le f_n \le 900$ $0.05 \le v_{nf} \le 0.1$ $8 \le f_n \le 25$ $0.1 \le v_{ns} \le 0.9$ $-\pi/4 \le \varphi \le \pi/4$ $T_s = T, 2T,, 8T$ $T_e - T_s = T, 2T,, 9T$
Elevação de tensão com flutuação de tensão	$v(t) = \sqrt{2}sin(2\pi \times 50t)[v_{nf}sin(2\pi f_n t)] + \sqrt{2}v_{ns}sin(2\pi \times 50t + \varphi) \times [u(t - T_s) - u(t - T_e)]$	$300 \le f_n \le 900$ $0.05 \le v_{nf} \le 0.1$ $8 \le f_n \le 25$ $1.1 \le v_{ns} \le 1.8$ $-\pi/4 \le \varphi \le \pi/4$ $T_s = T, 2T,, 8T$ $T_e - T_s = T, 2T,, 9T$
Afundamento de tensão com distorções harmônicas	$v(t) = \sqrt{2}v_n[\sin(2\pi \times 50t + \varphi) + \dots + \alpha_{2k}\sin(2\pi(2k) \times 50t + \varphi_{2k}) + \alpha_{2k+1}\sin(2\pi(2k+1) \times 50t + \varphi_{2k+1}) + \dots][u(t-T_s) - u(t-T_e)]$	$\begin{array}{c} 0.1 \leq v_n \leq 0.9 \\ T_s = T, 2T,, 8T \\ T_e - T_s = T, 2T,, 9T \\ -\pi \leq \varphi \leq \pi, DHT \geq 5\% \\ 0.015 \leq \alpha_{2k} \leq 0.03 \\ 0.03 \leq v_{nt} \leq 1 \\ 0.1 \leq v_{ns} \leq 0.9 \\ -\pi \leq \varphi_{2k} \leq \pi \\ -\pi \leq \varphi_{2k+1} \leq \pi \\ k = 1, 2,, 10 \end{array}$
Elevação de tensão com distorções harmônicas	$v(t) = \sqrt{2}v_n[\sin(2\pi \times 50t + \varphi) + \dots + \alpha_{2k}\sin(2\pi(2k) \times 50t + \varphi_{2k}) + \alpha_{2k+1}\sin(2\pi(2k+1) \times 50t + \varphi_{2k+1}) + \dots][u(t-T_s) - u(t-T_e)]$	$1.1 \leq v_n \leq 1.8$ $T_s = T, 2T,, 8T$ $T_e - T_s = T, 2T,, 9T$ $-\pi \leq \varphi \leq \pi, DHT \geq 5\%$ $0.015 \leq \alpha_{2k} \leq 0.03$ $0.03 \leq v_{nt} \leq 1$ $0.1 \leq v_{ns} \leq 0.9$ $-\pi \leq \varphi_{2k} \leq \pi$ $-\pi \leq \varphi_{2k+1} \leq \pi$ $k = 1, 2,, 10$
Oscilatório transitório com elevação de tensão	$v(t) = \sqrt{2}sin(2\pi \times 50t)\sqrt{2}v_{nt}e^{-\alpha(t-T_{st})}sin(2\pi f_n(t-T_{st}) + \varphi_t) + \sqrt{2}v_{ns}sin(2\pi \times 50t + \varphi_s)[u(t-T_{ss}) - u(t-T_{es})]$	$0.3 \leq v_{nt} \leq 1$ $1.1 \leq v_{ns} \leq 1.8$ $0 \leq \varphi_t \leq 2\pi$ $-\pi/4 \leq \varphi_s \leq \pi/4$ $150 \leq \alpha \leq 1000$ $T_{ss} = T, 2T,, 8T$ $T_{es} - T_{ss} = T, 2T,, 9T$ $T_{st} = T,, (T_{es} - T_{ss}) - T$ $300 \leq f_n \leq 900$

Dist.	Equações	Parâmetros
Oscilatório transitório com afundamento de tensão	$v(t) = \sqrt{2}sin(2\pi \times 50t)\sqrt{2}v_{nt}e^{-\alpha(t-T_{st})}sin(2\pi f_n(t-T_{st}) + \varphi_t) + \sqrt{2}v_{ns}sin(2\pi \times 50t + \varphi_s)[u(t-T_{ss}) - u(t-T_{es})]$	$0.3 \leq v_{nt} \leq 1$ $0.1 \leq v_{ns} \leq 0.9$ $0 \leq \varphi_t \leq 2\pi$ $-\pi/4 \leq \varphi_s \leq \pi/4$ $150 \leq \alpha \leq 1000$ $T_{ss} = T, 2T,, 8T$ $T_{es} - T_{ss} = T, 2T,, 9T$ $T_{st} = T,, (T_{es} - T_{ss}) - T$ $300 \leq f_n \leq 900$

Dentre os arquivos da força tarefa 1159.3 de 2003 do IEEE, pode-se encontrar sinais de tensão a 60 Hz caracterizando distúrbios associados à falta de QEE, os quais também foram submetidos ao processo de segmentação e demais etapas desta pesquisa (classificação e compressão/descompressão dos dados), conforme será posteriormente apresentado.

#### 4.2.3 Oscilografias Reais Registradas

Também foram analisadas oscilografias registradas em subestações de distribuição de energia elétrica localizadas em cidades do interior do estado de São Paulo. Foram analisados trechos dessas oscilografias que apresentavam distúrbios de QEE como elevações de tensão, interrupções e transitórios impulsivos, entre outros.

## 4.3 Procedimento para a Classificação Geral dos Sinais

Em grande parte, a ocorrência dos distúrbios não pode ser prevista devido à sua natureza aleatória. Por conseguinte, os sistemas de monitorização têm de medir e registar continuamente a presença de qualquer anormalidade nos sinais de tensão e corrente. Entretanto, uma estratégia conhecida e usada na literatura correlata emprega a TW para a detecção de altas frequências nos sinais medidos (SANTOSO; POWERS; GRADY, 1994; POISSON; RIOUAL; MEUNIER, 1998; ZHANG; LIU; MALIK, 2003; VEGA et al., 2008; MAHMOUDI; HOSSEINIAN; DOROUDI, 2010; DWIVEDI; TIWARI, 2015). Essa detecção permite que seja feita a segmentação dos sinais medidos. Portanto, uma das ferramentas que integra o processo de segmentação dos distúrbios considerado nesta pesquisa emprega TW.

Normalmente, a quantidade de dados registrados pelos sistemas de monitorização é consideravelmente grande. Então, uma abordagem automática para analisar esses sinais deve reduzí-los a características baseadas em um processo conhecido como "extração de características". Esta tarefa é normalmente realizada pela aplicação da TW (SANTOSO et al., 2000; ELMITWALLY et al., 2001; HUANG; NEGNEVITSKY; NGUYEN, 2002;

## ZHU; TSO; LO, 2004; JANIK; LOBOS, 2006; REAZ et al., 2007).

As RNAs são normalmente responsáveis pela tarefa de classificação dos distúrbios (SANTOSO et al., 2000; HUANG; NEGNEVITSKY; NGUYEN, 2002; CHOONG; REAZ; MOHD-YASIN, 2005; REAZ et al., 2007; SAIKIA; BORAH; PAIT, 2010; KANIRAJAN; KUMAR, 2015). Elas foram utilizadas no caso das 14 classes sinteticamente geradas para esta pesquisa.

O framework usualmente empregado na classificação geral de distúrbios de QEE é apresentado na Figura 9. Esse framework foi utilizado em inúmeros trabalhos da literatura correlata (CHUNG et al., 1999; HSIEH; HUANG, 2003; HUANG; JOU, 2004a; LORIO; MAGNAGO, 2004; TCHEOU et al., 2014), assim como nesta pesquisa.

TW<sub>1</sub> Segmentação

TW<sub>2</sub> Extração de Características

RNA Classificação

Figura 9 – Framework para a classificação geral dos sinais.

Fonte: Autoria própria.

## 4.3.1 Segmentação dos Sinais

O processo de segmentação dos sinais é baseado na TW, uma vez que a sua capacidade de analisar um sinal, simultaneamente, no tempo e frequência, permite a detecção temporal de suas descontinuidades. A TW surgiu na década de 80 mas começou a ser empregada na solução de problemas de engenharia a partir da década de 90 (ADDISON, 2002). É importante mencionar que a TW pode ser empregada no modo contínuo ou discreto. No entanto, quando empregada na detecção e classificação de distúrbios relativos à qualidade de energia elétrica é frequente utilizar a TWD (OLESKOVICZ et al., 2009;

MORAVEJ; PAZOKI; ABDOOS, 2011). A TWD pode ser melhor compreendida através da Figura 10.

A Figura 10, ilustra a decomposição de um sinal discreto no tempo (sinal original). Sua saída são os coeficientes de detalhe (Detalhe 1) e de coeficientes de aproximação (Aproximação 1). Os coeficientes de aproximação armazenam as informações sobre os componentes de baixa frequência, enquanto os coeficientes de detalhes armazenam as informações de alta frequência. A transformada wavelet pode ser aplicada a um sinal repetidamente. Dessa forma o sinal é decomposto em vários níveis. Esses níveis são conhecidos como folhas da árvore de decomposição por wavelets.

Iniciando-se no nível 1 até o nível N, o sinal filtrado é decomposto em outros níveis a partir da folha de coeficientes de aproximação, onde o número de amostras é reduzida para metade (entre os coeficientes de aproximação e de detalhe) da folha pai. Este processo resulta na diminuição na resolução em tempo, mas proporciona um aumento na resolução em frequência. Esse aumento na resolução em frequência pode destacar as descontinuidades nos sinais, o que permite, no contexto desta pesquisa, a identificação de distúrbios relacionados à qualidade de energia elétrica.

Figura 10 – Exemplo ilustrativo da decomposição realizada pela TWD.

Fonte: Autoria própria.

### 4.3.1.1 Cálculo do Limiar Adaptativo

Cada um dos 1.400 padrões que formam a base de dados sintética leva em consideração parâmetros como duração, intensidade e localização dos distúrbios, determinados de forma aleatória, mas respeitando os limites indicados na literatura correlata (DUGAN et al., 2012). Assim, para cada um dos padrões analisados, foi calculado um limiar adaptativo

baseado na energia e na entropia da energia da curva de detalhes, do segundo nível da decomposição dos sinais aplicando a wavelet mãe da família Daubechies com suporte 6, com o intuito de que este limiar se ajustasse e permitisse a segmentação visando a posterior identificação dos trechos que contivessem os respectivos distúrbios.

Considerando que a energia total (En) é a soma quadrática de cada componente de cada folha de detalhe decomposta  $(d_j)$ , a energia percentual pode ser obtida pela Equação 4.1 (ZHENG-YOU; XIAOQING; GUOMING, 2006):

$$En(\%) = Energia = \sum_{j=1}^{N} (d_j)^2 \times 100.$$
 (4.1)

Já a entropia da energia de um dado nível de decomposição (Et) pode ser obtida conforme a Equação 4.2 (ZHENG-YOU; XIAOQING; GUOMING, 2006):

$$Et = Entropia = -\sum_{j=1}^{N} \left(\frac{d_j}{En} \times log \frac{d_j}{En}\right). \tag{4.2}$$

Das Equações 4.1 e 4.2, foi determinada de forma empírica (baseado no comportamento do limiar para os 1.400 padrões analisados) a Equação 4.3, que determina o limiar adaptativo empregado na segmentação dos sinais:

$$Limiar Adaptativo = |En^{3/5} \times Et|. \tag{4.3}$$

O valor da energia e, consequentemente, o valor da entropia da energia, estão diretamente relacionados com a intensidade de um determinado distúrbio (MAHMOUDI; HOSSEINIAN; DOROUDI, 2010), (ZHENG-YOU; XIAOQING; GUOMING, 2006). De forma a ilustrar tal comportamento, na Figura 11 é apresentado um gráfico que relaciona a amplitude com o valor do limiar adaptativo obtido para sinais que contêm afundamentos de tensão. Nota-se que, na medida em que o afundamento de tensão se torna mais severo, maior será o valor do limiar observado, justificando o uso de um limiar adaptativo.

A Figura 12 ilustra o comportamento que relaciona a amplitude com o valor do limiar adaptativo determinado para sinais que contêm oscilação transitória.

Assim como no caso dos afundamentos de tensão, o comportamento do limiar se ajusta conforme a intensidade dos transitórios oscilatórios (WANG; GAO; ZHU, 2006; TAN; RAMACHANDARAMURTHY, 2010), ou seja, quanto mais pronunciados forem os transitórios, maior será o valor do limiar observado.

Na sequência, com a intenção de demonstrar que o limiar adaptativo possui valores crescentes e que acompanham a severidade do distúrbio observado, a Figura 13 ilustra a

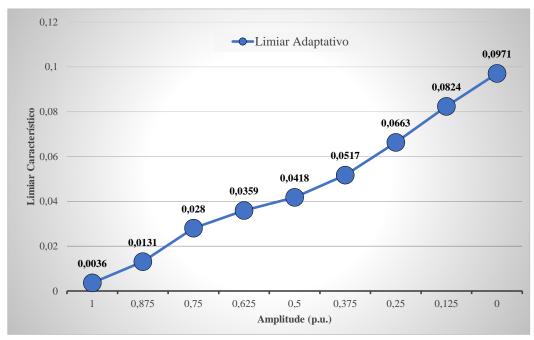


Figura 11 – Limiar característico baseado na severidade dos afundamentos de tensão.

Fonte: Autoria própria.

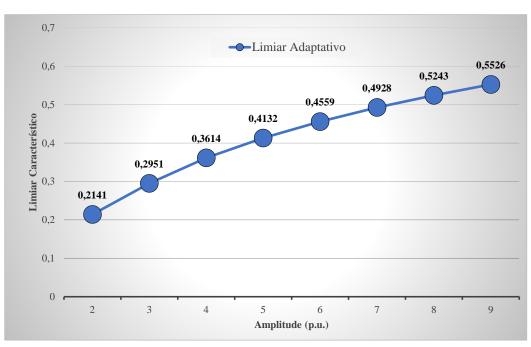


Figura 12 – Limiar característico baseado no comportamento dos sinais com oscilação transitória.

Fonte: Autoria própria.

relação entre a amplitude de sinais contendo componentes harmônicas e o limiar adaptativo calculado (WANG; GAO; ZHU, 2006; TAN; RAMACHANDARAMURTHY, 2010).

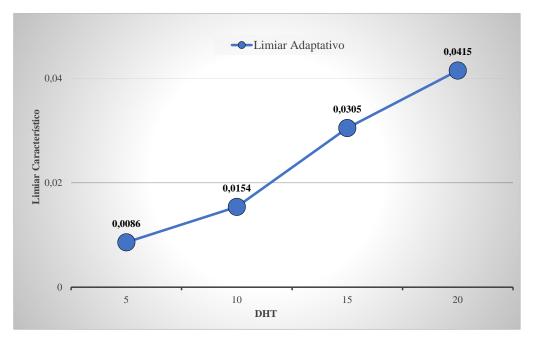


Figura 13 – Limiar característico baseado na DHT.

Fonte: Autoria própria.

Destaca-se que os demais distúrbios considerados nesta pesquisa também foram analisados seguindo o mesmo procedimento apresentado para os afundamentos de tensão, transitórios oscilatórios e distorções harmônicas, onde foi observado e comprovado que o valor da energia e o valor da entropia da energia estão diretamente relacionados com as respectivas intensidades.

Considerando a intensidade dos eventos e a definição de limiares que sejam pertinentes a cada situação (ou seja, a cada padrão em análise), foi possível garantir que houvesse intersecções entre os limiares adaptativos e os gráficos dos detalhes obtidos por meio da decomposição wavelet para todos os sinais analisados. Destas intersecções, têm-se, então, os pontos de início e fim dos distúrbios, como pode ser ilustrado nas Figuras 14 e 15.

Nota-se por meio da Figura 14 que os pontos inicial (0,05 segundos) e final (0,15 segundos) da ocorrência do *notching* são bem destacados no gráfico de segundo nível de decomposição. Assim, o limiar calculado (linha tracejada), conforme a Equação 4.3, permite a segmentação do sinal.

Já o gráfico da Figura 15, ilustra essa característica para o caso de distúrbios combinados de afundamento de tensão e distorção harmônica. Na medida em que o afundamento de tensão, ou os componentes harmônicos são mais severos, maior será o

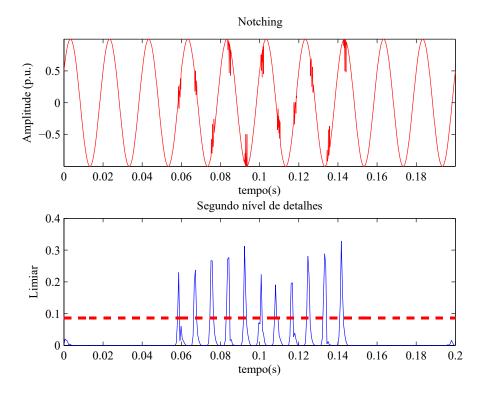


Figura 14 – Limiar adaptativo para sinais caracterizando o notching.

Fonte: Autoria própria.

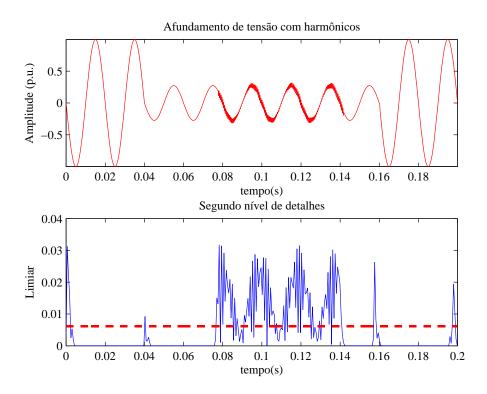
valor do limiar calculado, o que também justifica o seu uso adaptativo.

Pela Figura 15, os pontos inicial e final da ocorrência do afundamento de tensão (início em 0,04 (s) e final em 0,16 (s) e da distorção harmônica (início em 0,075 (s) e final em 0,145 (s)) são destacados no gráfico de segundo nível da decomposição wavelet. Uma vez que foi determinado um específico limiar (linha tracejada) para cruzar em tais pontos, pode-se segmentar o sinal de forma a separar os segmentos contendo os distúrbios das porções normais do mesmo.

É importante mencionar que, por meio da ferramenta *Mathworks Matlab* ©, distúrbios individuais e combinados foram gerados conforme encontrado em (WANG; GAO; ZHU, 2006; TAN; RAMACHANDARAMURTHY, 2010). Nas pesquisas citadas, os distúrbios estão contidos em sinais de no máximo 0,2 (s), 10 ciclos, com amplitudes entre -1 e 1 p.u. em regime permanente.

Durante a tarefa de segmentação dos distúrbios, foram analisadas as famílias Daubechies, pois, de acordo com (SANTOSO; POWERS; GRADY, 1994), estas são mais apropriadas para a identificação dos distúrbios em análise. Além disso, em (SANTOSO; POWERS; GRADY, 1994) é afirmado que as Daubechies com suporte 4 e 6 são mais indicadas para se detectar os distúrbios transitórios curtos e rápidos. Em contrapartida, as Daubechies 8 e 10 são mais eficazes para se detectar os transitórios lentos. Entretanto, os autores comentam que a determinação da wavelet mais apropriada ocorre sem que se

Figura 15 – Limiar adaptativo para a combinação de afundamentos com distorção harmônica.



Fonte: Autoria própria.

tenha um conhecimento prévio sobre quais são as características dos distúrbios que podem aparecer nos sinais, sendo essa uma tarefa desafiadora.

Neste sentido, para se determinar o comportamento do limiar adaptativo para cada um dos distúrbios analisados, foi considerada uma janela de duração total dos sinais sintéticos de 0,2 (s), 10 ciclos. Ademais, foram analisados os valores de intensidade característicos a cada situação, respeitando-se os limites indicados. Ou seja, para afundamentos de tensão a intensidade variou de 0,1 a 0,9 p.u., para as elevações de 1,1 a 1,8 p.u., para os transitórios, entre 0 p.u. a 8 p.u. e para as distorções harmônicas de 7% a 20% (DUGAN et al., 2012). Todos os sinais analisados foram amostrados a uma taxa de 128 pontos por ciclo, considerando a frequência fundamental de 60 Hz. A taxa de amostragem de 128 amostras por ciclo utilizada nesta pesquisa decorre de trabalhos anteriores dos autores (ANDRADE; OLESKOVICZ; FERNANDES, 2014).

Uma vez determinados os procedimentos para segmentação dos sinais, um algoritmo foi desenvolvido para o cálculo do limiar adaptativo. Os passos e as principais instruções implementadas podem ser seguidas conforme o Algoritmo 1 que é apresentado a seguir.

No Algoritmo 1, a instrução 2 consiste na leitura dos arquivos com os dados referentes aos distúrbios gerados. Na instrução 3 é feita a decomposição do sinal por meio da TWD, onde são extraídos os coeficientes para que a instrução 4 possa calcular sua

energia total. A instrução 5 calcula a entropia da energia, baseado na Equação 4.2. A sexta instrução representa o cálculo do limiar adaptativo, conforme a Equação 4.3. Por fim, a instrução 7 traça os gráficos, assim como apresentados nas Figuras 14 e 15.

Algoritmo 1: Algoritmo simplificado para a determinação do limiar adaptativo.

```
início
carregue os sinais com distúrbios;
decomponha os sinais com distúrbios;
calcule a energia total dos coeficientes, segundo a Equação 4.1;
calcule a entropia, segundo a Equação 4.2;
calcule o limiar (energiaTotal, entropia), segundo a equação 4.3;
trace os gráficos como ilustrado nas Figuras 14 e 15;
fim
```

#### 4.3.2 Determinação do melhor número de amostras por ciclo

O método de segmentação baseado no cálculo do limiar adaptativo e suas intersecções com a curva de detalhes via a decomposição pela TWD aplicando a wavelet mãe da família Daubechies com suporte 6, foi aplicado em sinais com taxas de amostragem de 64, 128 e 256 amostras por ciclo, considerando a frequência fundamental do sistema de 60 Hz, e com uma duração de 10 ciclos (ANDRADE; OLESKOVICZ; FERNANDES, 2014).

Durante a geração dos sinais foram registrados os pontos inicial e final dos distúrbios presentes em cada sinal, para que se pudesse comparar a localização real com a localização indicada pelo limiar adaptativo. Desse modo, também foi possível determinar o número de amostras mais indicado para o processo de segmentação (ANDRADE; OLESKOVICZ; FERNANDES, 2014).

No caso dos afundamentos de tensão, 9 sinais com diferentes amplitudes e taxas de amostragem foram analisados. Os resultados da segmentação podem ser visualizados por meio da Tabela 3. Cada uma das linhas apresenta o número de segmentos para afundamentos de tensão com amplitudes de 0,8 p.u. a 0,1 p.u..

A segunda coluna da Tabela 3 apresenta o número de segmentos esperado para os respectivos afundamentos de tensão, baseado nos parâmetros utilizados para a geração sintética dos distúrbios. As três últimas colunas apresentam o número de segmentos indicado pelo limiar adaptativo considerando as taxas de amostragens de 64, 128 e 256 amostras, respectivamente. Pode-se verificar que as taxas de 64 e 128 amostras por ciclo indicaram corretamente o número de 3 segmentos, esperados para os sinais com afundamentos de tensão analisados.

Afundamentos de tensão					
Amplitude (p.u.)	# Esperado de segmentos	# Segmentos (64 amostras)	# Segmentos (128 amostras)	# Segmentos (256 amostras)	
0,8	3	3	3	5	
0,7	3	3	3	5	
0,6	3	3	3	5	
0,5	3	3	3	5	
0,4	3	3	3	5	
0,3	3	3	3	5	
0,2	3	3	3	5	
0.1	3	3	3	5	

Tabela 3 – Número de segmentos para os afundamentos de tensão analisados.

Os resultados para a elevação de tensão são apresentados na Tabela 4. Pode-se verificar que o limiar adaptativo apresentou corretamente o número de segmentos esperados para todas as situações analisadas para as taxas de 128 e 256 amostras por ciclo.

Tabela 4 — Número de segmentos para as elevações de tensão analisadas.

Elevação de tensão					
Amplitude	# Esperado	# Segmentos	# Segmentos	# Segmentos	
(p.u.)	de segmentos	(64 amostras)	(128 amostras)	(256 amostras)	
1,1	3	3	3	3	
1,2	3	3	3	3	
1,3	3	3	3	3	
1,4	3	3	3	3	
1,5	3	3	3	3	
1,6	3	3	3	3	
1,7	3	5	3	3	

Os resultados para a interrupção de tensão são apresentados na Tabela 5. Pode-se verificar que o limiar adaptativo apresentou corretamente o número de segmentos esperados quando as taxas de 64 e 128 amostras por ciclo foram consideradas.

Tabela 5 – Número de segmentos para as interrupções de tensão analisadas.

Interrupções de tensão				
Amplitude (p.u.)	# Esperado de segmentos	# Segmentos (64 amostras)	# Segmentos (128 amostras)	# Segmentos (256 amostras)
0	3	3	3	3
0,01	3	3	3	5
0,02	3	3	3	5
0,03	3	3	3	5
0,04	3	3	3	5
0,05	3	3	3	5
0,06	3	3	3	5
0,07	3	3	3	5
0,08	3	3	3	5

A Tabela 6 apresenta os resultados da segmentação baseada no limiar adaptativo para as distorções harmônicas. Pode-se observar que não houveram intersecções do limiar com a curva de detalhes da decomposição pela TWD para a taxa com 64 amostras por ciclo. O limiar apresentou os resultados corretos para 128 amostras por ciclo, e voltou a apresentar resultados errôneos para 256 amostras por ciclo.

Distorção harmônica				
DHT (%)	# Esperado de segmentos	# Segmentos (64 amostras)	# Segmentos (128 amostras)	# Segmentos (256 amostras)
5%	3	sem interseções	3	3
10%	3	sem interseções	3	5
15%	3	sem interseções	3	5
20%	3	sem interseções	3	5

Tabela 6 – Número de segmentos para as distorções harmônicas analisadas.

Pode-se verificar pela Tabela 3, referente as taxas de amostragem de sinais com afundamento de tensão, que o limiar adaptativo apresentou o número correto de segmentos para 64 e 128 amostras por ciclo. No caso de sinais com elevação de tensão, apresentado na Tabela 4, os resultados foram corretos para taxas de amostragem de 128 e 256 amostras por ciclo. A Tabela 5 apresenta o número de segmentos para sinais com interrupção de tensão. Nesse caso o limiar apresentou o número correto de segmentos para 64 e 128 amostras por ciclo. Para o caso de distorção harmônica a única taxa de amostragem que apresentou o número correto de segmentos foi a de 128 amostras por ciclo.

Desse modo, pode-se concluir que a taxa de amostragem que demonstrou ser a mais adequada para segmentação dos sinais sintéticos em análise foi a de 128 amostras por ciclo. Portanto, para a continuidade da pesquisa foram considerados sinais com essa taxa de amostragem.

## 4.3.3 Extração de Características por meio de Wavelets

O estágio seguinte à segmentação realiza a extração de características dos sinais segmentados, onde várias características foram calculadas (ERISTI; UCAR; DEMIR, 2010; ERISTI et al., 2013). Seu conjunto inicial é formado por:

- 1. Número de amostras do distúrbio (N);
- 2. Valor RMS do sinal com o distúrbio, que determina a amplitude de um sinal de tensão ou corrente  $(s_j)$ (JARAMILLO; HEYDT; O'NEILL-CARRILLO, 2000) com

um número N de amostras,

$$RMS = \sqrt{\frac{1}{N} \sum_{j=1}^{N} s_j^2};$$
(4.4)

- 3. Energia total dos coeficientes de detalhes de 5 níveis de decomposição dos sinais por Wavelets  $(En_1, ..., En_5)$ , segundo a Equação 4.1;
- 4. Entropia da energia dos coeficientes de detalhes de 5 níveis de decomposição por Wavelets ( $Et_1, ..., Et_5$ ), segundo a Equação 4.2;
- 5. Média  $(\mu_d)$  dos coeficientes de detalhes  $(d_{ij})$  de 5 níveis de decomposição  $(M_1, ..., M_5)$ . Esta é uma das medidas mais comumente usadas para se determinar a tendência central de dados (TWYCROSS; SHIELDS, 2004a),

$$M_i = \mu_d = \frac{1}{N} \sum_{j=1}^{N} d_{ij}; \tag{4.5}$$

6. Desvio Padrão  $(SD_1, ..., SD_5)$ , que é a medida da dispersão de um conjunto de dados de sua média. Se os pontos de dados estiverem mais afastados da média, há um desvio maior dentro do conjunto de dados. O desvio padrão é calculado como a raiz quadrada da variância  $(\sigma_d)$ , determinando a variação entre cada ponto de dados em relação à média (TWYCROSS; SHIELDS, 2004b),

$$SD_i = \sqrt{\sigma_d} = \sqrt{\frac{1}{N} \sum_{j=1}^{N} (dij - \mu_d)^2};$$
 (4.6)

7. Kurtosis (K<sub>1</sub>,..., K<sub>5</sub>), que é uma medida que verifica se os dados apresentam outliers (valores atípicos) em relação a uma distribuição normal, ou seja, conjuntos de dados com alta curtose tendem a ter outliers (valores atípicos), enquanto que conjuntos de dados com baixa curtose tendem a não ter outliers (valores atípicos) (MARDIA, 1970),

$$K_{i} = \sqrt{\frac{N}{24}} \left\{ \frac{1}{N} \sum_{j=1}^{N} \left( \frac{d_{ij} - \mu_{d}}{\sigma_{d}} \right)^{4} - 3 \right\};$$
(4.7)

8. Skewness  $(Sk_1, ..., Sk_5)$ , é uma medida de simetria ou, mais precisamente, a falta de simetria. Uma distribuição, ou conjunto de dados, é simétrico, se parecer a mesma simetria à esquerda e à direita do ponto central (MARDIA, 1970),

$$Sk_i = \sqrt{\frac{1}{6N}} \sum_{i=1}^{N} \left(\frac{d_{ij} - \mu_d}{\sigma_d}\right)^3.$$
 (4.8)

## 4.3.4 Seleção de Atributos por meio do software WEKA

Na prática, considerar atributos irrelevantes ou redundantes para um conjunto de dados muitas vezes confunde algoritmos de aprendizado. O efeito negativo dos atributos redundantes e irrelevantes nos algoritmos de aprendizagem leva à execução de um estágio de seleção de atributos anteriores que tenta eliminá-los. A melhor maneira de selecionar os atributos mais relevantes é manualmente, com base em uma profunda compreensão do problema e o que cada atributo realmente significa. No entanto, esta abordagem pode ser impraticável em uma aplicação real, exigindo o uso de métodos automáticos. O desempenho e a velocidade dos algoritmos de aprendizagem são melhorados devido a uma redução da dimensionalidade dos dados por meio da remoção de atributos inadequados. A redução da dimensionalidade torna um sistema mais compacto e mais compreensível, com foco nas variáveis mais relevantes. Essas variáveis devem formar o menor subconjunto de atributos que serve para distinguir todas as instâncias unicamente (WITTEN; FRANK; HALL, 2011).

Em geral, a seleção de características é um problema multi-objetivo, uma vez que tem o objetivo de maximizar o desempenho da classificação e minimizar o número de atributos.

Um conjunto de dados pode conter várias características as quais podem ser altamente correlacionadas com outras características (no caso de duas características perfeitamente correlacionadas, apenas uma é suficiente para descrever os dados) (CHAN-DRASHEKAR; SAHIN, 2014). A ideia é eliminar as características redundantes, bem como as irrelevantes, e considerar um subconjunto de características altamente correlacionados com a classe, mas pouco correlacionadas entre si (WITTEN; FRANK; HALL, 2011). Embora uma característica seja irrelevante individualmente, ela pode tornar-se relevante no caso de trabalhar em conjunto com outras características, isto é, um subconjunto de características ótimo tem de ser um grupo de características complementares que representam as propriedades das classes para discriminá-las. O número de características em um conjunto de dados aumenta exponencialmente o tamanho do espaço de busca, impedindo uma pesquisa exaustiva (XUE; ZHANG; BROWNE, 2013).

A fim de superar esse problema, diferentes técnicas de seleção de características foram desenvolvidas usando critérios de seleção distintos e algoritmos de busca para avaliar e encontrar heuristicamente subconjuntos de características mais apropriadas.

As técnicas de seleção de características geralmente são divididas em três categorias (CHANDRASHEKAR; SAHIN, 2014):

1. Embedded - a seleção de características nesta técnica é intrínseca ao algoritmo de aprendizado, que simultaneamente aprende o classificador e escolhe um subconjunto

de características. A abordagem principal é incorporada diretamente no algoritmo responsável pela indução do modelo de classificação;

- 2. Wrapper as estratégias wrapper são executadas em uma etapa de pré-processamento de dados, e cada subconjunto é usado para avaliar um algoritmo de classificação. Um número de algoritmos de busca pode ser usado para encontrar os subconjuntos de variáveis que maximizam a função objetivo que determina o desempenho da classificação. Infelizmente, a pesquisa pode crescer exponencialmente para um maior número de características. O algoritmo de seleção começa com um conjunto vazio (ou conjunto completo) e adiciona recursos (ou remove recursos), até que o máximo da função objetivo seja obtido;
- 3. Filter os métodos baseados em filtros usam técnicas de ranqueamento variável, como o critério principal para selecionar variáveis por ordenação. Métodos de ranqueamento são usados devido à sua simplicidade e o sucesso é constatado em aplicações práticas. Um critério de classificação apropriado é usado para a pontuação das variáveis e um limiar é usado para remover as variáveis abaixo dele. Os métodos de ranqueamento são procedimentos de filtragem, uma vez que são aplicados antes da classificação para excluir as variáveis menos relevantes. A propriedade básica de uma única característica é conter informações úteis sobre as diferentes classes que formam os dados. Esta propriedade pode ser relevante quando fornece uma medida de sua utilidade na discriminação de diferentes classes.

Nesta pesquisa, para a seleção das características extraídas dos sinais foi adotada uma técnica simples, rápida e sofisticada. Tal técnica é denominada Information Gain Attribute Ranking (HALL; HOLMES, 2003) e é suportada pelo software Waikato Environment for Knowledge Analysis (WEKA) de mineração de dados (WITTEN; FRANK; HALL, 2011). O WEKA contém inúmeros algoritmos de aprendizagem e ferramentas de processamento de dados. Ele foi projetado para fornecer suporte extensivo para um processo completo de mineração de dados experimental, incluindo a preparação e visualização dos dados de entrada, esquemas de aprendizagem por avaliação estatística, exibindo o resultado de vários algoritmos de aprendizagem e ferramentas de processamento. Ele fornece métodos para pré e pós-processamento e para avaliar o resultado de esquemas de aprendizagem em um dado conjunto de dados. É possível pré-processar os dados, apresentá-los a um esquema de aprendizagem e analisar o resultado e seu desempenho. O WEKA inclui métodos para regressão, classificação, agrupamento e mineração por regras de associação. As ferramentas de mineração de dados, chamadas de filtros, são alguns dos mais valiosos recursos do WEKA (WITTEN; FRANK; HALL, 2011) e foram empregadas após nesta pesquisa a etapa de extração de características por Wavelets, a fim de selecionar as características mais relevantes, como dados de entrada para as RNAs.

O Information Gain Attribute Ranking implementado no WEKA é utilizado para avaliar as características individualmente e escolher a melhor. Esta técnica calcula a entropia de uma classe considerando a presença, ou ausência, de uma característica. A diminuição na entropia de uma classe reflete o ganho de informação sobre a classe fornecida por uma característica e é chamada Information Gain (HALL; HOLMES, 2003).

Cada característica tem uma probabilidade  $p(x_i)$ ,  $0 \le p(x_i) \le 1$ , e sua soma é  $sump(x_i) = 1$ . Se A é uma característica e C é a classe, as Equações 4.9 e 4.10 dão a entropia da classe antes e depois de se observar uma característica (HALL; HOLMES, 2003).

$$H(C) = -\sum_{c \in C} p(c) \log_2 p(c).$$
 (4.9)

$$H(C|A) = -\sum_{a \in A} p(a) \sum_{c \in C} p(c|a) \log_2 p(c|a).$$
(4.10)

A informação adicional sobre a classe fornecida pela característica é chamada de *Information Gain* e se baseia na diminuição no valor da entropia (HALL; HOLMES, 2003).

Uma pontuação é atribuída para cada característica  $A_i$  com base no ganho de informação (*Information Gain*) sobre a classe C dada uma característica:

$$IG_{i} = H(C) - H(C|A_{i})$$
  
=  $H(A_{i}) - H(A_{i}|C)$   
=  $H(A_{i}) + H(C) - H(A_{i}, C)$ . (4.11)

Uma vez determinada a técnica de seleção, todas as características extraídas foram apresentadas ao Information Gain Attribute Ranking disponível no WEKA e aquelas mais correlacionadas às 14 classes de distúrbios foram determinadas, a saber: número de amostras do distúrbio (N); valor eficaz do sinal com distúrbio (RMS); Energia  $(En_1)$  do primeiro nível de decomposição por Wavelets; Entropia  $(Et_1)$  do primeiro nível de decomposição; Desvio Padrão  $(SD_1)$  dos coeficientes do primeiro nível de Decomposição; e Entropia  $(Et_3)$  do terceiro nível de decomposição.

### 4.3.5 O Uso das RNAs para a Classificação dos Sinais

As 1.400 amostras de distúrbios foram preparadas para o treinamento de 14 RNAs, do tipo Perceptron Multicamadas (PMC), individualmente (uma RNA especializada na classificação para cada categoria de distúrbio de QEE em interesse). A RNA escolhida

para a tarefa de classificação dos sinais foi a PMC, uma vez que essa RNA permite a investigação de resultados para topologias que contém uma ou mais camadas intermediárias, que não são parte da entrada ou da saída da rede. Estes neurônios ocultos capacitam a PMC a aprender tarefas complexas extraindo progressivamente as características mais significativas dos padrões de entrada (HAYKIN, 2001). A habilidade das RNAs PMC de aprender por meio de treinamento supervisionado pôde ser utilizada, uma vez que eram, a priori, conhecidas as classes de distúrbios presentes nos sinais gerados sinteticamente.

O treinamento supervisionado das RNAs consiste na divisão do banco de dados geral em subconjuntos de treinamento (1.120 padrões ou 80%) e de teste (280 padrões ou 20%) (HAYKIN, 2001). Previamente ao treinamento das RNAs para a classificação dos afundamentos de tensão, por exemplo, as respostas desejadas tiveram suas saídas ajustadas para 1 (quando deviam indicar a situação de afundamento) e as amostras restantes foram ajustadas para 0, em caso contrário. Em seguida, o treinamento supervisionado e os testes foram executados para que o desempenho da classificação do afundamento de tensão pudesse ser determinado.

Para o caso de elevação de tensão, o mesmo processo foi realizado, sendo que agora as saídas desejadas para indicar a elevação de tensão foram ajustadas para 1 e, para as amostras restantes, o ajuste foi para 0. Na sequência, o treinamento supervisionado e os testes foram executados para determinar o desempenho para classificar as elevações de tensão.

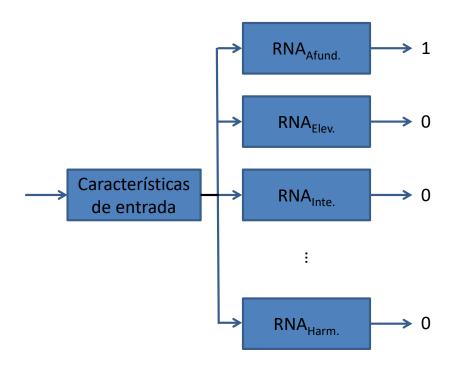
O mesmo método foi utilizado para todas as 14 categorias de distúrbios como ilustra a Figura 16. Fica então evidente a existência de uma RNA especificamente projetada para classificar cada distúrbio. Uma vez que uma entrada é apresentada ao esquema de RNAs, a RNA designada para classificar a categoria do distúrbio responderá como verdadeiro (1), e as outras RNAs responderão como falso (0).

A topologia mais adequada e indicada pela "Validação Cruzada" (HAYKIN, 2001) das PMC, empregada na classificação de cada um dos 14 distúrbios associados à falta de QEE, está representada na Figura 17. A PMC é formada pelas seis entradas selecionadas por meio do algoritmo *Information Gain Attribute Ranking*. Apresenta uma única camada intermediária com 10 neurônios e um único neurônio na sua camada de saída, que indicará a classe do distúrbio resultante. O algoritmo de aprendizagem de *Levenberg-Marquardt* (HAGAN; MENHAJ, 1994) foi adotado devido à sua característica de rápida convergência.

### 4.3.6 Otimização da Segmentação e Classificação dos Sinais

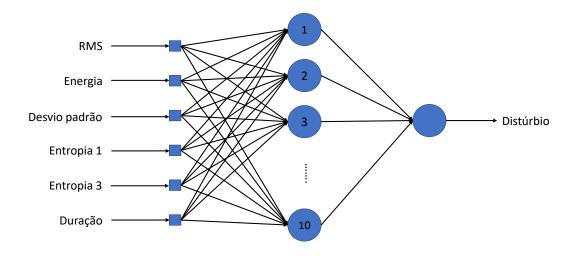
Um procedimento baseado na estratégia evolutiva de Algoritmo Genético (AG) foi desenvolvido para determinar o conjunto  $(TWD_1; TWD_2; PMC)$  mais apto à tarefa de

Figura 16 – As características de entrada direcionadas às 14 RNAs implementadas para a classificação dos distúrbios.



Fonte: Autoria própria.

Figura 17 – Topologia final das RNAs empregadas para a classificação dos distúrbios.



Fonte: Autoria própria.

segmentação dos distúrbios de QEE, extração das características e da classificação, como apresentado na Figura 9.

Foi gerado um espaço de busca de 8.192 conjuntos possíveis, cada um deles formado por duas Wavelets e uma RNA. As famílias de Wavelets consideradas no conjunto de indivíduos foram Haar, Daubechies, Coiflets, Symlets e Biorthogonal. As topologias consideradas têm uma (10, 20, 30 ou 40 neurônios) ou duas ([10 5], [20 10], [30 15] ou [40 20]) camadas ocultas.

Sua implementação foi realizada no *Matlab Matworks* © e seus procedimentos são apresentados de forma simplificada nos Algoritmos 2 e 3.

A segunda linha do Algoritmo 2 define o tamanho de 50 conjuntos como população inicial selecionados aleatoriamente a partir de 8.192 (32\*32\*8=8.192) conjuntos possíveis de 32 Wavelets com seus respectivos suportes para segmentação, 32 Wavelets com seus respectivos suportes para a extração de características e 8 RNAs compostas de 4 topologias com uma única camada oculta e 4 topologias com duas camadas ocultas.

A terceira linha define o número máximo de ciclos e número máximo de gerações que devem ser executados pelo algoritmo. Cada ciclo executa 50 gerações do AG. O indivíduo mais apto de cada ciclo (50 gerações) é selecionado e inserido no ciclo seguinte.

A linha 4 do algoritmo carrega os 1.400 sinais sintéticos da base de dados, apresentados na Seção 4.2.1. Os sinais são armazenados no formato *Mathworks Matlab* ©.

A linha 5 é responsável por repetir o algoritmo genético 50 vezes completamente para demonstrar a confiança de sua convergência (ciclos). O primeiro passo de cada ciclo gera uma população inicial de 50 indivíduos selecionados dos 8.192 conjuntos possíveis (linha 6). O segundo passo (linha 7) inclui, na população inicial, o indivíduo mais apto obtido no ciclo anterior. Este procedimento repete o AG com o indivíduo mais apto da geração anterior, incluído na população inicial, para cobrir de forma mais ampla o espaço de busca (8.192 conjuntos possíveis) e assegurar que o AG está convergindo para o mínimo global.

A linha 8 é o início dos procedimentos que formam a abordagem evolutiva inerente ao AG. Todas as linhas contidas nessa iteração são executadas até que a geração mais apta de conjuntos seja alcançada. A iteração da linha 11 contém a função responsável pela determinação da aptidão de todos os conjuntos, conforme descrito pelo Algoritmo simplificado 3.

Após a determinação da aptidão de todos os conjuntos, é possível selecionar o mais apto (linha 13), e registrar o menos apto (linha 14). A linha 15 executa uma abordagem que pode ser usada em AGs que consiste em selecionar um certo número de indivíduos mais aptos para a próxima geração. Esta abordagem é chamada "elitismo"e foi empregada

no AG desta pesquisa (JONG, 1988).

**Algoritmo 2:** O AG que determina os conjuntos  $(TWD_1; TWD_2; PMC)$  mais aptos.

```
1 início
      defina o número de conjuntos da população;
 2
      defina o número máximo de ciclos e gerações;
 3
      carregue os sinais com distúrbios;
 4
      enquanto houver ciclos faça
 5
         gere aleatoriamente a população de conjuntos;
 6
         inclua o conjunto mais apto da última geração;
         enquanto houver gerações faça
 8
             incremente o número de gerações;
 9
             enquanto houver conjuntos faça
10
                função AptidãoI [Alg. 3] de cada conjunto (sinais, conjunto atual);
11
             fim
12
             selecione o conjunto mais apto;
13
             selecione o conjunto menos apto;
14
             selecione, por elitismo, os conjuntos mais aptos para a próxima geração;
15
             calcule a aptidão relativa para todos os conjuntos;
16
             utilize o método de seleção da roleta dos conjuntos mais aptos;
17
             enquanto houver conjuntos mais aptos faça
18
                selecione os conjuntos mais aptos para o cruzamento;
19
                recombine os cromossomos dos conjuntos selecionados;
20
             fim
21
             aplique o operador de mutação genética;
             atualize a população de conjuntos;
23
             salve as variáveis atuais relevantes;
24
         fim
25
      fim
26
      salve as variáveis gerais relevantes;
27
28 fim
```

A linha 16 calcula a aptidão relativa para permitir o uso do método de seleção da roleta empregado na pesquisa. A iteração que começou na linha 18 contém os mecanismos que realizam o cruzamento entre os conjuntos mais aptos. O Cruzamento Uniforme é usado, como ilustrado na Figura 19, apresentada na página 101. Após estes procedimentos, o operador de mutação é aplicado a 1% dos conjuntos recombinados e a população para a próxima geração é determinada.

Em seguida, os valores das variáveis relevantes da iteração do AG atual são salvos em arquivo para fornecer informações sobre a execução do algoritmo. Após a última

geração, as variáveis relevantes de toda a execução do algoritmo são salvas também.

O Algoritmo 3 é uma função empregada no cálculo da aptidão de um conjunto  $(TWD_1; TWD_2; PMC)$  em relação a todos os 1.400 sinais. Na linha 3 começa a iteração para tratar todos os 14 distúrbios. Para cada um deles, há 100 amostras de sinais a serem segmentados (linha 5), submetidos à extração de características (linha 6) e classificados (linha 7). As instruções 8 e 9 são responsáveis em retornar quantos deles foram corretamente segmentados (nroS) e quantos foram corretamente classificados (nroC), respectivamente. O valor de aptidão do conjunto atual é calculado com base na correta segmentação e classificação, ou seja, nroF = nroS + nroC, de todos os sinais dos 14 distúrbios.

Algoritmo 3: Função que determina a aptidão dos conjuntos  $(TWD_1; TWD_2; PMC)$ 

```
1 função AptidãoI (sinais, conjunto atual);
2 início
3
      enquanto houver distúrbios faça
         enquanto houver sinais de cada distúrbio faça
4
             faça a segmentação do sinal;
5
             faça a extração de características;
6
             faça a classificação do distúrbio;
7
             calcule o número de sinais segmentados corretamente (nroS);
8
             calcule o número de sinais classificados corretamento (nroC);
9
         fim
10
         calcule a aptidão para cada distúrbio (nroF = nroS + nroC);
11
      fim
12
      retorna a média de todas aptidões;
13
14 fim
```

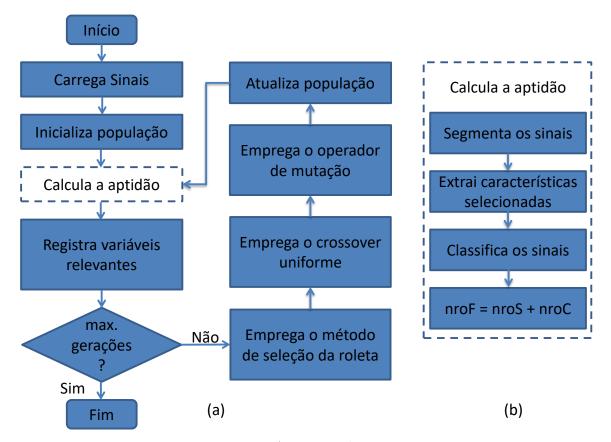
O AG desenvolvido é composto de cromossomos com 13 genes ou *bits*. Este valor foi determinado com base no espaço de busca formado pelos possíveis conjuntos considerados no AG ( $2^{13} = 8.192$ ).

Para um maior esclarecimento, a Figura 18 apresenta o fluxograma dos passos empregados no processo de determinação do conjunto  $(TWD_1; TWD_2; PMC)$  mais apto para segmentação, extração de características e classificação dos sinais com distúrbios de QEE. Pode-se notar que a parte (a) do fluxograma consiste basicamente dos passos que compõem a otimização por meio do AG. A parte (b) do fluxograma é dedicada a determinação da aptidão de cada um dos indivíduos que formam a população do AG. Essa parte do fluxograma consiste em quatro passos principais. O primeiro efetua a segmentação dos sinais formados pelos 1.400 sinais apresentados na Seção 4.2.1. O segundo passo faz a extração das características dos sinais previamente segmentados segundo o método descrito na Seção 4.3.3. O terceiro passo consiste na classificação das amostras geradas

pela extração das características. Esse passo empregou RNAs como classificador, segundo apresentado na Seção 4.3.5.

Uma vez que o cálculo das taxas de segmentação e classificação dos sinais não são conflitantes, não foi necessário o uso de AG multiobjetivo. A fórmula de determinação da aptidão dos indivíduos mais aptos, no quarto passo, consiste apenas da soma (nroF = nroS + nroC), onde nroS é a taxa de segmentação dos sinais e nroC é a taxa de classificação dos sinais.

Figura 18 – Fluxograma de determinação do conjunto  $(TWD_1; TWD_2; PMC)$  mais apto para a segmentação, extração de características e classificação dos sinais com distúrbios de QEE.



Fonte: Autoria própria.

## 4.3.6.1 Cruzamento Uniforme

O Cruzamento Uniforme foi empregado na determinação da geração seguinte dos conjuntos durante a execução do Algoritimo 2. Esse método de cruzamento supera as outras técnicas tradicionais em relação à capacidade de explorar o espaço de busca (ESHELMAN; CARUANA; SCHAFFER, 1989; SYSWERDA, 1989). Um número maior de conjuntos do espaço pode ser avaliado em uma sequência curta de gerações, o que também diminui o

número de avaliações para encontrar o ótimo global. Tal característica evita a amostragem de apenas alguns conjuntos do espaço de busca durante o cruzamento.

O Cruzamento Uniforme troca os bits de dois pais sob determinada probabilidade. No caso desta pesquisa, a probabilidade utilizada foi de 50%. Tal probabilidade significa que a chance de um filho receber um bit de cada um dos pais é a mesma (ESHELMAN; CARUANA; SCHAFFER, 1989; SYSWERDA, 1989). A Figura 19 ilustra um resultado da execução do Cruzamento Uniforme. No caso desta pesquisa, os cromossomos são formados por 13 bits (genes). O Algoritmo 2 seleciona dois indivíduos (pai 1 e pai 2) pelo método de seleção de roleta. Em seguida, o procedimento de Cruzamento Uniforme percorre os pais e transmite aleatoriamente seus bits para o filho 1 e filho 2. Conforme ilustrado na Figura 19, o primeiro bit do pai 1 foi transmitido para o filho 1 e o primeiro bit do pai 2 foi transmitido para o filho 2 e o segundo bit do pai 2 foi transmitido para o filho 1 e assim por diante. Lembrando que a probabilidade é de 50% para todos os genes (bits).

TWD1 TWD2 PMC

1 2 3 4 5 6 7 8 9 10 11 12 13

Pai 1

Pai 2

Filho 1

Filho 2

Figura 19 – Cruzamento uniforme empregado no AG.

Fonte: Autoria própria.

#### 4.4 Procedimento de Compressão dos Sinais

O objetivo em compressão de sinais é encontrar uma aproximação  $\hat{f}$  do sinal de interesse f, codificado em um montante de b bits, que minimize a distorção  $d(f,b) = ||f - \hat{f}||$  de acordo com uma métrica. A função da taxa de distorção D(s,b) (COVER; THOMAS, 2006) fornece um mapeamento monotônico entre o tamanho do sinal comprimido e sua fidelidade com a versão original do sinal (DUARTE et al., 2012).

A compressão de sinais pode ser obtida por meio da atribuição de descrições curtas para os valores mais frequentes de um sinal e descrições longas para os resultados menos frequentes de um sinal (DUARTE et al., 2012). Desse modo, pode-se obter um equilíbrio entre a taxa de compressão e a distorção, uma vez que essas duas entidades são conflitantes, como ilustrado na Figura 20.

Figura 20 – Busca de equilíbrio na compressão.



Fonte: Autoria própria.

Um dos frameworks mais conhecidos e empregados na compressão de sinais em QEE é apresentado, na sua forma adaptada ao problema de compressão dessa pesquisa, na Figura 21 (CHUNG et al., 1999; HSIEH; HUANG, 2003; HUANG; JOU, 2004a; LORIO; MAGNAGO, 2004; TCHEOU et al., 2014). Este framework adaptado para essa pesquisa é formado por 10 estágios:

- Entrada dos sinais que foram segmentados e classificados nos estágios anteriores da pesquisa. Foram segmentados e classificados 1.400 sinais formados por 14 distúrbios de acordo com o apresentado na Seção 4.2.1;
- 2. Decomposição dos sinais pela TWD para separar as baixas frequências das altas frequências. Esse processo é necessário para se determinar os valores mais relevantes (altas frequências) que deverão ser preservados para que a reconstrução dos sinais seja a mais próxima possível dos sinais originais;
- 3. Quantização dos sinais resultantes (baixas frequências e altas frequências) por meio de um limiar linear. Os valores do sinal decomposto pela TWD que ficaram abaixo do limiar de quantização são considerados irrelevantes e, portanto, são substituídos por 0 (zero) para que a taxa de compressão possa ser intensificada;
- 4. Aplicação de uma técnica de compressão sem perdas. No caso dessa pesquisa, foram empregadas as técnicas conhecidas por *Huffman Coding* e *Arithmetic Coding*. As duas técnicas foram, evidentemente, empregadas individualmente e foram usadas por serem amplamente empregadas pela literatura correlata (HUANG; JOU, 2004a; LORIO; MAGNAGO, 2004). Maiores informações são apresentadas nas Seções 4.4.2 e 4.4.3;

- 5. O passo seguinte seria o de transmissão do sinal (para o caso dessa pesquisa). Essa transmissão se dá no contexto apresentado na Seção 1.1. O processo de compressão, desse modo, minimiza o uso dos recursos de transmissão dos sinais e suas informações;
- 6. Ainda considerando o contexto apresentado na Seção 1.1, após sua compressão e transmissão, o sinal é armazenado em servidores de arquivos localizados, por exemplo, nas concessionárias de energia. O processo de compressão, desse modo, minimiza os custos de armazenamento dos sinais e suas informações;
- 7. Uma vez que os sinais estão armazenados em servidores centrais nas concessionárias de energia, suas informações podem ser resgatadas para análises em áreas específicas ou análises que englobem todo SEP. Isso permite, por exemplo, a prevenção e mitigação das consequências causadas pelos distúrbios de QEE;
- 8. O processo de descompressão do sinal se inicia então por meio da descompressão pelo mesmo método sem perdas empregado no passo 4. Desse modo as informações resgatadas dos servidores podem ser reconstruídas pelas wavelets;
- 9. Reconstrução dos sinais por meio da TWD inversa da empregada no passo 2. Os sinais decompostos que serão reconstruídos contêm modificações causadas pelo passo de quantização dos sinais. Essas modificações são responsáveis pelas distorções que estarão presentes no sinal a ser armazenado. A quantização é realizada para intensificar a compressão (aumentar a taxa de compressão), mas deve respeitar níveis de distorção aceitáveis que, no caso dessa pesquisa, são níveis indicados pela literatura correlata (SANTOSO; POWERS; GRADY, 1997; CHUNG et al., 1999; HSIEH; HUANG, 2003; HUANG; JOU, 2004a; LORIO; MAGNAGO, 2004; TCHEOU et al., 2014);
- O último passo é a disponibilização dos sinais e das suas informações para os funcionários das concessionárias de energia.

#### 4.4.1 Método de Quantização Linear

O método de quantização linear empregado durante a compressão dos sinais está ilustrado na Figura 22. Os sinais foram decompostos pela TWD Daubechies com suporte 6 até terceiro nível de detalhes. Em seguida, os valores menos significativos da curva, ou seja, aqueles que estão entre os limiares (linhas em vermelho) são substituídos por 0 (zero), formando uma região conhecida como "zona morta". Essa operação intensifica a compressão dos coeficientes da TWD, pois durante a compressão sem perdas esses valores são identificados por apenas um código no Huffman coding e apenas um intervalo no Arithmetic coding, como apresentado nas Seções 4.4.2 e 4.4.3, respectivamente.

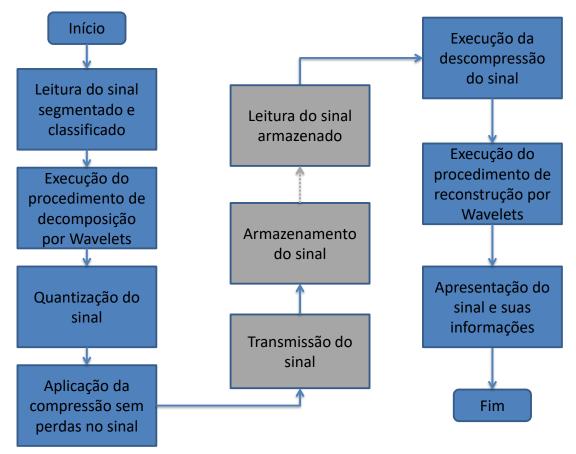


Figura 21 – Fluxograma do framework de compressão dos sinais.

Fonte: Baseado em Chung et al. (1999), Lorio e Magnago (2004).

Os valores acima ou abaixo dos limiares são mantidos, uma vez que são mais significativos, ou seja, representam as descontinuidades nos sinais de distúrbios de QEE.

## 4.4.2 Huffman Coding

Huffman coding é amplamente empregado na compressão de imagens e vídeos, e tem sido tema de intensivas pesquisas na área de compressão de dados. Uma dessas pesquisas provou que Huffman coding cria um código de tamanho mínimo no sentido de que nenhum outro código tem um comprimento médio menor (SALOMON; MOTTA, 2009). Seu código é ótimo, uma vez que símbolos que ocorrem mais frequentemente terão códigos mais curtos do que símbolos que ocorrem menos frequentemente (SAYOOD, 2000). Huffman coding tem uma única propriedade de decodificação, indicando que a informação decodificada através desse método pode ser expressa unicamente e sem ambiguidades.

No processo de codificação, uma árvore *Huffman* é desenvolvida e construída baseada na probabilidade de um evento (ou símbolo). Esta árvore é usada tanto pelo processo de codificação quanto pelo de decodificação. Depois de associar cada dado de entrada a uma folha com uma determinada probabilidade, cada folha pode ser concatenada,

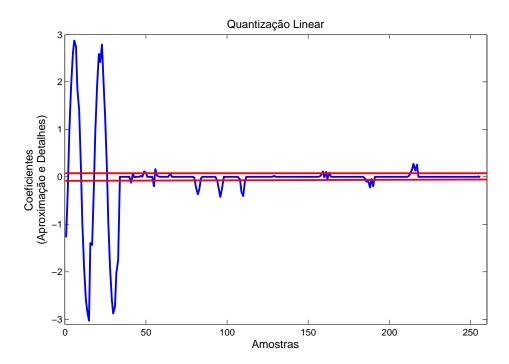


Figura 22 – Exemplo da Quantização Linear.

Fonte: Própria Autoria.

formando, assim, uma árvore por meio de 5 passos (HSIEH; HUANG, 2003):

- 1. Ordene os símbolos de acordo com sua probabilidade;
- 2. Atribua os valores 0 e 1 para os dois símbolos de entrada com a menor probabilidade;
- Adicione essas duas menores probabilidades e atribua seu resultado para o próximo símbolo de entrada;
- 4. repita os passos (1), (2) e (3) até que haja apenas dois símbolos restantes; e
- 5. Concatene todos símbolos de entrada nos passos anteriores, sequencialmente, a partir do último até voltar ao primeiro.

A codificação obtida por *Huffman coding* é ligeiramente maior do que a codificação da Entropia de *Shannon*, que trata da menor codificação possível (HSIEH; HUANG, 2003). Portanto, esse método pode ser considerado apropriado em problemas de QEE.

Todos os procedimentos de compressão de sinais dessa pesquisa foram desenvolvidos empregando-se as funções disponíveis na Communications System Toolbox do Matlab Mathworks ©.

## 4.4.3 Arithmetic Coding

Arithmetic coding não substitui um símbolo por um código específico, e sim, substitui símbolos de entrada por um único Tag (número fracionário). Quanto mais longa a entrada,

mais bits são necessários para representar esse Tag. A saída do algoritmo do Arithmetic coding é um único Tag entre 0 (zero) e 1 (um). Este único Tag pode decodificar unicamente e criar a entrada de símbolos usados para sua construção. A fim de se construir esse Tag, os símbolos a serem codificados devem estar associados a um conjunto de probabilidades. Uma vez que se conhecem essas probabilidades, os símbolos são individualmente associados a um intervalo entre 0 (zero) e 1 (um) (LORIO; MAGNAGO, 2004). As probabilidades são usadas para reduzir esse intervalo. Para se obter intervalos menores são necessários mais bits. Portanto, o Tag construído pelo algoritmo "cresce" constantemente (SALOMON; MOTTA, 2009).

Para se obter a compressão, o algoritmo foi projetado de tal forma que os símbolos com alta probabilidade reduzem o intervalo menos do que aqueles com baixa probabilidade. O resultado é que símbolos com alta probabilidade exigem menos bits para representar o único Tag de saída. Qualquer número pertencente ao último intervalo pode ser usado como Tag. Um escolha intuitiva é se adotar o valor central do intervalo (SAYOOD, 2000).

Pode-se definir o método de compressão de *Arithmetic coding* pela seguinte equação geral:

$$T(x_i) = \sum_{y < x_i} P(y) + \frac{1}{2} P(x_i)$$
 (4.12)

Onde  $T(x_i)$  é a Tag resultante;  $x_i$  é uma sequência de números reais a serem comprimidos; P(y) é a probabilidade de ocorrência de y e  $P(x_i)$  é a probabilidade de ocorrência de  $x_i$ . Dado que y < x significa que y precede x.

As seguintes regras resumem os principais passos do *Arithmetic coding* (HUANG; JOU, 2004a; SALOMON; MOTTA, 2009):

- 1. Defina o intervalo atual como [0,1);
- 2. Repita os dois passos seguintes para cada símbolo s de entrada:
  - a) Divida o intervalo atual em subintervalos de forma proporcional às probabilidades dos símbolos;
  - b) Selecione o subintervalo para s e o defina como o novo intervalo atual;
- 3. Assim que todos os símbolos de entrada forem processados, um único *Tag* (número fracionário pertencente ao último intervalo) os identifica.

Para cada símbolo processado, o intervalo atual fica menor, sendo necessário mais bits para representá-lo, mas a saída final é um único Tag, que não se trata de códigos que representam os símbolos individualmente.

# 4.4.4 Otimização da Compressão dos Sinais

A metodologia empregada para realizar a compressão de cada uma das 14 categorias de distúrbios é dividida em duas etapas principais: treinamento e teste.

Além da base de dados com 1.400 sinais descrita na Seção 4.2.1 foram gerados mais 1.400 sinais. A primeira base de 1.400 sinais de distúrbios foi empregada na primeira etapa. Esta etapa combinou o algoritmo de otimização multi-objetivo, conhecido por NSGA-II, com TWD e a compressão sem perdas para determinar os indivíduos mais aptos para a compressão. Cada indivíduo é formado por uma wavelet, um limiar, um fator de escala, uma constante de deslocamento e um dicionário. O segundo passo empregou os indivíduos mais aptos determinados no primeiro passo para executar a compressão do segundo conjunto de 1.400 sinais de distúrbios e calcular a taxa de compressão e a distorção para cada um desses indivíduos.

## 4.4.4.1 Treinamento para Determinação dos Indivíduos mais Aptos

Procedimentos baseados na estratégia evolutiva de AGs foram desenvolvidos para determinar o conjunto de indivíduos (limiar; *wavelet*; fator de escala; constante de deslocamento; dicionário;) mais aptos na tarefa de compressão de distúrbios de QEE.

Sua implementação foi feita no *Matlab Matworks* © e seus procedimentos são apresentados de forma simplificada nos Algoritmos 4 e 5. A Fronteira de Pareto (FP) gerada representa um conjunto válido de soluções para dois objetivos conflitantes como apresentado no início dessa seção, sendo os mesmos: maximizar a taxa de compressão e minimizar a distorção.

Foi gerado um espaço de busca de 2.368.000 indivíduos possíveis (37 wavelets, 50 limiares, 64 fatores de escala e 20 contantes de deslocamento). As famílias de Wavelets consideradas no conjunto de indivíduos foram Haar, Daubechies, Coiflets, Symlets e Biorthogonal.

Depois da determinação da quantidade das variáveis que gerariam o espaço de busca, a linha 9 do algoritmo NSGA-II (Algoritmo 4) implementado gera aleatoriamente 50 valores de limiares. Os limiares são empregados na quantização dos sinais decompostos pelas wavelets, como apresentado no fluxograma da Figura 21. A linha 10 gera os fatores de escala variando de  $2^7$  a  $2^9$ , que são multiplicados pelos sinais para que a operação de arredondamento modifique os sinais o mínimo possível. As constantes de deslocamento são geradas na linha 11. Elas são usadas no processo de reconstrução dos sinais e também para minimizar os efeitos da operação de arredondamento.

Algoritmo 4: NSGA-II para determinar o indivíduo mais apto:

(Limiar; Wavelet; FatorDeEscala; ConstanteDeDeslocamento;)

```
1 início
 2
      defina o número de limiares;
      defina o número de fatores de escala;
 3
      defina o número de constantes de deslocamento;
      defina o número de variáveis de decisão:
 5
      defina o número de funções objetivo;
 6
      defina o número total de gerações;
 7
      defina o número total de indivíduos na população;
 8
      gere os limiares;
 9
      gere os fatores de escala;
10
      gere as constantes de deslocamento;
11
      carregue as wavelets;
12
      carregue os sinais de treinamento com distúrbios;
13
      gere aleatoriamente a população de indivíduos;
14
      enquanto houver indivíduos faça
15
         função AptidãoII de cada indivíduo (sinais, indivíduo atual);
16
      fim
17
      ordene a população de indivíduos;
18
      enquanto houver gerações faça
19
         incremente o número de gerações;
20
          utilize o método de torneio para seleção dos indivíduos mais aptos;
21
         recombine os cromossomos dos indivíduos melhor ranqueados;
\mathbf{22}
         aplique o operador de mutação genética;
23
          enquanto houver indivíduos faça
24
             função AptidãoII de cada indivíduo (sinais de testes, indivíduo atual);
25
         fim
26
          agrupe pais e filhos;
         ordene a população de indivíduos;
28
      fim
29
      salve a população de indivíduos mais apta;
30
31 fim
```

A linha 12 do Algoritmo 4 carrega a lista de wavelets com seus respectivos suportes para serem empregadas na decomposição dos sinais com distúrbios e, em seguida, na linha 13, são carregados os sinais de treinamento que serão usados pelo NSGA-II. Após a criação do espaço de busca, o algoritmo gera aleatoriamente a população inicial de indivíduos. Essa população formará a FP no final da execução do NSGA-II com os indivíduos mais

aptos.

O algoritmo calcula no laço das linhas 15 a 17 a aptidão de cada indivíduo, segundo o Algoritmo 5. Após a determinação da aptidão de cada um dos indivíduos da geração inicial, o NSGA-II faz o ranqueamento dos indivíduos segundo o procedimento conhecido por Fast Nondominated Sorting Approach (DEB et al., 2002).

O laço principal (linhas 19 até 29) forma o AG que irá determinar, no final de sua execução, a FP formada pelas soluções ótimas com relação à taxa de compressão e à distorção, simultaneamente.

No algoritmo 4, empregado nessa pesquisa, foi utilizado um número fixo de 25 gerações, uma vez que foi observado durante as primeiras execuções do algoritmo que esse valor permitia a determinação da FP. O NSGA-II emprega o operador de seleção por torneio binário (DEB et al., 2002) para selecionar os indivíduos mais aptos para, em seguida, fazer a recombinação dos indivíduos empregando o método conhecido por Simulated Binary Crossover (SBX). O operador de Mutação Polinomial (MP) é, então, empregado em 10% dos indivíduos selecionados (DEB et al., 2002).

O procedimento que calcula a aptidão da nova geração de indivíduos (Algoritmo 5) é, então, chamado novamente sempre que se formar uma nova geração de indivíduos do AG.

O NSGA-II agrupa os indivíduos da geração atual com os da geração anterior para fazer o ranqueamento dos indivíduos que serão envolvidos no operador de seleção por torneio binário na próxima iteração do AG.

O Algoritmo 5 consiste na função empregada para determinação da aptidão (máxima taxa de compressão e mínima distorção) de cada indivíduo da geração atual do Algoritmo 4. Os parâmetros que são passados para o procedimento são os sinais com os distúrbios e os indivíduos (Limiar; *Wavelet*; Fator de escala; Constante de deslocamento).

O procedimento se inicia com a decomposição dos sinais que foram passados por parâmetro. Após sua decomposição, é feita a quantização dos coeficientes (aproximação e detalhes), criando uma zona morta com os valores não significativos dos coeficientes (próximos de zero). Essa quantização é a operação principal que gera a distorção no sinal resultante do processo de compressão. Um dos objetivos do NSGA-II é minimizar a distorção, ou seja, minimizar os efeitos da quantização.

Os métodos Huffman coding e Arithmetic coding disponíveis na Communications System Toolbox do Matlab Mathworks ©, fazem a compressão apenas de valores inteiros. Os sinais com os distúrbios estão entre -1 p.u. e 1 p.u., ou seja, é necessária uma operação de mudança de escala dos sinais antes de se fazer a compressão sem perdas. Para isso, no processo de otimização pelo NSGA-II, foi empregada uma variável de decisão chamada de Fator de Escala (FE). Essa variável é multiplicada pelo sinal, ampliando sua escala para

minimizar os efeitos da operação de arredondamento de cada um dos pontos que formam os sinais.

Para se fazer a operação de compressão sem perdas dos sinais é necessário gerar um dicionário. Esse dicionário será empregado na etapa de testes, sendo que cada um dos indivíduos mais aptos determinados pelo NSGA-II tem o seu respectivo dicionário gerado pelo Algoritmo 5.

A operação da linha 12 é a compressão sem perdas propriamente dita. Essa operação transforma o sinal com distúrbio em um código que está diretamente relacionado com o dicionário também gerado, que será salvo e utilizado na descompressão dos sinais. Esses dicionários têm que estar disponíveis para o processo de compressão e descompressão da etapa de testes que será descrita na Seção 4.4.4.2.

```
Algoritmo 5: Função que determina a aptidão dos indivíduos:
(Limiar; Wavelet; FatorDeEscala; ConstanteDeDeslocamento; Dicionário;)
```

```
1 função AptidãoII (sinais, indivíduo atual);
2 início
      faça a decomposição dos sinais segmentados;
 3
      faça a quantização dos sinais decompostos;
 4
      faça a multiplicação pelo FatorDeEscala;
 5
      faça o arredondamento dos sinais;
 6
      se Dicionário está vazio então
 7
         gere um novo Dicionário;
 8
      senão
 9
         use Dicionário;
10
      fim
11
      faça a compressão sem perda dos sinais arredondados;
12
      calcule a taxa de compressão;
13
      faça a descompressão dos sinais;
14
      faça a divisão pelo fatorDeEscala;
15
      faça a adição da ConstanteDeDeslocamento;
16
      faça a reconstrução dos sinais;
17
      calcule a distorção;
18
      retorna a taxa de compressão e a distorção;
19
20 fim
```

Na linha 13 já é possível calcular a taxa de compressão do sinal, que consiste em:

$$taxaDeCompressao = \frac{tamanhoDoSinalOriginal}{tamanhoDoCodigo}.$$
 (4.13)

A operação seguinte consiste na descompressão do sinal pelo mesmo método usado na compressão, e empregando-se o dicionário previamente gerado. O sinal é então dividido pela variável de decisão chamada de FE, empregada anteriormente à execução da compressão.

Uma das operações necessárias para realizar a compressão sem perdas dos sinais foi a de arredondamento dos coeficientes (aproximação e detalhes), uma vez que os procedimentos de *Huffman coding* e *Arithmetic coding* aceitam como entrada apenas valores inteiros. Essa operação introduziu um nova quantização no sinal. Os efeitos dessa quantização são amenizados com o uso da variável de decisão chamada de Constante de Deslocamento. Esse valor é adicionado ao sinal após o procedimento de divisão pelo FE.

A linha 17 aplica a inversa da TWD para a reconstrução do sinal de forma mais semelhante possível ao sinal original com os distúrbios. Esses sinais não são completamente iguais, uma vez que uma das funções objetivo é a minimização da distorção entre o sinal original s(n) e o sinal reconstruído  $\tilde{s}(n)$ , que foi determinada por meio do Normalized Mean Square Error (NMSE):

$$NMSE = \frac{\|s(n) - \tilde{s}(n)\|^2}{\|s(n)\|^2}.$$
(4.14)

A Figura 23, apresenta um fluxograma dividido nas partes (a) e (b). A parte (a) consiste nos passos que formam o método evolutivo do NSGA-II. A parte (b) consiste nos procedimentos empregados para o cálculo da aptidão dos indivíduos da população no NSGA-II. Uma vez que esse fluxograma reproduz os Algoritmos 4 e 5, maiores detalhes foram apresentados no início dessa seção (Seção 4.4.4.1).

## 4.4.4.2 Testes dos Indivíduos mais Aptos

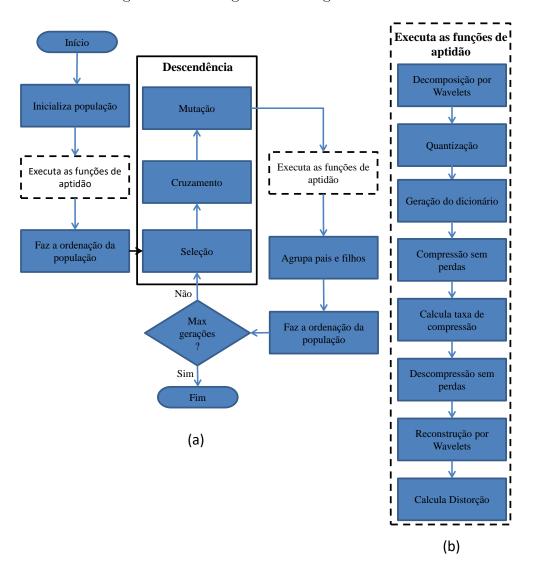
Uma vez determinados os indivíduos mais aptos (Limiar; Wavelet; Fator De Escala; Constante De Deslocamento; Dicionário) na etapa de treinamento, foi desenvolvido um novo algoritmo para testar sua eficiência (taxa de compressão X distorção) na tarefa de compressão de sinais distintos dos sinais utilizados na otimização pelo NSGA-II.

O Algoritmo 6 carrega novos sinais e os apresenta para os indivíduos mais aptos, que foram determinados durante o treinamento. É então feita a chamada do procedimento apresentado no Algoritmo 5 e efetuado o recálculo da taxa de compressão e da distorção. Os resultados obtidos são apresentados na Seção 5.4.1.

```
Algoritmo 6: Chamada da função de aptidão para os sinais de teste:
(LimiarMaisApto; WaveletMaisApta; FatorDeEscalaMaisApto;
ConstanteDeDeslocamentoMaisApto; Dicionário;)
```

```
início
carregue os sinais de testes com distúrbios;
enquanto houver indivíduos mais aptos faça
função AptidãoII de cada indivíduo (sinais de testes, indivíduo mais apto);
fim
salve taxa de compressão e distorção;
trace o gráfico com a FP (taxa de compressão X distorção);
fim
```

Figura 23 – Fluxograma dos Algoritmos 4 e 5.



# 4.4.4.3 Determinação do Melhor Indivíduo

Na etapa de treinamento foi determinado o conjunto de indivíduos mais aptos, ou o conjunto de possíveis soluções (FP I), considerando-se simultaneamente as duas funções objetivo do NSGA-II, taxa de compressão e distorção. Uma vez determinados esses indivíduos, eles foram empregados na compressão de sinais distintos daqueles utilizados durante os testes, formando um conjunto de soluções possíveis para compressão de novos sinais (FP II).

Uma vez determinado o conjunto de soluções para os novos sinais (FP II), foi necessária a determinação de um critério para a escolha de apenas um dos indivíduos, como aquele mais adequado para se determinar a taxa de compressão dos sinais. Baseado na literatura correlata, identificou-se que uma distorção aceitável para um processo de compressão de sinais de QEE é de um NMSE =  $1,0 \times 10^{-5}$  (SANTOSO; POWERS; GRADY, 1997; HSIEH; HUANG; HUANG, 1998; CHUNG et al., 1999; HUANG; JOU, 2004a; LORIO; MAGNAGO, 2004; TCHEOU et al., 2014). Portanto, o indivíduo mais adequado escolhido foi aquele cuja distorção ficou mais próxima desse valor, como ilustrado na Figura 24. A Tabela 9 (na página 137), apresenta os valores das taxas de compressão para cada um dos distúrbios em análise.

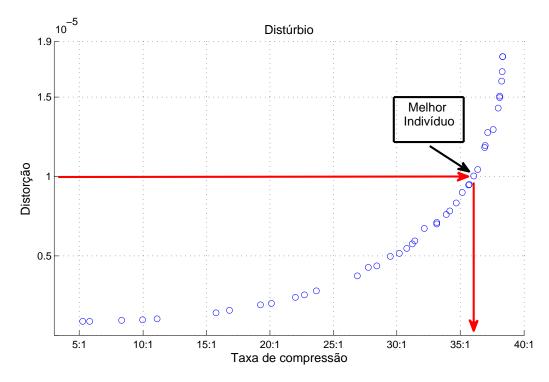


Figura 24 – Fronteira de Pareto (Melhor indivíduo).

# 4.5 Considerações Finais

Neste capítulo foram apresentados os materiais e os métodos empregados na pesquisa de doutorado como um todo. Foram apresentadas as ferramentas matemáticas e de sistemas inteligentes adotadas, assim como, de que forma as mesmas foram empregadas.

Tais ferramentas demonstraram eficiência nas soluções dos problemas como formulados. As equações utilizadas para a geração dos sinais sintéticos foram capazes de formar uma base de dados balanceada que pôde ser utilizada na continuidade da pesquisa.

As intersecções do limiar adaptativo com as curvas de detalhes da decomposição dos sinais pela TWD, permitiu a segmentação dos sinais analisados.

A otimização por AG permitiu a determinação eficiente dos materiais a serem empregados na segmentação  $(TWD_1)$  e classificação dos sinais analisados  $(TWD_2)$  e PMC).

O método de compressão adaptado daquele encontrado na literatura correlata pôde ser otimizado pelo NSGA-II, o que permitiu a determinação mais adequada dos seus parâmetros, como também o limiar empregado na quantização dos sinais, a wavelet mãe empregada na decomposição dos sinais, e o fator de escala e a constante de deslocamento, empregados na compressão sem perdas por Huffman coding e Arithmetic coding.

# Resultados

A princípio, o capítulo de resultados apresentará o comportamento do limiar adaptativo frente aos diversos distúrbios simples e múltiplos analisados. Posteriormente, serão apresentados os resultados dos métodos de segmentação e classificação dos sinais de forma empírica e otimizada. Por fim, o capítulo apresenta o desempenho do método de compressão e de descompressão proposto para os sinais gerados sinteticamente e os sinais reais.

## 5.1 Módulo de Segmentação dos Sinais

Nessa seção são apresentados exemplos dos resultados obtidos com a segmentação por meio de um limiar adaptativo, como apresentado na Seção 4.3.1.

## 5.1.1 Distúrbios Simples - Sinais Sintéticos

Após uma extensiva análise sobre os sinais sintéticos, constatou-se que a família de Wavelets do tipo Daubechies com suporte 6 apresentou os melhores resultados, pois exigiu menos níveis de decomposição com picos mais proeminentes nas curvas de detalhes. Com isto, as descontinuidades nos sinais foram ressaltadas e, por este motivo, esta família de Wavelets foi escolhida para realizar a segmentação dos sinais que contêm distúrbios simples, que é uma das propostas dessa pesquisa.

Para ilustrar o comportamento das curvas de detalhes da decomposição por Wavelets e o comportamento do correspondente limiar adaptativo para cada um dos distúrbios simples, são apresentadas as Figuras de 25 a 31.

Assim, a Figura 25 é utilizada para exemplificar o comportamento do limiar adaptativo para os 100 casos de flutuação de tensão (designada neste documento simplesmente por flicker) que foram gerados de forma sintética. Nota-se que a curva de detalhes apresentou picos proeminentes e que suas intersecções com o limiar adaptativo indicam de forma

eficiente os pontos de início e fim da flutuação de tensão (flicker).

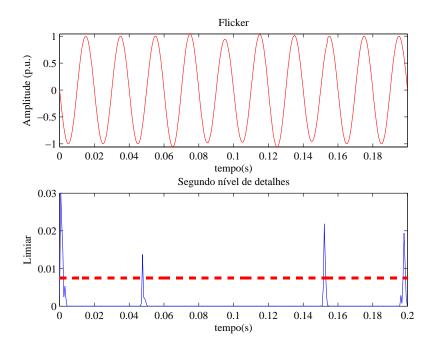


Figura 25 – Limiar adaptativo para um sinal com flicker.

Fonte: Autoria própria.

Pelos detalhes apresentados na Figura 26, é possível observar que a decomposição dos 100 sinais sintéticos que contêm distorções harmônicas exibe uma evidente mudança de comportamento durante a ocorrência do distúrbio. Desta forma, o limiar adaptativo gerado de acordo com a Equação 4.3 também permite identificar com clareza o início e o final desse tipo de distúrbio.

Assim como nos casos anteriormente citados, para a análise do comportamento do limiar adaptativo para sinais elétricos que contenham distúrbios de transitórios impulsivos e oscilatórios, também foram gerados 100 casos de cada situação. No entanto, o tempo de duração destes distúrbios é muito menor do que o tempo dos demais distúrbios analisados (DUGAN et al., 2012). Esse fato leva esses distúrbios a serem identificados e segmentados pela análise de um único pico que aparece no gráfico de detalhes da decomposição Wavelet, conforme pode ser observado nas Figuras 27 e 28.

As interrupções de tensão também foram analisadas segundo a abordagem proposta nesse trabalho. Ou seja, visando a identificação de um limiar que permita identificar o início e o fim desse distúrbio, foram analisados 100 casos de interrupções variando-se tanto a amplitude quanto a duração, respeitando os parâmetros indicados em Dugan et al. (2012). A Figura 29 ilustra o comportamento do limiar e da curva de detalhes cujas intersecções indicam os pontos inicial e final da interrupção.

Distorção Harmônica Amplitude (p.u.) 0.5 0 0 0.025 0.05 0.075 0.1 0.125 0.15 0.175 tempo(s) Segundo nível de detalhes 0.03 Limiar 0.02 0.01 0 0.025 0.175 0.05 0.15 0.2 tempo(s) Fonte: Autoria própria.

Figura 26 – Limiar adaptativo para um sinal com distorção harmônica.



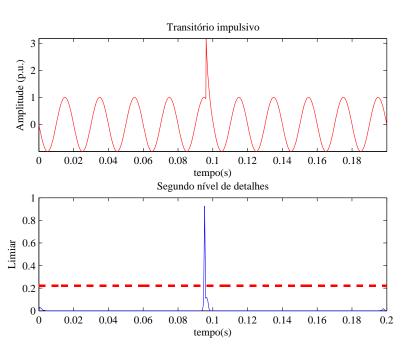


Figura 27 – Limiar adaptativo para um sinal com transitório impulsivo.

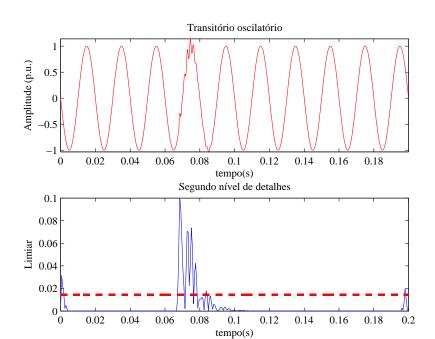
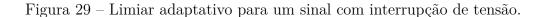
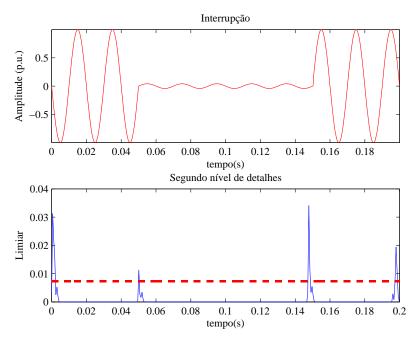


Figura 28 – Limiar adaptativo para um sinal com transitório oscilatório.



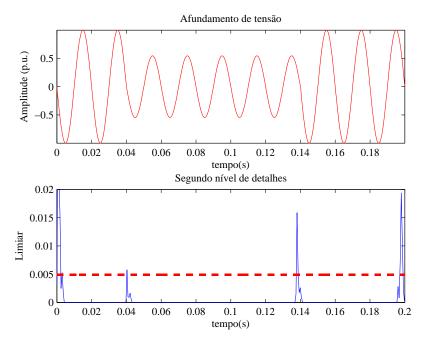


Fonte: Autoria própria.

Para os casos de afundamento e de elevação de tensão, foram analisados 100 casos para cada tipo de distúrbio, variando-se seus níveis de intensidade (DUGAN et al., 2012) e duração para se verificar o comportamento do limiar adaptativo. Para esses casos, o limiar adaptativo encontrado permitiu uma eficaz segmentação do sinal, pois suas intersecções

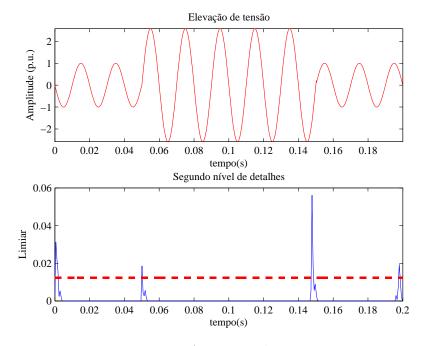
com a curva de detalhes indicaram os pontos inicial e final dos distúrbios, como pode ser constatado nas Figuras 30 e 31.

Figura 30 – Limiar adaptativo para um sinal com afundamento de tensão.



Fonte: Autoria própria.

Figura 31 – Limiar adaptativo para um sinal com elevação de tensão.



A Figura 32 ilustra o comportamento da curva de detalhes no caso da decomposição de um sinal com *Notching* por *wavelets Daubechies* com suporte 6. Pode-se observar que é possível identificar o ponto inicial e final desse tipo de distúrbio por meio da intersecção de sua curva de detalhes e do limiar adaptativo.

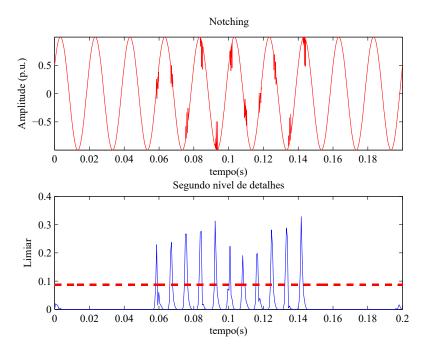


Figura 32 – Limiar adaptativo para um sinal com notching.

Fonte: Autoria própria.

### 5.1.2 Distúrbios Múltiplos - Sinais Sintéticos

Também foi analisado o comportamento do limiar adaptativo para o caso de sinais que contenham distúrbios combinados, ou seja, situações que contemplem mais de um distúrbio simultaneamente. Como nos casos anteriores, a família de *Wavelets Daubechies* de suporte 6 foi escolhida para a decomposição dos sinais sintéticos, uma vez que esta apresentou resultados mais promissores frente às situações analisadas empiricamente.

Para o caso de afundamento de tensão com *flicker*, foram analisados 100 casos onde houve uma combinação de distintos níveis de intensidade para ambos os distúrbios. Desta forma, foi possível verificar o comportamento do limiar adaptativo, o qual é ilustrado para um caso específico na Figura 33. Cabe informar que os níveis de intensidade foram variados, respeitando-se as características de duração e magnitude indicadas em Dugan et al. (2012). Novamente, para todos os casos analisados, o limiar adaptativo encontrado permitiu a segmentação do sinal de forma eficiente, detectando os pontos inicial e final dos distúrbios.

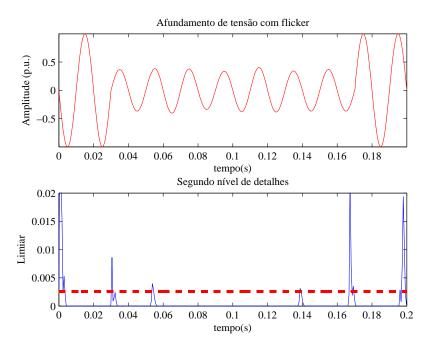


Figura 33 – Limiar adaptativo para um sinal com afundamento de tensão e flicker.

De forma similar, foram analisadas as elevações de tensão cuja ocorrência se dá de forma simultânea aos *flickers*. Em conformidade com os casos anteriores, também foram analisados 100 casos dessa combinação de distúrbios, onde a segmentação mostrouse bastante eficaz, possibilitando a detecção dos pontos inicial e final de cada um dos distúrbios, como pode ser visualizado na Figura 34.

As combinações de elevação de tensão com distorções harmônicas também foram analisadas segundo a abordagem proposta nesse trabalho, ou seja, visando a definição de um limiar adaptativo que permitisse identificar o início e o fim desses distúrbios. Neste sentido, foram analisados 100 casos sintéticos gerados em conformidade com os limites de magnitude e duração indicados em (DUGAN et al., 2012). A Figura 35 ilustra uma das combinações avaliadas e segmentadas. Todos os casos analisados apresentaram um limiar adaptativo cujas intersecções com as curvas de detalhes da decomposição Wavelet indicaram, corretamente, o início e fim de ocorrência dos distúrbios presentes no sinal.

Também foi investigado o comportamento de um limiar adaptativo para a ocorrência de afundamentos de tensão precedidos por transitórios oscilatórios, caracterizando uma ocorrência sequencial de distúrbios. Conforme pode ser observado na Figura 36, a decomposição por Wavelet gerou uma curva de detalhes cujos picos indicaram de forma eficaz tanto a localização temporal do fenômeno transitório, que coincide com o início do afundamento de tensão, quanto o final do mesmo. Os pontos de intersecção do limiar adaptativo com a curva de detalhes permitiu a segmentação correta dos casos investigados.

Elevação de tensão com flicker Amplitude (p.u.) 0.02 0.04 0.06 0.12 0.14 0.16 0.18 0.08 0.1 tempo(s) Segundo nível de detalhes 0.04 0.03

Figura 34 – Limiar adaptativo para um sinal com elevação de tensão e flicker.

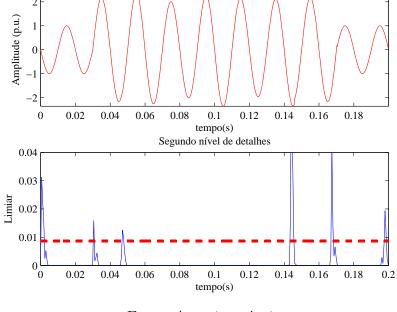


Figura 35 – Limiar adaptativo para um sinal com elevação de tensão e distorção harmônica.

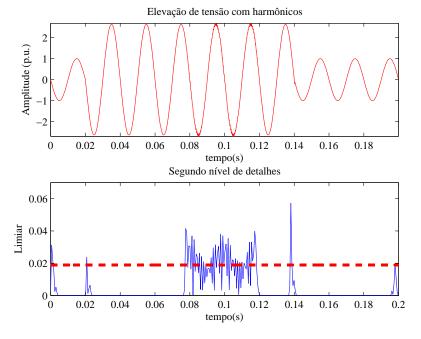
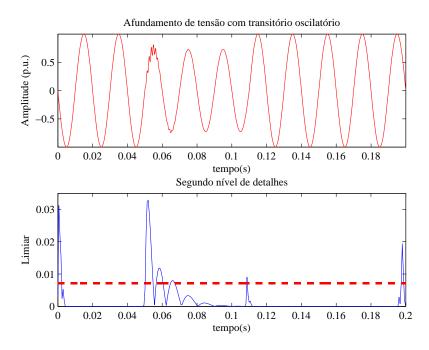


Figura 36 – Limiar adaptativo para um sinal com afundamento de tensão e transitório oscilatório.



Por fim, o comportamento do limiar adaptativo frente à combinação de elevações de tensão precedidas por transitórios oscilatórios também foi investigada nesta pesquisa. Assim como para todos os demais distúrbios combinados analisados, todos os 100 casos para este tipo de distúrbio combinado foram segmentados de forma eficiente, ou seja, o limiar adaptativo apresentou boas intersecções com a curva de detalhes da decomposição por Wavelet. Tal resultado está ilustrado na Figura 37.

O gráfico da Figura 38, ilustra o caso de distúrbios combinados de afundamento de tensão com distorção harmônica. Vale comentar que na medida em que se intensificam o afundamento de tensão, ou os componentes harmônicos, maior também será o valor do limiar adaptativo calculado.

## 5.1.3 Oscilografias Reais

Com a intenção de validar a metodologia proposta, aplicou-se a mesma à segmentação de oscilografias contidas em IEEE 1159.3 Task Force (1993) e também em oscilografias reais registradas em campo. É importante adiantar e ressaltar que esse método também foi empregado com sucesso na segmentação desses casos. Contudo, foi necessário adequar o suporte da família de Wavelets do tipo Daubechies para os casos das distorções harmônicas, transitórios oscilatórios e afundamento de tensão com transitório oscilatório. O limiar adaptativo baseado da Wavelet Daubechies com suporte 6 ficou abaixo de  $10^{-2}$  para esse

Figura 37 – Limiar adaptativo para um sinal com elevação de tensão e transitório oscilatório.

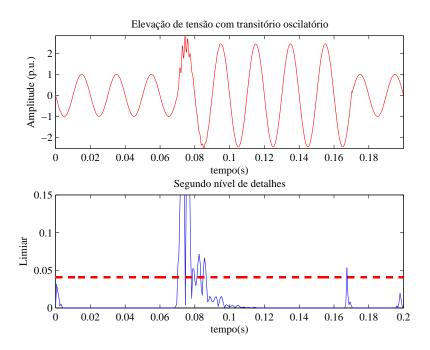
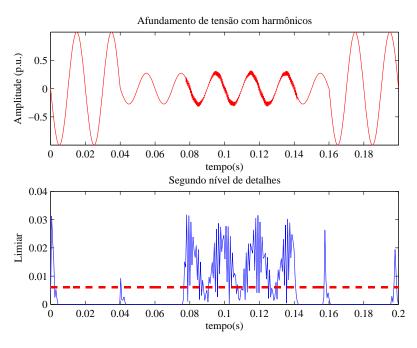


Figura 38 – Limiar adaptativo para um sinal com afundamento e distorção harmônica.



casos, resultando em indesejadas intersecções com as curvas de detalhes da TWD. Portanto, foi necessário mudar o suporte das Wavelet Daubechies para 2. Essa mudança no suporte das Wavelets Daubechies garantiu o uso do limiar adaptativo na identificação dos pontos inicial e final dos distúrbios por meio de suas intersecções com as curvas de detalhes obtidas pela TWD para esses distúrbios em específico.

É importante mencionar que para o caso das oscilografias reais, uma etapa de filtragem foi empregada para mitigar a presença de ruídos, onde, neste caso, foi utilizada uma Wavelet da família Symlets de suporte 8.

Portanto, o mesmo método de cálculo do limiar adaptativo baseado na Equação 4.3 foi empregado na segmentação e detecção dos pontos de início e fim da distorção harmônica presente no sinal ilustrado pela Figura 39, o qual fora obtido em IEEE 1159.3 Task Force (1993). Nota-se que o limiar adaptativo apresentou intersecções com a curva de detalhes da decomposição por Wavelets Daubechies de suporte 2.

Oscilograma com Harmônicos Amplitude (p.u.) 0.02 0.041 0.0622 0.083 0 tempo(s) Segundo nível de detalhes 0.08 0.06 0.04 0.02 0.041 0.0622 0.083 tempo(s)

Figura 39 – Limiar adaptativo para uma oscilografia com distorção harmônica.

Fonte: Autoria própria.

Já a Figura 40 caracteriza um evento com um transitório oscilatório. Tal oscilografia também foi obtida em IEEE 1159.3 Task Force (1993). Pode-se verificar que a intersecção do limiar adaptativo com a curva de detalhes da decomposição por Wavelets Daubechies de suporte 2 permitiu sua detecção temporal.

Conforme previamente comentado, a ocorrência de múltiplos eventos é, de certa forma, comum em SEPs. Assim, uma das oscilografias obtidas junto a IEEE 1159.3 Task Force (1993) apresenta a ocorrência de um evento transitório seguido de um afundamento

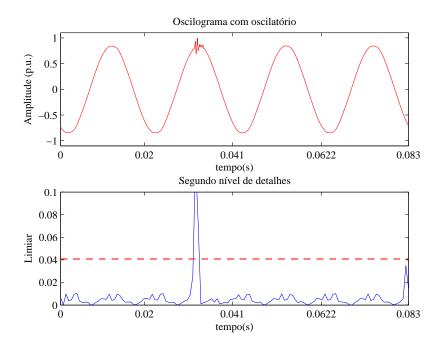
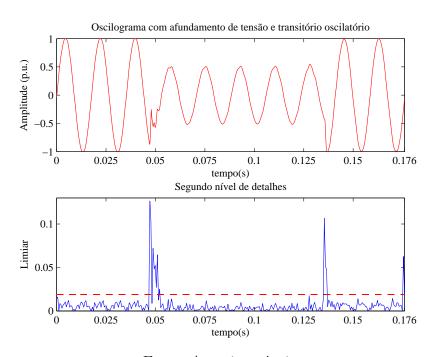


Figura 40 – Limiar adaptativo para uma oscilografia com transitório oscilatório.

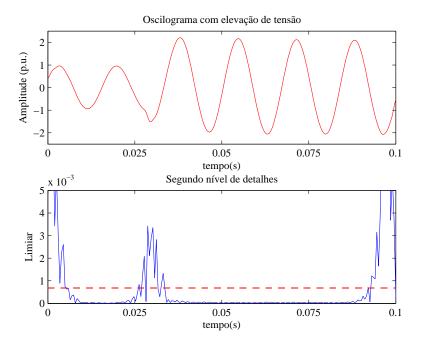
de tensão (Figura 41). Novamente, a metodologia proposta se mostrou eficiente quando aplicada a sinais obtidos em campo. Cabe comentar, que para esse caso, também foi empregada a família de *Wavelets* do tipo *Daubechies* com suporte 2.

Figura 41 – Limiar adaptativo para uma oscilografia com afundamento de tensão e transitório oscilatório.



Além dos distúrbios previamente citados, uma oscilografia obtida em IEEE 1159.3 Task Force (1993), apresentada na Figura 42, exibe a ocorrência de uma elevação de tensão, onde o limiar adaptativo apresentou uma eficiente detecção temporal para o início do distúrbio. Na decomposição desse distúrbio empregou-se a Wavelet Daubechies com suporte 6.

Figura 42 – Limiar adaptativo para uma oscilografia com elevação de tensão.



Fonte: Autoria própria.

Oscilografias contendo tanto interrupção de tensão quanto transitório impulsivo também foram obtidas por meio de medições realizadas em campo por uma concessionária de energia elétrica nacional. Nestes sinais, empregou-se a decomposição por *Wavelets* da família *Daubechies* com suporte 6. Assim, na Figura 43 é apresentado um exemplo de interrupção de tensão, e na Figura 44, de um transitório impulsivo. Nota-se que o limiar adaptativo permitiu identificar com sucesso a ocorrência dos distúrbios.

Figura 43 – Exemplo do limiar adaptativo para uma oscilografia com interrupção de tensão.

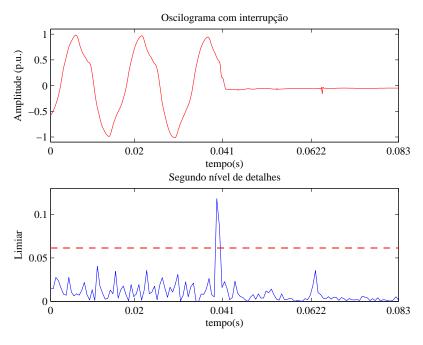
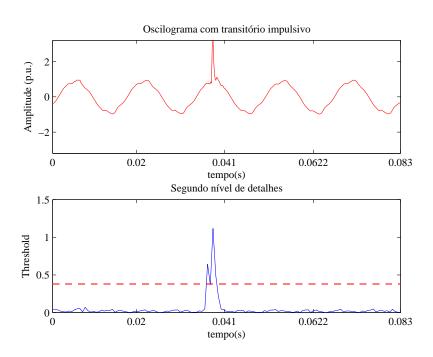


Figura 44 – Exemplo do limiar adaptativo para uma oscilografia com transitório impulsivo.



# 5.2 Módulo de Classificação dos Sinais

Para a classificação dos sinais foi primeiramente empregado o método empírico baseado na técnica de "Validação Cruzada" (HAYKIN, 2001). O treinamento supervisionado e os testes foram executados para que o desempenho da classificação de cada tipo de distúrbio fosse determinado individualmente. Foi projetado um esquema simples, mas eficiente, onde existe uma RNA dedicada à classificação de cada um dos distúrbios. Na Seção 4.3.5 foram apresentados detalhes do método empregado na classificação dos distúrbios.

### 5.2.1 Sinais Sintéticos

O treinamento supervisionado das RNAs consistiu na divisão dos dados sintéticos em subconjuntos de treinamento (1.120 padrões ou 80%) e de testes (280 padrões ou 20%) (HAYKIN, 2001). As RNAs foram organizadas para atuarem de forma dedicada a cada tipo de distúrbio a ser classificado. O desempenho das RNAs é apresentado no gráfico da Figura 46, na página 134, cujos valores são aqueles referentes à legenda de "Validação Cruzada". É importante mencionar que o desempenho médio na classificação dos distúrbios foi de 98,21%.

## 5.2.2 Oscilografias Reais

Os sinais reais, apresentados na Seção 5.1.3, também foram utilizados para a análise do método de classificação proposto.

O primeiro passo para classificação dos sinais é a sua segmentação. Na Seção 5.1.3 foram apresentados os gráficos ilustrando a correta identificação da posição dos distúrbios nos sinais reais analisados. Entretanto, pode-se notar que os sinais com elevação de tensão (Figura 42) e interrupção de tensão (Figura 43) apresentam uma descontinuidade característica identificando a posição inicial desses distúrbios, mas não apresenta qualquer descontinuidade que permita identificar o final desses distúrbios.

Essa característica fez com que o algoritmo segmentasse esse sinais como se tais distúrbios fossem oscilatórios transitórios, ou seja, distúrbios identificados apenas pelo ponto inicial. Na Seção 5.4.1.2 serão apresentadas as oscilografias de elevação de tensão e interrupção de tensão segmentadas.

Uma vez apresentados tais esclarecimentos, é possível verificar na Tabela 7 o resultado geral da classificação das oscilografias analisadas.

A primeira coluna da Tabela 7 apresenta a lista de distúrbios presentes nas oscilogra-

fias que foram analisadas. A primeira linha da Tabela 7 apresenta as classes de distúrbios em que o algoritmo proposto poderia classificar os eventos presentes nas oscilografias.

Pode-se notar que no caso das oscilografias de distorção harmônica (Harm.) e de transitórios oscilatórios (Tran. Osc.), o algoritmo classificou corretamente os distúrbios.

É importante verificar que o algoritmo classificou corretamente o caso de afundamento de tensão com oscilatório transitório, uma vez que a oscilografia disponível para análise apresenta as descontinuidades do ponto inicial e do ponto final desse distúrbio, como se pode verificar pela Figura 50.

Como já mencionado, o método proposto para a segmentação das oscilografias de elevação de tensão e interrupção de tensão identificou apenas o ponto inicial de ocorrência dos distúrbios, visto a inexistência do ponto final na oscilografia disponível para análise. Desse modo, o processo de classificação desses distúrbios identificou ambos erroneamente como transitório oscilatório.

No caso da oscilografia com transitório impulsivo o método de segmentação e posterior classificação funcionaram corretamente como apresentado na última linha da Tabela 7.

Distúrbios	Harm.	Tran. Osc.	Afund. Osc.	Elev.	Inter.	Tran. Imp.
Harm.	1	0	0	0	0	0
Tran. Osc.	0	1	0	0	0	0
Afund. Osc.	0	0	1	0	0	0
Elev.	0	<u>1</u>	0	0	0	0
Inter.	0	<u>1</u>	0	0	0	0
Tran. Imp.	0	0	0	0	0	1

Tabela 7 – Resultado geral da classificação das oscilografias reais.

# 5.3 Otimização da Segmentação e Classificação dos Sinais

Como apresentado na Seção 4.3.6, foi implementado um AG para a otimização da determinação do indivíduo mais apto para a fase de segmentação, extração de características e para a classificação dos sinais com distúrbios associados à QEE. Neste contexto, o seu desempenho pode agora ser comparado com as técnicas empíricas previamente apresentadas.

# 5.3.1 Análise do Desempenho do Método Otimizado para a Segmentação dos Sinais

O gráfico da Figura 45 apresenta uma forma de medida de desempenho do limiar adaptativo na tarefa de detecção temporal dos pontos iniciais e finais dos distúrbios gerados com base nos modelos paramétricos. Para tanto, realizou-se uma comparação entre os

pontos de início e fim (previamente conhecidos) dos distúrbios contidos nos sinais sintéticos com os pontos indicados pelo limiar adaptativo, ou seja, os pontos de intersecção com a curva de detalhes da decomposição *Wavelet*.

Analisando o gráfico, é possível observar que o mesmo apresenta duas barras para cada um dos tipos de distúrbios que compõem a base principal de dados (contendo 1.400 padrões) empregada neste trabalho.

O primeiro conjunto de barras (destacado em azul) está relacionado com o desempenho do limiar adaptativo na identificação dos pontos inicial e final dos distúrbios empregando-se a Wavelet Daubechies 6. Essa Wavelet foi escolhida, pois, nos testes empíricos realizados, a mesma apresentou os melhores resultados.

Já o segundo conjunto de barras (destacado em laranja), refere-se ao desempenho do limiar adaptativo na determinação dos pontos inicial e final dos distúrbios empregando-se a Wavelet Coiflets 2. Vale lembrar que essa Wavelet foi escolhida por meio de um AG como apresentado na Seção 4.3.6, e apresentou melhores resultados do que aquela determinada empiricamente.

Os valores associados às barras indicam o percentual de casos de distúrbios que tiveram seu início e final corretamente detectados pelo limiar adaptativo.

Para os afundamentos de tensão, a técnica do limiar adaptativo proposta foi 100% eficaz, tanto empregando-se a Wavelet Daubechies 6 por meio do método empírico, quanto pela Wavelet Coiflets 2 resultante do processo de otimização por AG.

No caso das distorções harmônicas, tanto o método empírico quanto da otimização por meio de um AG apresentaram o mesmo desempenho. Sua eficácia foi de 92% de acerto das posições inicial e final dos distúrbios em análise.

Em distúrbios combinados de distorção harmônica com afundamento de tensão ocorreu uma melhora significativa entre o desempenho do método empírico por Wavelet Daubechies 6 e a otimização por meio de AG, que determinou a Coiflets 2 como a Wavelet mais apta para segmentação dos sinais. Os desempenhos das Wavelets Daubechies 6 e da Wavelets Coiflets 2 foram de 90% e 94%, respectivamente.

Pode-se verificar pelos gráficos da Figura 45 que, no caso particular do distúrbio combinado de distorção harmônica com elevação de tensão, houve uma queda do percentual de acerto comparando-se o método empírico com o método otimizado por AG. Esse foi o único caso em que se identificou essa característica. Essa queda foi de 93% para 92% de acerto na determinação dos pontos inicial e final dessa combinação de distúrbios.

No caso de elevação de tensão, tanto para o caso da Wavelet Daubechies 6 quanto para o caso da Wavelet Coiflets 2, a taxa de acerto foi de 100% para determinação dos pontos inicial e final dos distúrbios observados.

O próximo distúrbio em que foi avaliado o desempenho do limiar adaptativo foi o de flutuação de tensão. Nesse caso, houve uma melhora de 1% da Wavelet Daubechies 6 para a Wavelet Coiflets 2.

Também houve uma melhora no desempenho do limiar adaptativo na segmentação da combinação de flutuação de tensão com afundamento de tensão. Essa melhora foi de 5%. É importante destacar que a taxa de acerto aumentou de 95% para 100%, ou seja, a otimização do método de segmentação por meio do AG permitiu o acerto de 100% dos sinais analisados com essa combinação de distúrbio.

A maior diferença obtida entre a *Daubechies 6*, determinada empiricamente, e a *Coiflets 2*, determinada por meio de otimização por AG, foi de 9%. Esse melhora significativa ocorreu durante a segmentação da combinação de flutuação de tensão com elevação de tensão.

Tanto por meio das Wavelets Daubechies 6 quanto para as Coiflets 2, a taxa foi de 100% de acerto na segmentação das interrupções de tensão.

No caso de notching, apesar do aumento no percentual ser de apenas 1%, o método passou a identificar as posições inicial e final do distúrbio em todos os 100 casos analisados.

Nos demais distúrbios, a saber, transitório impulsivo, transitório oscilatório, transitório oscilatório com afundamento de tensão e transitório oscilatório com elevação de tensão, as duas abordagens foram 100% efetivas na determinação dos pontos inicial e final dos distúrbios, conforme apresentado na Figura 45.

É importante mencionar que o desempenho médio da segmentação dos distúrbios foi de 97,78%.

### 5.3.2 Análise do Desempenho do Método Otimizado para a Classificação dos Sinais

O Gráfico da Figura 46 apresenta a taxa de classificação para todos os distúrbios em análise de forma comparativa entre o método de "Validação Cruzada", inicialmente utilizado, e a otimização do procedimento de classificação por meio de AG.

Pode-se notar que tanto por meio da "Validação Cruzada", quanto por meio do AG, os resultados são muito próximos. Isso se deve ao fato de que o AG determinou como indivíduo mais apto para extração de características e classificação  $(xx_x; TWD_2; PMC)$  o mesmo que foi determinado pela "Validação Cruzada". O indivíduo mais apto empregou a Wavelet Daubechies 6 para extração de características, ou seja, a mesma Wavelet determinada pela "Validação Cruzada". Assim como o indivíduo mais apto empregou uma RNA com uma única camada intermediária formada por 10 neurônios, ou seja, a mesma topologia determinada pela "Validação Cruzada".

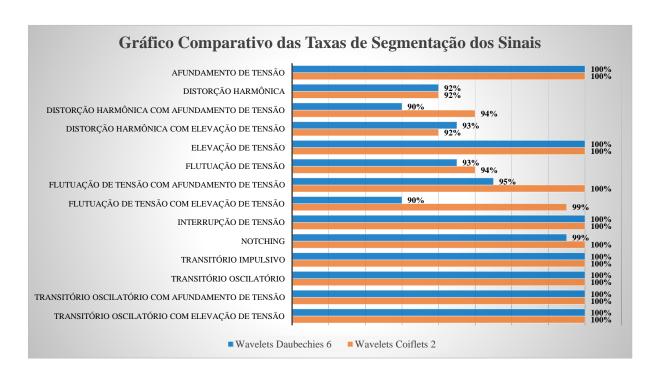


Figura 45 – Taxas de segmentação (Daubechies 6 vs Coiflets 2).

Os únicos distúrbios que apresentaram taxa de classificação distintas foram de distorção harmônica com afundamento de tensão e transitório oscilatório com afundamento de tensão. Nesses casos, a diferença foi de, no máximo, 1%, ou seja, menos de 3 sinais no montante de 280 sinais utilizados no conjunto de testes, como apresentado na Seção 4.3.5. Isso se deve ao fato de que a inicialização dos pesos das RNAs é aleatória. Contudo, essa diferença não é significativa para invalidar os resultados obtidos, uma vez que o AG foi executado 50 vezes, como apresentado no Algoritmo 2, e sempre indicou o mesmo indivíduo como aquele mais apto. Esse indivíduo é formado pela Wavelet Coiflets 2, para segmentação, Daubehies 6 para a extração de características e uma RNA com uma única camada intermediária com 10 neurônios  $(TWD_1; TWD_2; PMC)$ .

#### 5.4 Módulo de Compressão dos Sinais

Como detalhado na Seção 4.4.4, o processo de determinação das taxas de compressão e das distorções referentes à compressão de cada um dos sinais (afundamentos de tensão, elevações de tensão, interrupções de tensão, transitórios, distorções harmônicas, flutuações de tensão e notching, afundamento de tensão com flicker, elevação de tensão com flicker, afundamento de tensão com distorção harmônica, transitório com elevação de tensão e transitório com afundamento de tensão) foi dividido em treinamento e testes.

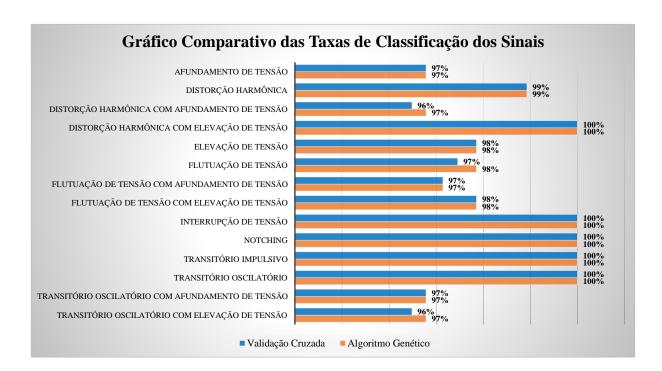


Figura 46 – Taxas de classificação (Validação Cruzada vs Algoritmo Genético).

## 5.4.1 Análise do Desempenho do Método para a Compressão dos Sinais

Foram utilizados dados sintéticos para treinamento e teste do modelo adotado para a compressão dos sinais associados à QEE. O desempenho do indivíduo determinado como o mais adequado para se determinar a taxa de compressão dos sinais é apresentado nas Tabelas 8 e 9.

Também foi analisado o comportamento dos parâmetros do melhor indivíduo diante de oscilografias disponíveis na base de dados da IEEE 1159.3 Task Force (1993). As Figuras 48, 49, 50, 51, 52 e 53 apresentam curvas comparativas entre os sinais originais e os sinais reconstruídos após o processo de compressão considerado nessa pesquisa e apresentados na Seção 4.4.4.

### 5.4.1.1 Sinais Sintéticos

Os resultados apresentados nesta seção são referentes ao desempenho da compressão de sinais distintos daqueles usados na otimização multiobjetivo do NSGA-II e são apresentados na Tabela 9. Para cada um dos distúrbios em análise, foi determinado um indivíduo mais adequado para a compressão dentre todas as possíveis soluções (Fronteira de Pareto II), segundo o critério adotado na Seção 4.4.4.3.

Uma consulta na literatura correlata indicou que a wavelet mais comumente empre-

gada para decomposição dos sinais associados à QEE durante o processo de compressão de sinais é a *Daubechies 4*, sendo a máxima taxa de compressão obtida de 16:1, referente a uma distorção de NMSE =  $1,0 \times 10^{-5}$ . (SANTOSO; POWERS; GRADY, 1997; HSIEH; HUANG; HUANG, 1998; CHUNG et al., 1999; HUANG; JOU, 2004a; LORIO; MAGNAGO, 2004; TCHEOU et al., 2014).

Uma análise sobre transitório oscilatório e notching foi apresentada em Chung et al. (1999). Os autores empregaram a família de wavelets Daubechies com suporte 4 para decompor os sinais e usaram uma técnica chamada de zerotree para executar a compressão. O melhor resultado obtido foi uma taxa de compressão de 16:1 com uma distorção de  $NMSE = 1,0 \times 10^{-5}$ .

Outra análise de sinais relacionados à QEE foi apresentada em Hsieh e Huang (2003). Os autores empregaram a família de wavelets Daubechies com suporte 4 para decompor sinais de afundamento de tensão, elevação de tensão, interrupção de tensão e distorção harmônica. Huffman coding foi o método de compressão sem perdas utilizado. A melhor taxa de compressão obtida foi de 3,43:1 com uma distorção harmônica de NMSE =  $1,0 \times 10^{-5}$ .

A compressão de afundamentos, elevações e interrupções de tensão foi realizada por Huang e Jou (2004b). Os autores também empregaram a família de wavelets Daubechies para decompor os sinais e os métodos de Huffman coding e Arithmetic coding como as técnicas de compressão sem perdas. Os resultados obtidos foram de 6,9:1 para a taxa de compressão, com distorção de NMSE= $1,0 \times 10^{-5}$ .

Uma taxa de compressão de 16:1 com distorção de NMSE= $1,0\times10^{-5}$ , foi obtida também por Lorio e Magnago (2004). No entanto, os autores analisaram mais amostras de distúrbios relacionados à QEE, dentre as quais, as caracterizando flutuação de tensão, elevação de tensão, afundamento de tensão, harmônicos e transitórios impulsivos. A família de wavelets Daubechies com suporte 4 foi utilizada na decomposição dos distúrbios mencionados e os métodos de compressão sem perdas foram Huffman coding e Arithmetic coding.

Esse breve relato sobre a bibliografia correlata foi necessário para justificar os dados apresentados na Tabela 9. Como mencionado na literatura correlata, as análises foram concentradas na aplicação da família de wavelets Daubechies com suporte 4. Entretanto, a otimização por meio do NSGA-II indicou, para todos os sinais analisados, que a Wavelet Biortogonal com suporte 3.1 é a mais adequada para uso na compressão dos sinais analisados. Desse modo, a Tabela 9 apresenta dados comparativos entre essas duas famílias de Wavelets, assim como dados comparativos dentre as duas técnicas de compressão sem perdas mais comumente utilizadas nesse tipo de problema, Huffman coding e Arithmetic coding (HUANG; JOU, 2004a; LORIO; MAGNAGO, 2004).

A Tabela 8 apresenta as abreviaturas dos nomes dos distúrbios dos sinais para a formatação e o entendimento adequado da Tabela 9.

Abreviatura	Distúrbios			
Afund.	Afundamento de tensão			
Harm.	Distorção harmônica			
Elev.	Elevação de tensão			
Flut.	Flutuação de tensão			
Int.	Interrupção de tensão			
Notching	Notching			
Imp.	Transitório impulsivo			
Osc.	Transitório Oscilatório			
Afund. com Flut.	Afundamento de tensão com flutuação de tensão			
Elev. com Flut.	Elevação de tensão com flutuação de tensão			
Afund. com Harm.	Afundamento de tensão com distorção harmônica			
Elev. com Harm.	Elevação de tensão com distorção harmônica			
Osc. com Elev.	Transitório oscilatório com elevação de tensão			
Osc. com Afund.	Transitório oscilatório com afundamento de tensão			

Tabela 8 – Abreviaturas dos distúrbios.

A Tabela 9 apresenta as taxas de compressão de todos os distúrbios analisados nessa pesquisa. Foram obtidos resultados de três abordagens:

- Pelo uso da wavelet Daubechies com suporte 4, como na literatura correlata;
- Pelo uso da wavelet Daubechies com suporte 4 e com a determinação pelo NSGA-II
  dos outros parâmetros necessários para a compressão (Limiar; Fator de Escala; e
  Constante de Deslocamento); e
- Pela determinação de todos os parâmetros necessários para a compressão pelo NSGA-II, inclusive as wavelets, resultando no uso da wavelet Biortogonal com suporte 3.1 como a mais apta para a compressão dos sinais.

Essas três abordagens foram empregadas tanto com o método de compressão sem perdas *Huffman coding*, como pelo método de compressão sem perdas *Arithmetic coding*.

Pode-se notar que os resultados obtidos, empregando-se a família da wavelet Biortogonal com suporte 3.1, são melhores do que aqueles obtidos empregando-se a família de wavelet Daubechies com suporte 4, tanto não-otimizada quanto otimizada pelo NSGA-II.

Um aspecto importante dessa pesquisa foi a análise de 14 tipos de distúrbios (8 distúrbios individuais e 6 distúrbios combinados), uma vez que, na literatura correlata são analisados casos de 3 ou 4 distúrbios individuais apenas.

É importante destacar da Tabela 9, que as piores taxas de compressão, empregandose a família de wavelets Biortogonal com suporte 3.1, foram obtidas nos casos de distorção harmônica, elevação de tensão com harmônicos e elevação de tensão com oscilatório transitório. Entretanto, mesmo para esses casos, as taxas de compressão de 16:1 são superior as observadas na literatura correlata.

Distorção (NMSE) = $1.0 \times 10^{-5}$									
	Taxa de Compressão								
Distúrbios	Huffman coding			Arithmetic coding					
	db4	db4	bior3.1	db4	db4	bior3.1			
	não-oti	oti	oti	não-oti	oti	oti			
Afund.	21:1	26:1	29:1	24:1	31:1	37:1			
Harm.	13:1	15:1	15:1	13:1	16:1	16:1			
Elev.	19:1	22:1	23:1	21:1	25:1	29:1			
Flut.	16:1	23:1	26:1	17:1	26:1	27:1			
Int	23:1	32:1	35:1	30:1	42:1	48:1			
Int	23:1	32:1	35:1	30:1	42:1	48:1			
Notching	12:1	14:1	17:1	13:1	14:1	17:1			
Imp.	10:1	13:1	17:1	11:1	14:1	18:1			
Osc.	14:1	18:1	20:1	15:1	20:1	22:1			
Afund. com Flut.	24:1	26:1	29:1	28:1	32:1	37:1			
Elev. com Flut.	19:1	22:1	22:1	21:1	26:1	29:1			
Afund. com Harm.	15:1	18:1	18:1	16:1	19:1	19:1			
Elev. com Harm.	15:1	16:1	16:1	15:1	16:1	16:1			
Osc. com Elev.	13:1	14:1	15:1	13:1	15:1	16:1			
Osc. com Afund.	17:1	21:1	23:1	18:1	23:1	27:1			

Tabela 9 – Comparação da taxa de compressão.

A maior taxa de compressão obtida foi para interrupções de tensão. Isso se deve ao fato de que no caso desse distúrbio, a quantização cria uma "zona morta" (Seção 4.4.1) mais extensa do que no caso de outros distúrbios.

Houveram ganhos de até 55% na taxa de compressão do método não otimizado com uso da wavelet Daubechies com suporte 4, como encontrado na bibliografia, quando comparado ao método otimizado pelo NSGA-II com uso das wavelets Biortogonal com suporte 3.1.

A Figura 47 apresenta o valor médio da taxa (bits por amostra) para representar os 14 distúrbios em análise após o processo de compressão. É importante mencionar que originalmente foram utilizados 32 bits para representar cada amostra do sinal.

Pode-se observar que na compressão menos eficiente, em que foi empregada a wavelet Daubechies com suporte 4 e o método de compressão sem perdas Huffman coding, são necessários 1,6 bits para representar cada amostra dos sinais, considerando-se uma distorção de NMSE =  $1,0 \times 10^{-5}$ .

Para o caso em que foi empregada a wavelet Daubechies com suporte 4, mas o método de compressão sem perdas utilizado foi o Arithmetic coding, o resultado foi melhor, pois apresentou um taxa de 1,5 bits por amostra.

No caso da compressão empregando-se a wavelet Biortogonal com suporte 3.1, indicada como a mais apta pelo NSGA-II para decomposição dos sinais e posterior quantização e compressão, os resultados foram ainda melhores. Pode-se verificar que o uso

dessa família de wavelets, associada ao método de compressão sem perdas Huffman coding, apresentou uma taxa ligeiramente superior a 1,4 bits por amostra e, quando associada com o método de compressão sem perdas Arithmetic coding, a taxa caiu para 1,3 bits por amostra. Em todos estes casos, a distorção de referência foi de NMSE =  $1,0 \times 10^{-5}$ .

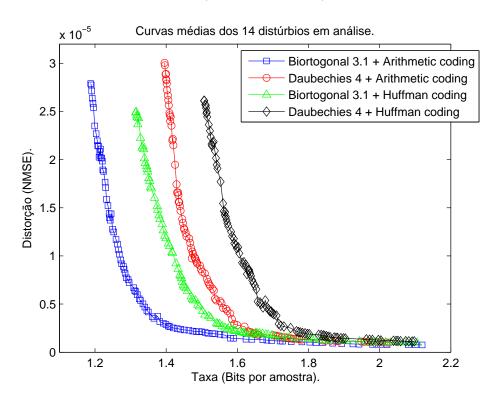


Figura 47 – Gráficos das taxas (bits por amostra) médias dos 14 distúrbios.

Fonte: Autoria própria.

Portanto, o uso da wavelet Biortogonal com suporte 3.1, e o método de compressão sem perdas Arithmetic coding, resultou em um número menor de bits necessários para representar cada sinal com distúrbio.

## 5.4.1.2 Oscilografias Reais

Um aspecto primordial dos métodos de compressão de sinais com perdas, como o empregado nessa pesquisa, diz respeito às informações que podem ser perdidas durante o processo de quantização dos sinais. Desse modo, as distorções causadas têm que ser mantidas em níveis aceitáveis para cada tipo de aplicação. No caso de compressão com perdas de dados de áudio (SPANIAS, 1994) e imagens (SULLIVAN et al., 2012), por exemplo, esses níveis estão relacionados com as percepções auditiva e visual dos seres humanos, respectivamente.

No caso da análise visual das oscilografias dos distúrbios associados à QEE, os níveis aceitáveis das distorções causadas por métodos de compressão com perdas de sinais,

como o empregado nessa pesquisa, estão relacionados evidentemente às percepções visuais dos sinais analisados.

Contudo, segundo a literatura correlata consultada, os níveis aceitáveis para distorções em sinais de distúrbios de QEE devem ser próximos de NMSE =  $1,0 \times 10^{-5}$  (SANTOSO; POWERS; GRADY, 1997; HSIEH; HUANG; HUANG, 1998; CHUNG et al., 1999; HUANG; JOU, 2004a; LORIO; MAGNAGO, 2004; TCHEOU et al., 2014), como empregado na Tabela 9.

Desse modo, nas figuras que seguem, as curvas reconstruídas (em vermelho), que são as curvas que passaram pelo processo de compressão empregado nessa pesquisa (Figura 21), possuem um comportamento nitidamente similar ao das curvas originais (em azul), após a sua descompressão.

Pode-se verificar esse relevante resultado pelos gráficos das Figuras 48, 49, 50, 51, 52 e 53. Cabe afirmar que esse importante resultado pode ser verificado para todos os casos de oscilografias reais analisadas, a saber: harmônicos, transitório oscilatório, transitório oscilatório com afundamento de tensão, elevação de tensão, interrupção de tensão e transitórios impulsivos.

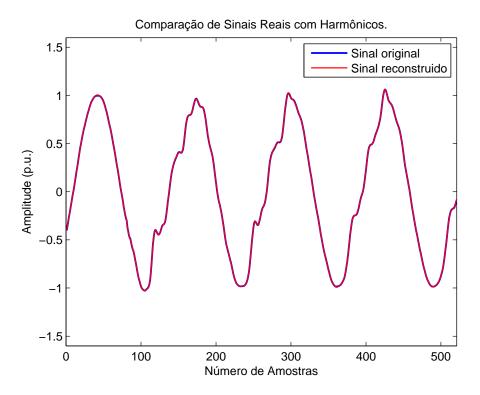


Figura 48 – Curvas comparativas para harmônicos.

Figura 49 – Curvas comparativas para transitório oscilatório.

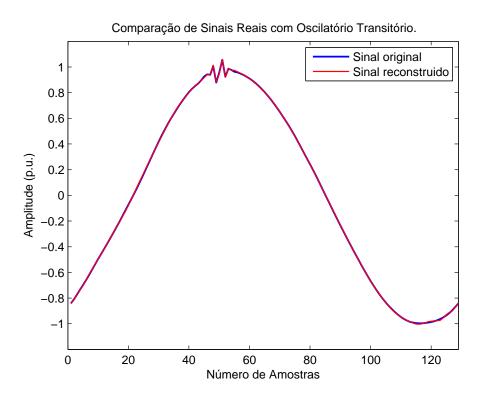


Figura 50 – Curvas comparativas para transitório oscilatório com afundamento de tensão.

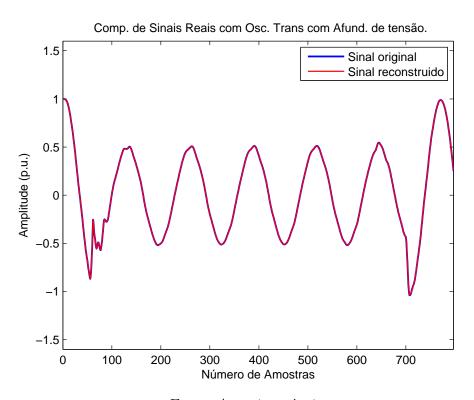


Figura 51 – Curvas comparativas para elevação de tensão.

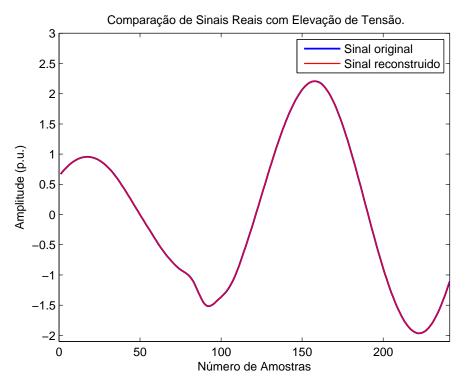
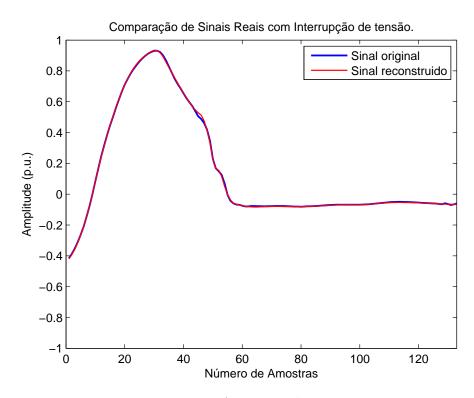


Figura 52 – Curvas comparativas para interrupção de tensão.



Comparação de Sinais Reais com Transitórios Impulsivos. 3 Sinal original Sinal reconstruido 2.5 2 Amplitude (p.u.) 1.5 0.5 0 -0.5 -1 <u>-</u> 20 40 60 80 100 120

Figura53 – Curvas comparativas para transitório impulsivo.

Número de Amostras

## Conclusões Gerais

A pesquisa conduzida e referente a esta tese de doutorado apresenta seis etapas principais. Todas fortemente embasadas em uma extensiva revisão bibliográfica realizada para se conhecer e se aprofundar nos métodos utilizados e aplicados ao contexto desta pesquisa, bem como para ressaltar as contribuições decorrentes do trabalho desenvolvido.

A primeira etapa da pesquisa consistiu na geração de uma base sintética de dados formada por sinais com 8 tipos de distúrbios individuais (afundamentos de tensão, elevações de tensão, interrupções de tensão, transitórios impulsivos e oscilatórios, distorções harmônicas, flutuações de tensão e notching), e 6 tipos de distúrbios combinados (afundamento de tensão com flicker, elevação de tensão com flicker, afundamento de tensão com distorção harmônica, transitório com elevação de tensão e transitório com afundamento de tensão).

A criação dessa base de dados foi baseada nos modelos matemáticos apresentados na Seção 4.2.1 e amplamente empregados na área de pesquisa de distúrbios associados à falta de QEE (UYAR; YILDIRIM; GENCOGLU, 2008; PANIGRAHI; PANDI, 2009; ERISTI; UCAR; DEMIR, 2010; HOOSHMAND; ENSHAEE, 2010; TAN; RAMACHANDARA-MURTHY, 2010). Sua criação permitiu o desenvolvimento de todas as principais etapas da pesquisa. É importante mencionar que análises de oscilografias reais também foram incorporadas, como apresentado na Seção 5. Uma conclusão que se pode extrair dessa etapa da pesquisa é a necessidade de que a comunidade acadêmica se alie ao meio corporativo, formado por concessionárias e empresas de energia elétrica para a criação de uma massa de dados de sinais de distúrbios relacionados à QEE que permita o desenvolvimento e a validação de técnicas de tratamento de sinais no contexto apresentado.

A segunda etapa da pesquisa compreendeu a análise e o desenvolvimento de um procedimento adaptativo que permitisse a segmentação de sinais que caracterizam distúrbios associados à falta da QEE. Vale ressaltar que trabalhos anteriores já empregaram a TW na detecção de distúrbios de QEE (XUE et al., 2008; TAN; RAMACHANDARA-MURTHY, 2009; MAHMOUDI; HOSSEINIAN; DOROUDI, 2010; SUSHAMA; RAM; LAXMI, 2010; DWIVEDI; TIWARI, 2015). Contudo, os autores se limitaram a apresentar

gráficos com as curvas de detalhes após a decomposição dos sinais pela TW. Na prática, não implementaram um método para segmentar efetivamente os sinais.

Desse modo, essa pesquisa propôs o uso das características da energia e da entropia da energia, extraídas do segundo nível de decomposição pela TWD, cujos valores se modificam de acordo com a intensidade dos distúrbios contidos nos sinais de QEE. Portanto, essas duas características permitiram que um limiar adaptativo fosse adotado para que sua intersecção com as descontinuidades das curvas de detalhes indicassem os pontos inicial e final dos distúrbios. De maneira geral, a abordagem empírica inicialmente empregada para a segmentação dos sinais apresentou um bom desempenho, na medida em que, no pior caso, não foram detectados 10% dos exemplos analisados para as distorções harmônicas com afundamento de tensão, e de flutuação de tensão com elevação de tensão. A conclusão que se pode apontar dessa etapa da pesquisa é de que foi possível desenvolver um método adaptativo que permitiu segmentar os distintos distúrbios presentes nos sinais de tensão em análise. Na prática, pode-se então armazenar apenas os trechos relevantes dos sinais de tensão, contendo e adequadamente representando os distúrbios, na medida em que esses forem registrados.

Concluída a etapa de segmentação adaptativa dos sinais, a terceira e a quarta etapas desenvolvidas passaram a ser a de extração de características por meio da TW (selecionadas por meio do WEKA) e de classificação por RNAs. É importante mencionar que, primeiramente, essas etapas foram desenvolvidas de forma também empírica, adotandose o procedimento de "Validação Cruzada" (HAYKIN, 2001) para garantir e avaliar o desempenho das funções.

Existem vários trabalhos técnico-científicos que empregaram a TW para a extração de características e as RNAs para a classificação dos distúrbios associados à QEE (ABDEL-GALIL et al., 2004; CHOONG; REAZ; MOHD-YASIN, 2005; REAZ et al., 2007; SAIKIA; BORAH; PAIT, 2010; KANIRAJAN; KUMAR, 2015). Entretanto, esses trabalhos concentraram seus métodos na família de wavelets Daubechies, ou seja, não fizeram uma investigação mais ampla sobre a família de wavelets mais adequada para a extração das características. Os trabalhos também não apresentaram maiores informações sobre como foi determinada a topologia das RNAs mais apropriada para a classificação. Desse modo, surgiu a necessidade de se verificar se os métodos empíricos adotados realmente se valeram de toda a capacidade das ferramentas empregadas na segmentação adaptativa, extração de características e na classificação dos distúrbios.

Desse modo, foi implementado um AG para otimizar as etapas de segmentação adaptativa, extração de características e classificação dos distúrbios em análise, com o intuito de determinar as wavelets e a topologia das RNAs mais aptas para essas tarefas. O desenvolvimento desse AG e os resultados observados caracterizam uma importante contribuição dessa pesquisa, sendo os resultados comparativos entre o método empírico e

o otimizado apresentados na Seção 5.3.

A quinta e primordial etapa dessa pesquisa foi a análise e o desenvolvimento de um método de compressão dos distúrbios para o contexto da QEE, uma vez que foi apresentada na Seção 1 a necessidade transmissão e de armazenamento dos sinais e seus dados em um centro de operação. Essa etapa consistiu no aprimoramento de um método já empregado na literatura correlata (CHUNG et al., 1999; HSIEH; HUANG, 2003; HUANG; JOU, 2004a; LORIO; MAGNAGO, 2004; TCHEOU et al., 2014). Esse método foi aprimorado para o problema de compressão/descompressão dessa pesquisa, como apresentado na Seção 4.4.

Vale comentar que, originalmente, nos trabalhos consultados, os autores que propuseram esse método o fizeram para um número reduzido de distúrbios. Ainda mais, o passo de decomposição dos sinais empregou apenas a família de wavelets Daubechies, ou seja, os autores não pesquisaram os resultados para os casos de outras famílias de wavelets. Os trabalhos também não apresentaram informações para tornar compreensível o passo de quantização linear da curva de detalhes adotada e não trataram de todas as variáveis de contexto necessárias para a compressão sem perdas por Huffman coding e Arithmetic coding.

Diferentemente dos trabalhos citados, essa pesquisa empregou um AG multiobjetivo para otimizar as variáveis de decisão (Limiar; Wavelets; Fator de Escala; Constante de Deslocamento) fundamentais para a compressão de sinais voltados à área de QEE. Desse modo, foi possível aprimorar o método proposto na literatura e elucidar todos os aspectos que envolvem os passos necessários para seu uso. Baseados nos resultados apresentados na seção 5.4, pode-se concluir que a família de wavelets Biortogonal demonstrou ser a mais adequada para a decomposição dos sinais no contexto apresentado, da QEE, para sua posterior compressão. Conclui-se também que o método baseado na otimização pelo NSGA-II foi eficiente na determinação do limiar para a quantização dos sinais. A determinação do fator de escala e da constante de deslocamento pelo NSGA-II também caracterizou uma significativa contribuição para a área de compressão de sinais no cenário pesquisado.

Após a compressão e transmissão dos sinais, os mesmos podem então ser armazenados em forma de arquivos do *Matlab Mathworks* ©, possuindo todas as variáveis necessárias para a posterior descompressão e visualização de suas informações.

Para finalizar, é importante destacar a forma inovadora em que foram utilizadas wavelets, sistemas inteligentes e métodos de compressão sem perdas, no que se refere a cada uma das etapas dessa pequisa, visando aprimorar as condições de operação dos SEPs.

## 6.1 Publicações Decorrentes da Pesquisa Realizada

Em seguida são apresentadas as publicações originadas até o depósito desta tese:

- de Andrade L. C. M., Oleskovicz M., Fernandes, R. A. S. Adaptive Threshold Based on Wavelet Transform Applied to the Segmentation of Single and Combined Power Quality Disturbances. Applied Soft Computing, ISSN: 1568-4946, v. 38, p. 967-977, 2016.
- de Andrade L. C. M., Oleskovicz M., Fernandes, R. A. S. Adaptive threshold for segmentation of combined Power Quality disturbances. In: 2015 IEEE Eindhoven PowerTech, 2015, Eindhoven. 2015 IEEE Eindhoven PowerTech. p. 1-5.
- de Andrade L. C. M., Oleskovicz M., Fernandes, R. A. S., Adaptive Threshold for Electrical Disturbances Segmentation, Renewable Energy and Power Quality Journal (RE&PQJ), ISSN 2172-038X, No.12, 2014.
- de Andrade, L. C. M.; Oleskovicz, M., Fernandes, R. A. S. Analysis of Wavelet Transform applied to the segmentation of disturbance signals with different sampling rates, PES General Meeting, pg. 1-5, 2014.
- de Andrade, L. C. M.; Oleskovicz, M., Fernandes, R. A. S., Power quality disturbances segmentation based on wavelet decomposition and adaptive thresholds, IEEE 16th International Conference on Harmonics and Quality of Power (ICHQP), pg. 803 -807, 2014.
- de Andrade L. C. M., Oleskoviz M., Fernandes, R. A. S., Limiar Adaptativo Empregado na Segmentação de Distúrbios em Qualidade de Energia Elétrica, Anais do XX Congresso Brasileiro de Automática, pg. 3098-3105 2014.

ABDEL-GALIL, T. et al. Disturbance classification using hidden markov models and vector quantization. **IEEE Transactions on Power Delivery**, v. 20, n. 3, p. 2129–2135, 2005. ISSN 0885-8977.

\_\_\_\_\_. Power quality disturbance classification using the inductive inference approach. **IEEE Transactions on Power Delivery**, v. 19, n. 4, p. 1812–1818, 2004. ISSN 0885-8977.

ADDISON, P. The Illustrated Wavelet Transform Handbook: Introductory Theory and Applications in Science, Engineering, Medicine and Finance. [S.l.]: Taylor & Francis, 2002. ISBN 9781420033397.

ANDRADE, L. C. M. de; OLESKOVICZ, M.; FERNANDES, R. A. S. Analysis of wavelet transform applied to the segmentation of disturbance signals with different sampling rates. In: **2014 IEEE PES General Meeting** | **Conference Exposition**. [S.l.: s.n.], 2014. p. 1–5.

ANGARITA, J. A. C. Compressão de Dados para Sinais de Distúrbios no Ambiente de Redes Elétricas Inteligentes. 2013. Tese de Doutorado em Engenharia de Sistemas Eletrônicos e de Automação PPGEA.TD 069/2013, Departamento de Engenharia Elétrica, Universidade de Brasília., 2013.

ARRILLAGA, J.; WATSON, N.; CHEN, S. Power system quality assessment. [S.l.]: John Wiley & Sons, 2000. ISBN 9780471988656.

BARBOSA, B.; FERREIRA, D. Classification of multiple and single power quality disturbances using a decision tree-based approach. **Journal of Control, Automation and Electrical Systems**, v. 24, n. 5, p. 638–648, 2013. ISSN 2195-3899.

BASHEER, I.; HAJMEER, M. Artificial neural networks: fundamentals, computing, design, and application. **Journal of Microbiological Methods**, v. 43, n. 1, p. 3-31, 2000. ISSN 0167-7012. Neural Computing in Microbiology.

BOLLEN, M. et al. Bridging the gap between signal and power. **IEEE Signal Processing Magazine**, v. 26, n. 4, p. 12–31, July 2009. ISSN 1053-5888.

CHANDRASHEKAR, G.; SAHIN, F. A survey on feature selection methods. **Computers and Electrical Engineering**, v. 40, n. 1, p. 16–28, 2014.

CHOONG, F.; REAZ, M. B. I.; MOHD-YASIN, F. Power quality disturbance detection using artificial intelligence: A hardware approach. In: **2005 Proceedings of 19th IEEE International Parallel and Distributed Processing Symposium**. [S.l.: s.n.], 2005. p. 146a–146a.

- CHRISTY, J.; VEDAMANI, X.; KARTHIKEYAN, S. Wavelet based detection of power quality disturbance a case study. In: **2011 International Conference on Signal Processing, Communication, Computing and Networking Technologies (ICSCCN)**. [S.l.: s.n.], 2011. p. 157–162.
- CHUNG, J. et al. Variable rate power disturbance signal compression using embedded zerotree wavelet transform coding. In: **Power Engineering Society 1999 Winter Meeting, IEEE**. [S.l.: s.n.], 1999. v. 2, p. 1305–1309 vol.2.
- COVER, T.; THOMAS, J. Elements of Information Theory. [S.l.]: Wiley, 2006. (A Wiley-Interscience publication). ISBN 9780471748816.
- DAPPER, R. E. et al. High compression ratio algorithm for power quality signals. In: **2015 IEEE 24th International Symposium on Industrial Electronics (ISIE)**. [S.l.: s.n.], 2015. p. 1322–1326. ISSN 2163-5137.
- DEB, K. et al. A fast and elitist multiobjective genetic algorithm: Nsga-ii. **IEEE** Transactions on Evolutionary Computation, v. 6, n. 2, p. 182–197, Apr 2002. ISSN 1089-778X.
- DEBNATH, L. Wavelet transform and their application. **PINSA-A**, v. 64, n. 06, p. 685–713, Nobember 1998.
- DEPURU, S.; WANG, L.; DEVABHAKTUNI, V. Smart meters for power grid: Challenges, issues, advantages and status. **Renewable and Sustainable Energy Reviews**, v. 15, n. 6, p. 2736–2742, 2011.
- DU, K.-L. Clustering: A neural network approach. **Neural Networks**, v. 23, n. 1, p. 89 107, 2010. ISSN 0893-6080.
- DUARTE, M. et al. Signal compression in wireless sensor networks. Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences, v. 370, n. 1958, p. 118–135, 2012.
- DUGAN, R. et al. Electrical Power Systems Quality, Third Edition. [S.l.]: McGraw-Hill Education, 2012. ISBN 9780071761567.
- DWIVEDI, U.; TIWARI, C. Detection and time localization of power quality events using orthogonal polynomial. In: . [S.l.: s.n.], 2015.
- EKICI, S. Classification of power system disturbances using support vector machines. **Expert Systems with Applications**, v. 36, n. 6, p. 9859 9868, 2009. ISSN 0957-4174.
- ELMITWALLY, A. et al. Proposed wavelet-neurofuzzy combined system for power quality violations detection and diagnosis. **IEEE Proceedings of Generation**, **Transmission and Distribution**, v. 148, n. 1, p. 15–20, 2001. ISSN 1350-2360.

ERISTI, H.; UCAR, A.; DEMIR, Y. Wavelet-based feature extraction and selection for classification of power system disturbances using support vector machines. **Electric Power Systems Research**, v. 80, n. 7, p. 743–752, 2010. ISSN 0378-7796.

- ERISTI, H. et al. Optimal feature selection for classification of the power quality events using wavelet transform and least squares support vector machines. **International Journal of Electrical Power & Energy Systems**, v. 49, p. 95 103, 2013. ISSN 0142-0615.
- ESHELMAN, L. J.; CARUANA, R. A.; SCHAFFER, J. D. Biases in the crossover landscape. In: **Proceedings of the Third International Conference on Genetic Algorithms**. San Francisco, CA, USA: Morgan Kaufmann Publishers Inc., 1989. p. 10–19. ISBN 1-55860-006-3.
- FARHANGI, H. The path of the smart grid. **IEEE Power and Energy Magazine**, v. 8, n. 1, p. 18–28, 2010.
- FOSTER, J. A. Evolutionary computation. **Nature Reviews Genetics**, v. 2, p. 428–436, June 2001. ISSN 1471-0064.
- GARGOUR, C. et al. A short introduction to wavelets and their applications. Circuits and Systems Magazine, IEEE, v. 9, n. 2, p. 57–68, Second 2009. ISSN 1531-636X.
- GEREK, O. N.; ECE, D. G. Compression of power quality event data using 2d respresentation. **Electric Power System Research**, v. 78, n. 6, p. 1047–1052, 2008. ISSN 0378-7796.
- GHARAVI, H.; GHAFURIAN, R. Smart grid: The electric energy system of the future. **Proceedings of the IEEE**, v. 99, n. 6, p. 917–921, 2011.
- HAGAN, M.; MENHAJ, M. Training feedforward networks with the marquardt algorithm. **IEEE Transactions on Neural Networks**, v. 5, n. 6, p. 989–993, Nov 1994. ISSN 1045-9227.
- HALL, M.; HOLMES, G. Benchmarking attribute selection techniques for discrete class data mining. **IEEE Transactions on Knowledge and Data Engineering**, v. 15, n. 6, p. 1437–1447, Nov 2003. ISSN 1041-4347.
- HAMID, E.; KAWASAKI, Z.-I. Wavelet-based data compression of power system disturbances using the minimum description length criterion. **IEEE Transactions on Power Delivery**, v. 17, n. 2, p. 460–466, Apr 2002. ISSN 0885-8977.
- HAQUE, M.; KASHTIBAN, A. Application of neural networks in power systems; a review. In: [S.l.: s.n.], 2005. v. 6, p. 53–57.
- HAYKIN, S. Redes Neurais Princípios de prática. [S.l.]: Bookman Companhia Ed., 2001. ISBN 9788573077186.
- HE, H.; STARZYK, J. A self-organizing learning array system for power quality classification based on wavelet transform. **IEEE Transactions on Power Delivery**, v. 21, n. 1, p. 286–295, 2006. ISSN 0885-8977.
- HEYDT, G. Electric power quality: a tutorial introduction. **IEEE Computer Applications in Power**, v. 11, n. 1, p. 15–19, Jan 1998. ISSN 0895-0156.

HILL, T. et al. Artificial neural network models for forecasting and decision making. **International Journal of Forecasting**, v. 10, n. 1, p. 5 – 15, 1994. ISSN 0169-2070.

- HOOSHMAND, R.; ENSHAEE, A. Detection and classification of single and combined power quality disturbances using fuzzy systems oriented by particle swarm optimization algorithm. **Electric Power Systems Research**, v. 80, n. 12, p. 1552–1561, 2010. ISSN 0378-7796.
- HSIEH, C. T.; HUANG, S. J. Disturbance data compression of a power system using the huffman coding approach with wavelet transform enhancement. **IEE Proceedings Generation, Transmission and Distribution**, v. 150, n. 1, p. 7–14, Jan 2003. ISSN 1350-2360.
- HSIEH, C.-T.; HUANG, S.-J.; HUANG, C.-L. Data reduction of power quality disturbances a wavelet transform approach. **Electric Power System Research**, v. 47, n. 2, p. 79–86, 1998. ISSN 0378-7796.
- HUANG, J.; NEGNEVITSKY, M.; NGUYEN, D. A neural-fuzzy classifier for recognition of power quality disturbances. **IEEE Transactions on Power Delivery**, v. 17, n. 2, p. 609–616, 2002. ISSN 0885-8977.
- HUANG, S.-J.; JOU, M.-J. Application of arithmetic coding for electric power disturbance data compression with wavelet packet enhancement. **IEEE Transactions on Power Systems**, v. 19, n. 3, p. 1334–1341, 2004.
- \_\_\_\_\_. Application of arithmetic coding for electric power disturbance data compression with wavelet packet enhancement. **IEEE Transactions on Power Systems**, v. 19, n. 3, p. 1334–1341, Aug 2004. ISSN 0885-8950.
- HUNTER, I. Power quality issues-a distribution company perspective. **Power Engineering Journal**, v. 15, n. 2, p. 75–80, April 2001. ISSN 0950-3366.
- IBRAHIM, W.; MORCOS, M. Novel data compression technique for power waveforms using adaptive fuzzy logic. **IEEE Transactions on Power Delivery**, v. 20, n. 3, p. 2136–2143, July 2005. ISSN 0885-8977.
- IEC 61000-1-1. IEC 61000 1 1 Electromagnetic Campatibility EMC. [S.l.], 2013.
- IEC 61000-2-1. Electromagnetic compatibility (EMC) Part 2: Environment Section 1: Description of the environment Electromagnetic environment for low-frequency conducted disturbances and signalling in public power supply systems. 1990.
- IEC 61000-3-4. Electromagnetic compatibility (EMC) Part 3-4: Limits Limitation of emission of harmonic currents in low-voltage power supply systems for equipment with rated current greater than 16 A. 1998.
- IEC 61000-4-15. Electromagnetic compatibility (EMC) Part 4-15: Testing and measurement techniques Flickermeter Functional and design specifications. 2010.
- IEEE 1159.3 Task Force. **IEEE 1159.3 Online Documents**. 1993. Disponível em <grouper.ieee.org/groups/1159/3/docs.html>.

IEEE Std 100-1992. The New IEEE Standards Dictionary of Electrical and Electronics Terms. 1993.

IEEE Std 1100-2005. **IEEE Recommended Practice for Powering and Grounding Electronic Equipment**. 2006. 1-703 p.

IEEE Std 1159-1995. **IEEE Recommended Practice for Monitoring Electric Power Quality**. 1995. i- p.

JANIK, P.; LOBOS, T. Automated classification of power-quality disturbances using svm and rbf networks. **IEEE Transactions on Power Delivery**, v. 21, n. 3, p. 1663–1669, 2006. ISSN 0885-8977.

JARAMILLO, S.; HEYDT, G.; O'NEILL-CARRILLO, E. Power quality indices for aperiodic voltages and currents. **IEEE Transactions on Power Delivery**, v. 15, n. 2, p. 784–790, 2000.

JONG, K. de. Learning with genetic algorithms: An overview. **Machine Learning**, v. 3, n. 2, p. 121–138, 1988.

KANIRAJAN, P.; KUMAR, V. S. Power quality disturbance detection and classification using wavelet and rbfnn. **Applied Soft Computing Journal**, v. 35, p. 470–481, 2015.

LE, C.; GU, I.; BOLLEN, M. Joint causal and anti-causal segmentation and location of transitions in power disturbances. In: **Power and Energy Society General Meeting, 2010 IEEE**. [S.l.: s.n.], 2010. p. 1–6. ISSN 1944-9925.

LIAO, Y.; LEE, J.-B. A fuzzy-expert system for classifying power quality disturbances. **International Journal of Electrical Power & Energy Systems**, v. 26, n. 3, p. 199 – 205, 2004. ISSN 0142-0615.

LIMA, F. P.; LOTUFO, A. D. P.; MINUSSI, C. R. Disturbance detection for optimal database storage in electrical distribuition systems using artificial immune systems with negative selection. **Electric Power System Research**, v. 109, n. 0, p. 54–62, 2014. ISSN 0378-7796.

LITTLER, T.; MORROW, D. Wavelets for the analysis and compression of power system disturbances. **IEEE Transactions on Power Delivery**, v. 14, n. 2, p. 358–364, Apr 1999. ISSN 0885-8977.

LORENA, A. C.; CARVAHO, A. Introdução as Máquinas de Vetores Suporte. [S.l.], 2003.

LORIO, F.; MAGNAGO, F. Analysis of data compression methods for power quality events. In: **Power Engineering Society General Meeting, 2004. IEEE**. [S.l.: s.n.], 2004. p. 504–509 Vol.1.

MAHMOUDI, A.; HOSSEINIAN, S. H.; DOROUDI, A. A new and fast method for detection of power quality disturbances using wavelet transform. In: **2010 1st Power Quality Conferance**, **PQC 2010**. [S.l.: s.n.], 2010.

MALEK, A. Recurrent neural networks. In: \_\_\_\_\_. [S.l.]: InTech, 2008. cap. Applications of Recurrent Neural Networks to Optimization Problems, p. 255–288. ISBN 9789537619084.

MARDIA, K. Measures of multivariate skewness and kurtosis with applications. **Biometrika**, v. 57, n. 3, p. 519–530, 1970.

MASOUM, M. A. S.; JAMALI, S.; GHAFFARZADEH, N. Detection and classification of power quality disturbances using discrete wavelet transform and wavelet networks. **Science, Measurement Technology, IET**, v. 4, n. 4, p. 193–205, 2010. ISSN 1751-8822.

MEHER, S.; PRADHAN, K.; PANDA, G. An integrated data compression scheme for power quality events using spline wavelet and neural network. **Electric Power Systems Research**, v. 69, n. 2-3, p. 213–220, 2004. ISSN 0378-7796.

MICHEL, A.; FARRELL, J. Associative memories via artificial neural networks. **IEEE** Control Systems Magazine, v. 10, n. 3, p. 6–17, April 1990. ISSN 0272-1708.

MISITI, M. et al. Wavelets and their Applications. [S.l.]: ISTE Ltd USA, 2007. ISBN 9781905209316.

MITCHELL, M. An introduction to genetic algorithms. [S.l.]: Massachusetts Institute of Technology, 2002. (Eastern economy edition). ISBN 9788120313583.

MITCHELL, M.; TAYLOR, C. E. Evolutionary computation: An overview. **Annual Review of Ecology and Systematics**, v. 30, p. 593–616, 1999.

MORAVEJ, Z.; PAZOKI, M.; ABDOOS, A. A. Wavelet transform and multi-class relevance vector machines based recognition and classification of power quality disturbances. **European Transactions on Electrical Power**, John Wiley & Sons, Ltd., v. 21, n. 1, p. 212–222, 2011. ISSN 1546-3109.

MOSLEHI, K.; KUMAR, R. A reliability perspective of the smart grid. **IEEE** Transactions on Smart Grid, v. 1, n. 1, p. 57–64, 2010.

NING, J. et al. A wavelet-based data compression technique for smart grid. **IEEE** Transactions on Smart Grid, v. 2, n. 1, p. 212–218, March 2011. ISSN 1949-3053.

OLESKOVICZ, M. et al. Power quality analysis applying a hybrid methodology with wavelet transforms and neural networks. **International Journal of Electrical Power & Energy Systems**, v. 31, n. 5, p. 206 – 212, 2009. ISSN 0142-0615.

PANDA, G. et al. Data compression of power quality events using the slantlet transform. **IEEE Transactions on Power Delivery**, v. 17, n. 2, p. 662–667, Apr 2002. ISSN 0885-8977.

PANIGRAHI, B.; PANDI, V. Optimal feature selection for classification of power quality disturbances using wavelet packet-based fuzzy k-nearest neighbour algorithm. **IET Generation, Transmission and Distribution**, v. 3, n. 3, p. 296–306, 2009. ISSN 1751-8695.

POISSON, O.; RIOUAL, P.; MEUNIER, M. Detection and measurement of power quality disturbances using wavelet transform. In: **1998. Proceedings. 8th International Conference On Harmonics and Quality of Power Proceedings.** [S.l.: s.n.], 1998. v. 2, p. 1125–1130 vol.2.

- REAZ, M. et al. Expert system for power quality disturbance classifier. **IEEE** Transactions on Power Delivery, v. 22, n. 3, p. 1979–1988, 2007. ISSN 0885-8977.
- RIBEIRO, M. et al. A novel mdl-based compression method for power quality applications. **IEEE Transactions on Power Delivery**, v. 22, n. 1, p. 27–36, Jan 2007. ISSN 0885-8977.
- RIBEIRO, M.; ROMANO, J.; DUQUE, C. An improved method for signal processing and compression in power quality evaluation. **IEEE Transactions on Power Delivery**, v. 19, n. 2, p. 464–471, April 2004. ISSN 0885-8977.
- RIBEIRO, P. Wavelet transform: as advanced tool for analysing non-stationary harmonic distortion in power systems. In: **Proceeding of the 1994 IEEE International**Conference in Harmonics and Power Systems. [S.l.: s.n.], 1994. p. 365–369.
- ROBERTSON, D. C.; CAMPS, O. I.; MAYER, J. Wavelets and power system transients: feature detection and classification. In: [S.l.: s.n.], 1994. v. 2242, p. 474–487.
- RUNHONG, H.; SEN, O.; YILI, S. A precise location method of power quality disturbances based on morphological edge detection. In: **2012 Asia-Pacific Power and Energy Engineering Conference (APPEEC)**. [S.l.: s.n.], 2012. p. 1–5. ISSN 2157-4839.
- SAIKIA, L.; BORAH, S. M.; PAIT, S. Detection and classification of power quality disturbances using wavelet transform, fuzzy logic and neural network. In: **2010 Annual IEEE India Conference (INDICON)**. [S.l.: s.n.], 2010. p. 1–5.
- SALOMON, D.; MOTTA, G. Handbook of Data Compression. 5th. ed. [S.l.]: Springer Publishing Company, Incorporated, 2009. ISBN 1848829027, 9781848829022.
- SANTOSO, S. Fundamentals of Electric Power Quality. [S.l.]: CreateSpace Independent Publishing Platform, 2012. ISBN 9781440491023.
- SANTOSO, S.; POWERS, E.; GRADY, W. Electric power quality disturbance detection using wavelet transform analysis. In: **1994. Proceedings of the IEEE-SP International Symposium on Time-Frequency and Time-Scale Analysis**. [S.l.: s.n.], 1994. p. 166–169.
- \_\_\_\_\_. Power quality disturbance data compression using wavelet transform methods. **IEEE Transactions on Power Delivery**, v. 12, n. 3, p. 1250–1257, Jul 1997. ISSN 0885-8977.
- SANTOSO, S. et al. Power quality assessment via wavelet transform analysis. **IEEE** Transactions on Power Delivery, v. 11, n. 2, p. 924–930, 1996. ISSN 0885-8977.
- \_\_\_\_\_. Power quality disturbance waveform recognition using wavelet-based neural classifier. i. theoretical foundation. **IEEE Transactions on Power Delivery**, v. 15, n. 1, p. 222–228, 2000. ISSN 0885-8977.
- SAYOOD, K. Introduction to Data Compression. [S.l.]: Morgan Kaufmann Publishers, 2000. (Morgan Kaufmann series in multimedia information and systems). ISBN 9781558605589.

SHARIATINASAB, R.; AKBARI, M.; RAHMANI, B. Application of Wavelet Analysis in Power Systems, Advances in Wavelet Theory and Their Applications in Engineering, Physics and Technology. [S.l.]: InTech, 2012. ISBN 9789535104940.

- SILVA, I. N.; SPATTI, D. H.; FLAUZINO, R. A. Redes neurais artificiais para engenharia e ciências aplicadas. [S.l.: s.n.], 2010. ISBN 9788588098534.
- SPANIAS, A. S. Speech coding: A tutorial review. **Proceedings of the IEEE**, IEEE, v. 82, n. 10, p. 1541–1582, 1994.
- SULLIVAN, G. J. et al. Overview of the high efficiency video coding (HEVC) standard. **IEEE Transactions on Circuits and Systems for Video Technology**, IEEE, v. 22, n. 12, p. 1649–1668, 2012.
- SUSHAMA, M.; RAM, G. T.; LAXMI, A. J. Detection of power quality disturbances using wavelet transforms. **International Journal of the Computer, the Internet and Management**, v. 18, n. 1, p. 61–66, 2010. ISSN 0858-7027.
- SYSWERDA, G. Uniform crossover in genetic algorithms. In: **Proceedings of the 3rd International Conference on Genetic Algorithms**. San Francisco, CA, USA: Morgan Kaufmann Publishers Inc., 1989. p. 2–9. ISBN 1-55860-066-3.
- TAN, R. H. G.; RAMACHANDARAMURTHY, V. K. Power system transient analysis using scale selection wavelet transform. In: **TENCON 2009 2009 IEEE Region 10 Conference**. [S.l.: s.n.], 2009. p. 1–6.
- \_\_\_\_\_. Numerical model framework of power quality events. **European Journal of Scientific Research**, v. 43, p. 30–47, 2010. ISSN 1450-202X.
- TCHEOU, M. P. et al. The compression of electric signal waveforms for smart grids: State of the art and future trends. **IEEE Transactions on Smart Grid**, v. 5, n. 1, p. 291–302, Jan 2014. ISSN 1949-3053.
- TINÓS, R.; CARVALHO, A. Evolutionary computation in brazil: A review of the literature in two databases. **Revista de Informática Aplicada**, v. 4, n. 2, p. 34–69, 2008. ISSN 18095585.
- TWYCROSS, A.; SHIELDS, L. Statistics made simple. part 1. mean, medians and modes. **Paediatric nursing**, v. 16, n. 4, p. 32, 2004.
- \_\_\_\_\_. Statistics made simple. part 2. standard deviation, variance and range. **Paediatric** nursing, v. 16, n. 5, p. 24, 2004.
- UYAR, M.; YILDIRIM, S.; GENCOGLU, M. An effective wavelet-based feature extraction method for classification of power quality disturbance signals. **Electric Power Systems Research**, v. 78, n. 10, p. 1747–1755, 2008. ISSN 0378-7796.
- VEGA, V. et al. Selecting wavelet functions for detection of power quality disturbances. In: **2008 IEEE/PES Transmission and Distribution Conference and Exposition:** Latin America. [S.l.: s.n.], 2008. p. 1–4.

WANG, C.; GAO, H.; ZHU, T. A new method for detection and identification of power quality disturbance. In: **2006 IEEE PES Power Systems Conference and Exposition**, **PSCE '06.** [S.l.: s.n.], 2006. p. 1556–1561.

- WILLIS, M. et al. Artificial neural networks in process estimation and control. **Automatica**, v. 28, n. 6, p. 1181 1187, 1992. ISSN 0005-1098.
- WITTEN, I.; FRANK, E.; HALL, M. Data Mining: Practical Machine Learning Tools and Techniques. [S.l.]: Elsevier Science, 2011. (The Morgan Kaufmann Series in Data Management Systems). ISBN 9780080890364.
- XUE, B.; ZHANG, M.; BROWNE, W. Particle swarm optimization for feature selection in classification: A multi-objective approach. **IEEE Transactions on Cybernetics**, v. 43, n. 6, p. 1656–1671, 2013.
- XUE, C. et al. Power quality disturbances detection and location using mathematical morphology and complex wavelet transformation. In: **Industrial Electronics and Applications**, **2008**. **ICIEA 2008**. **3rd IEEE Conference on**. [S.l.: s.n.], 2008. p. 2263–2268.
- YEGNANARAYANA, B. Artificial neural networks for pattern recognition. **Journal of the Indian Academy of Sciences, SADHANA**, v. 19, n. 2, p. 189–238, 1994. ISSN 0973-7677.
- ZAINUDDIN, Z.; ONG, P. Function approximation using artificial neural networks. **WSEAS Transactions on Mathematics**, v. 7, n. 6, p. 333–338, 2008. ISSN 2224-2880.
- ZHANG, H.; LIU, P.; MALIK, O. P. Detection and classification of power quality disturbances in noisy conditions. **IEEE Proceedings of Generation, Transmission and Distribution**, v. 150, n. 5, p. 567–572, 2003. ISSN 1350-2360.
- ZHENG-YOU, H.; XIAOQING, C.; GUOMING, L. Wavelet entropy measure definition and its application for transmission line fault detection and identification; (part i: Definition and methodology). In: **PowerCon 2006. International Conference on Power System Technology.** [S.l.: s.n.], 2006. p. 1–6.
- ZHU, T. X.; TSO, S.; LO, K. Wavelet-based fuzzy reasoning approach to power-quality disturbance recognition. **IEEE Transactions on Power Delivery**, v. 19, n. 4, p. 1928–1935, 2004. ISSN 0885-8977.